

Aula 7: POD em Mecânica dos Fluidos

PCA em snapshots de escoamento, modos POD, coeficientes temporais e energia modal

Prof. Dr. Rodrigo Figueiredo Abdo

1. Ideia central da aula

Nas aulas anteriores, a decomposição em valores singulares foi construída em três camadas. Primeiro, como fatoração matricial; depois, como ferramenta de aproximação de posto baixo; por fim, como base matemática da análise de componentes principais. Nesta aula, a mesma ideia será transportada para o ambiente natural da mecânica dos fluidos: campos que variam no espaço e no tempo.

Em uma simulação ou experimento de escoamento, o estado do sistema raramente é descrito por poucos números. Mesmo um caso bidimensional simples pode produzir, em cada instante, milhares ou milhões de valores: velocidades em pontos de malha, pressão, vorticidade, temperatura ou concentração. Se guardamos esses campos ao longo do tempo, obtemos uma coleção de snapshots. A pergunta central é: existe uma forma de extrair, desses snapshots, poucos padrões espaciais dominantes que expliquem boa parte da evolução observada?

A Proper Orthogonal Decomposition, ou POD, responde exatamente a essa pergunta. Ela é, em essência, a PCA aplicada a snapshots de campos. Na prática, organizamos os estados do escoamento em uma matriz, subtraímos o campo médio quando apropriado, aplicamos SVD e interpretamos os vetores singulares esquerdos como modos espaciais. Os coeficientes temporais aparecem nas amplitudes associadas a esses modos.

A força da POD está em transformar uma sequência de campos de alta dimensão em uma representação do tipo

$$\mathbf{u}(\mathbf{x}, t) \approx \bar{\mathbf{u}}(\mathbf{x}) + \sum_{j=1}^r a_j(t) \phi_j(\mathbf{x}),$$

onde ϕ_j são modos espaciais ortonormais e $a_j(t)$ são coeficientes temporais. Quando poucos modos explicam a maior parte da energia das flutuações, obtemos uma descrição de baixa dimensão de um fenômeno originalmente descrito por muitos graus de liberdade.

A POD não é apenas uma técnica de compressão. Em mecânica dos fluidos, ela permite identificar estruturas coerentes, estudar energia modal, reduzir a dimensão de dados experimentais ou numéricos e preparar o caminho para modelos de ordem reduzida. Esta aula ainda não desenvolverá a projeção Galerkin-POD completa; isso ficará para a aula seguinte. O foco aqui é compreender a POD como análise de dados de escoamento.

2. De PCA para POD

Na PCA usual, consideramos uma matriz de dados centrados

$$B \in \mathbb{R}^{N \times d},$$

em que cada linha representa uma observação e cada coluna representa uma variável. A SVD

$$B = U \Sigma V^T$$

fornece direções principais, coordenadas principais e variância explicada.

Na POD, a organização mais comum em mecânica dos fluidos é ligeiramente diferente: cada coluna da matriz é um snapshot do campo. Assim, escrevemos

$$X = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \\ | & | & & | \end{bmatrix} \in \mathbb{R}^{n \times m},$$

onde $\mathbf{u}_k \in \mathbb{R}^n$ é o estado discretizado do escoamento no instante t_k , n é o número de graus de liberdade espaciais e m é o número de snapshots.

Se o campo for escalar, por exemplo vorticidade $\omega(x, y, t)$, então cada snapshot pode ser construído empilhando todos os valores da malha em um vetor. Se o campo for vetorial, por exemplo velocidade bidimensional $\mathbf{u} = (u, v)$, então uma possibilidade é concatenar as duas componentes:

$$\mathbf{q}_k = \begin{bmatrix} u(x_1, y_1, t_k) \\ \vdots \\ u(x_{N_p}, y_{N_p}, t_k) \\ v(x_1, y_1, t_k) \\ \vdots \\ v(x_{N_p}, y_{N_p}, t_k) \end{bmatrix} \in \mathbb{R}^{2N_p},$$

onde N_p é o número de pontos da malha (símbolo distinto do N de observações usado na PCA). Nesse caso, $n = 2N_p$. A matriz de snapshots passa a ser

$$X = \begin{bmatrix} \mathbf{q}_1 & \mathbf{q}_2 & \cdots & \mathbf{q}_m \end{bmatrix}.$$

A diferença entre PCA e POD é menos matemática do que interpretativa. A PCA fala em variáveis, observações e variância estatística. A POD fala em campos, snapshots, modos espaciais e energia modal. O significado físico dos fatores é que muda.

Há, porém, um detalhe de arrumação que precisa ficar explícito, sob pena de erro grosseiro na implementação: *as duas matrizes são transpostas uma da outra*. Na PCA cada observação é uma *linha* de $B \in \mathbb{R}^{N \times d}$; na POD cada snapshot é uma *coluna* de $X' \in \mathbb{R}^{n \times m}$, a matriz de

flutuações que definiremos na Seção 3; a comparação justa é com dados centrados dos dois lados. Como o snapshot faz o papel da observação e o ponto da malha faz o papel da variável, vale $X' = B^T$. A consequência é direta: escrevendo a SVD de X' como $X' = U\Sigma V^T$ (daqui em diante, U , Σ e V referem-se sempre à SVD de X'), temos $X'^T = V\Sigma^T U^T$, de modo que as componentes principais da PCA, que são os vetores singulares à *direita* da matriz de dados, correspondem, na POD, às colunas de U , os vetores singulares à *esquerda*. É a mesma decomposição lida de dois lados; trocar as convenções sem perceber leva, por exemplo, a alimentar uma rotina de PCA tratando pontos de malha como amostras.

Uma segunda ressalva: a identificação vale para o produto interno euclidiano. Quando se adota a matriz de massa M da Seção 5, a POD é uma PCA *ponderada*, um problema de autovalores generalizado, e não a mesma decomposição com outro nome. Vale notar ainda que a PCA frequentemente padroniza as variáveis, dividindo cada uma pelo seu desvio padrão; na POD isso não se faz, pois destruiria a estrutura espacial e a leitura energética.

3. Campo médio e flutuações

Em escoamentos, é comum separar o campo médio das flutuações. Dada a matriz de snapshots

$$X = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{bmatrix},$$

definimos o campo médio temporal por

$$\bar{\mathbf{u}} = \frac{1}{m} \sum_{k=1}^m \mathbf{u}_k.$$

A matriz cujas colunas repetem o campo médio é

$$\bar{X} = \bar{\mathbf{u}} \mathbf{1}^T,$$

onde

$$\mathbf{1} = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix}^T \in \mathbb{R}^m.$$

A matriz de flutuações é

$$X' = X - \bar{X}.$$

Assim, cada snapshot pode ser escrito como

$$\mathbf{u}_k = \bar{\mathbf{u}} + \mathbf{u}'_k.$$

A POD pode ser aplicada diretamente a X ou à matriz centrada X' . Em mecânica dos fluidos, aplicar POD às flutuações costuma ser mais informativo quando o interesse está nas estruturas não estacionárias do escoamento, como desprendimento de vórtices, oscilações de esteira, modos de instabilidade ou flutuações turbulentas. Se o campo médio não for subtraído,

o primeiro modo pode representar majoritariamente o escoamento médio, consumindo grande parte da energia modal e escondendo a dinâmica das flutuações.

Isso não significa que sempre devemos remover a média automaticamente. A escolha depende da pergunta física. Se o objetivo é comprimir o campo completo, incluir a média pode fazer sentido. Se o objetivo é entender a dinâmica coerente em torno de um estado médio, subtrair a média é geralmente o caminho natural.

4. SVD da matriz de snapshots

Aplicamos a SVD à matriz de flutuações:

$$X' = U\Sigma V^T.$$

Assumindo $X' \in \mathbb{R}^{n \times m}$, temos

$$U \in \mathbb{R}^{n \times n}, \quad \Sigma \in \mathbb{R}^{n \times m}, \quad V \in \mathbb{R}^{m \times m}.$$

Na forma reduzida, a que retém apenas as colunas associadas ao posto, como na Aula 4, onde o posto se chamava r ; aqui o denotamos r_0 para reservar r ao truncamento, se $r_0 = \text{rank}(X')$, escrevemos

$$X' = U_{r_0} \Sigma_{r_0} V_{r_0}^T,$$

em que

$$U_{r_0} = \begin{bmatrix} \phi_1 & \phi_2 & \cdots & \phi_{r_0} \end{bmatrix}.$$

As colunas de U_{r_0} são os modos POD. Cada modo ϕ_j é um campo espacial discretizado. Se o snapshot era uma imagem de vorticidade, ϕ_j pode ser reorganizado como uma imagem. Se o snapshot era um campo de velocidade, ϕ_j pode ser reorganizado como um campo vetorial.

A matriz V contém as direções temporais ortonormais dos modos; os coeficientes temporais propriamente ditos (não normalizados) são as linhas de ΣV^T . A matriz Σ pesa a importância de cada modo. De forma equivalente,

$$X' = \sum_{j=1}^{r_0} \sigma_j \phi_j \mathbf{v}_j^T,$$

onde $\mathbf{v}_j$ é a coluna j de V . Escolhendo um *posto de truncamento* $r \leq r_0$, o número de modos que decidimos manter, a coluna k de X' , isto é, o snapshot no instante t_k , é aproximada por

$$\mathbf{u}'_k \approx \sum_{j=1}^r a_j(t_k) \phi_j,$$

com

$$a_j(t_k) = \sigma_j V_{kj}.$$

Portanto, a matriz de coeficientes temporais é

$$A_r = \Sigma_r V_r^T \in \mathbb{R}^{r \times m}.$$

A linha j de A_r contém a evolução temporal do modo j .

Juntando média e flutuação, a reconstrução de posto r fica

$$\mathbf{u}_k \approx \bar{\mathbf{u}} + \sum_{j=1}^r a_j(t_k) \phi_j.$$

Em forma matricial,

$$X_r = \bar{X} + U_r \Sigma_r V_r^T.$$

5. Ortonormalidade dos modos e produto interno físico

Na SVD usual, os modos satisfazem

$$U_r^T U_r = I_r.$$

Isso significa que os modos são ortonormais em relação ao produto interno euclidiano dos vetores discretizados:

$$\langle \phi_i, \phi_j \rangle = \phi_i^T \phi_j = \delta_{ij}.$$

Em uma malha uniforme e para um campo escalar, esse produto interno pode ser interpretado como uma aproximação simples de uma integral espacial, a menos de um fator constante. Para um domínio Ω , a forma contínua do produto interno é

$$\langle \phi_i, \phi_j \rangle_{\Omega} = \int_{\Omega} \phi_i(\mathbf{x}) \phi_j(\mathbf{x}) \, d\Omega.$$

Para campos vetoriais de velocidade, usamos

$$\langle \phi_i, \phi_j \rangle_{\Omega} = \int_{\Omega} \phi_i(\mathbf{x}) \cdot \phi_j(\mathbf{x}) \, d\Omega.$$

Se a malha não for uniforme, ou se houver volumes de controle diferentes, o produto interno euclidiano simples pode não representar corretamente o produto interno físico. Nesse caso, introduzimos uma matriz de massa ou matriz de pesos M , simétrica e definida positiva, e usamos

$$\langle \mathbf{a}, \mathbf{b} \rangle_M = \mathbf{a}^T M \mathbf{b}.$$

Reunindo os modos nas colunas de $\Phi = [\phi_1 \cdots \phi_{r_0}]$, a ortonormalidade física passa a ser

$$\Phi^T M \Phi = I.$$

Atenção a um ponto que costuma passar despercebido e leva a implementações silenciosa-

mente erradas: *as colunas de U obtidas da SVD euclidiana de X' não satisfazem essa condição.* Elas satisfazem $U^T U = I$, e em geral $U^T M U$ é uma matriz cheia, não a identidade. Para obter modos M -ortonormais é preciso mudar o cálculo, e há dois caminhos equivalentes.

O primeiro é fatorar $M = L^T L$, com L triangular superior (é a fatoração de Cholesky, escrita aqui na forma $R^T R$), aplicar a SVD à matriz ponderada $Y = L X' = \hat{U} \Sigma V^T$, em que Σ e V são, daqui em diante, os fatores da SVD de Y , e recuperar

$$\Phi = L^{-1} \hat{U},$$

o que de fato dá $\Phi^T M \Phi = \hat{U}^T L^{-T} (L^T L) L^{-1} \hat{U} = \hat{U}^T \hat{U} = I$.

O segundo, mais barato quando $n \gg m$ e coerente com o método dos snapshots da próxima seção, é resolver o problema de autovalores da matriz pequena *ponderada*

$$C_t^{(M)} = X'^T M X' \in \mathbb{R}^{m \times m},$$

isto é, $C_t^{(M)} \mathbf{v}_j = \sigma_j^2 \mathbf{v}_j$ com autovetores $\mathbf{v}_j$ ortonormais e $\sigma_j > 0$, note que aqui os σ_j são os valores singulares *ponderados*, os de $Y = L X'$, e definir $\phi_j = X' \mathbf{v}_j / \sigma_j$. Verifica-se diretamente que $\phi_j^T M \phi_j = \delta_{ij}$, e que σ_j^2 já é a energia ponderada do modo j . Quando $M = I$, a matriz $C_t^{(M)}$ se reduz à matriz $C_t = X'^T X'$ que usaremos na Seção 7.

Esse ponto é importante. A POD maximiza energia em relação ao produto interno escolhido. Se o produto interno não representa a quantidade física de interesse, a interpretação energética dos modos pode ficar distorcida. Em uma primeira implementação didática com malha uniforme, é aceitável usar a SVD euclidiana, e é o que faremos no restante desta aula, de modo que as seções seguintes devem ser lidas com $M = I$. Em aplicações numéricas mais cuidadosas, a ponderação por volume, área ou massa deve ser considerada.

6. Energia modal

A SVD organiza os valores singulares em ordem decrescente:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_{r_0} > 0.$$

Para dados centrados (campo médio subtraído), a quantidade σ_j^2 mede a energia associada ao modo j , e é proporcional à variância, a variância amostral dos coeficientes temporais é $\sigma_j^2 / (m-1)$. Sem a centragem, σ_j^2 mede energia em torno da origem, não a variância das flutuações. A fração de energia do modo j é

$$E_j = \frac{\sigma_j^2}{\sum_{\ell=1}^{r_0} \sigma_\ell^2}.$$

A energia acumulada pelos primeiros r modos é

$$E_{\text{acum}}(r) = \frac{\sum_{j=1}^r \sigma_j^2}{\sum_{\ell=1}^{r_0} \sigma_\ell^2}.$$

Em um campo de velocidade incompressível discretizado em malha uniforme, a norma quadrática está relacionada à energia cinética das flutuações. De modo simplificado,

$$K'(t_k) \propto \|\mathbf{u}'_k\|_2^2.$$

Assim, quando dizemos que os dois primeiros modos POD explicam, por exemplo, 90% da energia, estamos dizendo que eles capturam 90% da norma quadrática total das flutuações presentes nos snapshots, dentro do produto interno adotado.

Essa frase deve ser interpretada com cuidado. Energia modal não é sinônimo automático de importância física. Um modo de baixa energia pode ser decisivo para uma instabilidade, para uma transição, para um evento raro ou para uma quantidade de interesse localizada. A POD ordena modos por variância/energia global, não por causalidade, controle ou relevância dinâmica.

7. Método dos snapshots

Em muitos problemas de fluidos, o número de graus de liberdade espaciais n é enorme, enquanto o número de snapshots m é bem menor. Nesse caso, calcular diretamente autovetores de

$$X'X'^T \in \mathbb{R}^{n \times n}$$

pode ser inviável. O método dos snapshots evita esse problema trabalhando com a matriz menor

$$C_t = X'^T X' \in \mathbb{R}^{m \times m}.$$

Se

$$C_t \mathbf{v}_j = \sigma_j^2 \mathbf{v}_j, \quad \|\mathbf{v}_j\|_2 = 1, \quad \sigma_j > 0,$$

então o modo espacial correspondente pode ser obtido por

$$\phi_j = \frac{1}{\sigma_j} X' \mathbf{v}_j.$$

De fato,

$$X'X'^T(X'\mathbf{v}_j) = X'(X'^T X')\mathbf{v}_j = X'(\sigma_j^2 \mathbf{v}_j) = \sigma_j^2(X'\mathbf{v}_j).$$

Logo, $X'\mathbf{v}_j$ é autovetor de $X'X'^T$, faltando apenas normalização. E a divisão por σ_j é exatamente a normalização correta, pois

$$\|X'\mathbf{v}_j\|_2^2 = \mathbf{v}_j^T X'^T X' \mathbf{v}_j = \sigma_j^2 \|\mathbf{v}_j\|_2^2 = \sigma_j^2.$$

As duas hipóteses são indispensáveis. Se $\sigma_j = 0$, então $X'\mathbf{v}_j = \mathbf{0}$, que não é autovetor, por isso o procedimento só produz os r_0 modos associados a valores singulares positivos. E se $\mathbf{v}_j$ não for unitário, a conta acima mostra que o fator $1/\sigma_j$ deixa de normalizar. Quando algum σ_j^2 é

repetido, é preciso ainda escolher uma base *ortonormal* do autoespaço correspondente, para que os ϕ_j saiam mutuamente ortogonais.

Vale registrar também a operação inversa, que é a que se usa na prática para projetar um snapshot qualquer sobre os modos. De $\phi_j^T X' = \sigma_j \mathbf{v}_j^T$ segue

$$a_j(t_k) = \phi_j^T \mathbf{u}'_k,$$

isto é, o coeficiente temporal é a projeção da flutuação sobre o modo. (No caso ponderado, $a_j(t_k) = \phi_j^T M \mathbf{u}'_k$.)

Esse procedimento é muito útil quando $n \gg m$. Em uma simulação bidimensional com $n = 10^6$ graus de liberdade e $m = 500$ snapshots, a matriz $X'X'^T$ teria dimensão $10^6 \times 10^6$, enquanto $X'^T X'$ teria dimensão 500×500 . A diferença computacional é enorme.

Do ponto de vista conceitual, o método dos snapshots mostra que os modos espaciais POD são combinações lineares dos próprios snapshots:

$$\phi_j = \frac{1}{\sigma_j} \sum_{k=1}^m V_{kj} \mathbf{u}'_k.$$

Portanto, a POD não inventa estruturas fora dos dados observados. Ela reorganiza os snapshots em direções ortogonais que capturam a maior energia possível.

8. Exemplo algébrico simples

Este exemplo é construído de trás para frente: escolhemos livremente tanto os modos quanto as amplitudes temporais, os valores abaixo são arbitrados, não calculados a partir de dado algum, e fabricamos os dados com eles. Como conhecemos a resposta de antemão, podemos verificar se a SVD a recupera. Em um problema real, o ponto de partida é o oposto: apenas X' é conhecido, e modos e amplitudes saem da SVD.

Considere, então, dois modos espaciais ortonormais em $\mathbb{R}^4$:

$$\phi_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \quad \phi_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ 0 \\ 1 \\ -1 \end{bmatrix}.$$

Suponha que quatro snapshots centrados sejam gerados por

$$\mathbf{u}'_k = a_1(t_k)\phi_1 + a_2(t_k)\phi_2,$$

com coeficientes igualmente escolhidos por nós, reunidos nos vetores $\mathbf{a}_1, \mathbf{a}_2 \in \mathbb{R}^4$, que escrevemos transpostos (como vetores linha), na mesma orientação em que aparecerão como linhas da matriz

de coeficientes na Seção 10:

$$\mathbf{a}_1^T = \begin{bmatrix} 2 & 0 & -2 & 0 \end{bmatrix}, \quad \mathbf{a}_2^T = \begin{bmatrix} 0 & 1 & 0 & -1 \end{bmatrix}.$$

A matriz de snapshots é

$$X' = \phi_1 \mathbf{a}_1^T + \phi_2 \mathbf{a}_2^T.$$

Como ϕ_1 e ϕ_2 são ortonormais e os vetores temporais $\mathbf{a}_1$ e $\mathbf{a}_2$ são ortogonais, a SVD é obtida diretamente normalizando as amplitudes temporais. Temos

$$\|\mathbf{a}_1\|_2 = \sqrt{2^2 + 0^2 + (-2)^2 + 0^2} = 2\sqrt{2},$$

$$\|\mathbf{a}_2\|_2 = \sqrt{0^2 + 1^2 + 0^2 + (-1)^2} = \sqrt{2}.$$

Logo,

$$\sigma_1 = 2\sqrt{2}, \quad \sigma_2 = \sqrt{2}.$$

Os vetores singulares direitos são

$$\mathbf{v}_1 = \frac{1}{2\sqrt{2}} \begin{bmatrix} 2 \\ 0 \\ -2 \\ 0 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 0 \\ -1 \\ 0 \end{bmatrix},$$

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ 1 \\ 0 \\ -1 \end{bmatrix}.$$

Portanto,

$$X' = \sigma_1 \phi_1 \mathbf{v}_1^T + \sigma_2 \phi_2 \mathbf{v}_2^T.$$

A energia total é

$$\sigma_1^2 + \sigma_2^2 = 8 + 2 = 10.$$

O primeiro modo explica

$$E_1 = \frac{8}{10} = 0,8,$$

e o segundo explica

$$E_2 = \frac{2}{10} = 0,2.$$

Assim, com apenas o primeiro modo, capturamos 80% da energia das flutuações. Com os dois modos, reconstruímos exatamente os snapshots.

Esse exemplo deixa claro que a POD separa dois objetos: padrões espaciais, dados por ϕ_j , e amplitudes temporais, dadas por $a_j(t_k) = \sigma_j V_{kj}$. Em problemas reais, os modos não são escolhidos manualmente; eles são extraídos da matriz de snapshots, e as amplitudes, por sua vez,

são lidas diretamente dos fatores ΣV^T ou obtidas projetando cada snapshot sobre os modos, $a_j(t_k) = \phi_j^T \mathbf{u}'_k$ (Seção 7).

9. POD em uma esteira de cilindro

Um dos exemplos mais clássicos em mecânica dos fluidos é o escoamento em torno de um cilindro. Para certos regimes de Reynolds, a esteira apresenta desprendimento alternado de vórtices, conhecido como esteira de von Kármán. Em uma simulação ou experimento, podemos registrar snapshots de velocidade, pressão ou vorticidade ao longo do tempo.

Suponha que usamos o campo de vorticidade $\omega(x, y, t)$. Cada snapshot é uma imagem escalar da esteira. Após discretizar o domínio e empilhar os valores da malha, construímos

$$X = \begin{bmatrix} | & | & & | \\ \omega_1 & \omega_2 & \cdots & \omega_m \\ | & | & & | \end{bmatrix}.$$

Subtraindo a média temporal, obtemos X' . A SVD fornece

$$X' = U \Sigma V^T.$$

As primeiras colunas de U , reorganizadas como campos no domínio, são os modos POD da vorticidade.

Em uma esteira periódica, é comum que os dois primeiros modos de flutuação apareçam como um par oscilatório. Eles representam padrões espaciais semelhantes, deslocados em fase, associados à oscilação periódica da esteira. Os coeficientes temporais correspondentes também aparecem defasados, tipicamente como $a_1(t) \sim \cos(2\pi ft)$ e $a_2(t) \sim \sin(2\pi ft)$, em que f é a frequência de desprendimento dos vórtices, escrevemos a fase como $2\pi ft$ para não reciclar o símbolo ω , reservado nesta aula à vorticidade, formando uma trajetória fechada no plano (a_1, a_2) . Convém ser preciso sobre a forma dessa trajetória: como $a_j(t_k) = \sigma_j V_{kj}$ e as colunas de V são unitárias, a órbita é em geral uma *ellipse* cujos semieixos são *proporcionais* a σ_1 e σ_2 , com razão de aspecto σ_1/σ_2 , no Exemplo da Seção 8, por exemplo, os semieixos são 2 e 1, com $\sigma_1 = 2\sqrt{2}$ e $\sigma_2 = \sqrt{2}$. Ela só é circular quando $\sigma_1 \approx \sigma_2$, o que de fato ocorre numa esteira periódica bem amostrada, e é justamente a assinatura do par oscilatório. Note a contrapartida: com $\sigma_1 = \sigma_2$ o *subespaço* bidimensional é bem definido, mas o *par de modos* não é único, qualquer rotação rígida dentro desse plano é igualmente válida, e por isso a fase absoluta do par é arbitrária. Essa estrutura é uma assinatura de dinâmica aproximadamente periódica em um subespaço bidimensional.





Figura 1: Primeiros modos POD do campo de vorticidade da esteira de cilindro (par oscilatório em quadratura de fase). (https://www.researchgate.net/publication/318710028_Special_Topics_in_CFD)



O par oscilatório percorre uma órbita quase circular: a dinâmica dominante vive num subespaço bidimensional.

A reconstrução com dois modos pode capturar a oscilação dominante da esteira:

$$\omega(x, y, t_k) \approx \bar{\omega}(x, y) + a_1(t_k)\phi_1(x, y) + a_2(t_k)\phi_2(x, y).$$

Modos posteriores podem capturar harmônicos, assimetrias, ruído numérico, efeitos transientes ou estruturas menores. A análise do espectro singular indica quantos modos são necessários para atingir uma determinada fração de energia.

O ponto conceitual é que a POD converte uma sequência de campos complexos em uma descrição modal: média, modos espaciais, amplitudes temporais e energia relativa. Isso permite estudar a esteira não apenas como uma sequência de imagens, mas como uma trajetória em um espaço de baixa dimensão.

10. Interpretação dos coeficientes temporais

A matriz de coeficientes temporais é

$$A_r = \Sigma_r V_r^T.$$

Escrevendo

$$A_r = \begin{bmatrix} - & \mathbf{a}_1^T & - \\ - & \mathbf{a}_2^T & - \\ & \vdots & \\ - & \mathbf{a}_r^T & - \end{bmatrix},$$

a linha j contém os valores $a_j(t_k)$ para todos os snapshots. Assim, cada modo espacial vem acompanhado de uma coordenada temporal.

Se dois coeficientes temporais apresentam comportamento aproximadamente senoidal e defasado de 90° , então o par de modos correspondente representa uma oscilação. Em uma esteira periódica, isso é esperado. Se os coeficientes decaem no tempo, podem indicar um transiente. Se apresentam crescimento, podem indicar instabilidade. Se parecem ruidosos, podem corresponder a modos de baixa energia, ruído ou estruturas mal resolvidas.

A POD, por si só, não fornece uma equação diferencial para $a_j(t)$. Ela fornece a coordenada temporal observada nos dados. A passagem de coordenadas temporais observadas para um modelo dinâmico é o próximo passo: regressão, DMD, SINDy, redes neurais ou Galerkin-POD podem ser usados para tentar construir uma lei de evolução em baixa dimensão.

11. POD como compressão, diagnóstico e pré-processamento

A POD pode ser usada de três formas complementares.

Primeiro, ela pode ser usada como compressão. Em vez de armazenar todos os snapshots, armazenamos o campo médio, os primeiros r modos, os r valores singulares dominantes e os coeficientes temporais associados. Se $r \ll m$ e $r \ll n$, a redução de armazenamento pode ser grande.

Segundo, ela pode ser usada como diagnóstico físico. O espectro singular informa se a dinâmica observada é efetivamente de baixa dimensão. Modos POD revelam estruturas spa-

ciais dominantes, enquanto coeficientes temporais indicam como essas estruturas aparecem e desaparecem no tempo.

Terceiro, ela pode ser usada como pré-processamento para aprendizado de máquina científico. Em vez de treinar modelos diretamente no espaço de dimensão n , podemos treinar modelos nos coeficientes $a_j(t)$, com dimensão r . Esse raciocínio é fundamental em modelos substitutos, modelos de ordem reduzida, DMD, SINDy e redes neurais para previsão temporal.

12. Limitações da POD

A POD é ótima para reconstrução linear de baixa dimensão em norma quadrática, mas não é uma ferramenta universal. A primeira limitação é que ela procura subespaços lineares. Se a dinâmica vive em uma variedade não linear, muitos modos podem ser necessários para representar algo que, geometricamente, possui poucos graus de liberdade.

A segunda limitação é a sensibilidade a translações e rotações. Uma estrutura coerente que simplesmente se desloca no espaço pode exigir muitos modos POD, porque a SVD tenta representá-la como combinação linear de padrões fixos. Uma onda viajante, por exemplo, pode ser fisicamente simples e ainda assim ter posto elevado na representação POD. O problema não está necessariamente na física, mas na escolha de coordenadas.

A terceira limitação é que a POD é orientada por energia. Modos de alta energia dominam a decomposição, mas modos de baixa energia podem ser dinamicamente relevantes. Em problemas de controle, instabilidade ou transição, pequenas componentes podem ter papel decisivo.

A quarta limitação é que os modos POD dependem dos dados usados para construí-los. Se os snapshots cobrem apenas uma faixa estreita de parâmetros ou condições iniciais, os modos podem falhar quando usados fora desse regime.

Essas limitações não diminuem a importância da POD. Elas indicam como usá-la corretamente. A POD deve ser lida como uma decomposição ótima dos dados disponíveis, no produto interno escolhido, para reconstrução linear de baixa dimensão. Qualquer interpretação além disso precisa ser sustentada por análise física e validação.

13. Síntese da aula

A POD é a aplicação da SVD a matrizes de snapshots de campos. Dado

$$X = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{bmatrix},$$

frequentemente trabalhamos com as flutuações

$$X' = X - \bar{\mathbf{u}}\mathbf{1}^T.$$

A SVD

$$X' = U\Sigma V^T$$

fornece modos espaciais nas colunas de U , valores singulares em Σ e evolução temporal normalizada em V . Os coeficientes temporais são

$$A = \Sigma V^T.$$

A aproximação de posto r é

$$\mathbf{u}_k \approx \bar{\mathbf{u}} + \sum_{j=1}^r a_j(t_k) \phi_j.$$

A energia modal é dada por

$$E_j = \frac{\sigma_j^2}{\sum_{\ell} \sigma_{\ell}^2},$$

e a energia acumulada pelos primeiros r modos é

$$E_{\text{acum}}(r) = \frac{\sum_{j=1}^r \sigma_j^2}{\sum_{\ell} \sigma_{\ell}^2}.$$

A POD permite identificar estruturas coerentes, comprimir dados, separar média e flutuações e construir coordenadas de baixa dimensão para futuros modelos dinâmicos.

14. Exercícios propostos

Exercício 1. Considere os três snapshots centrados

$$\mathbf{u}'_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{u}'_2 = \begin{bmatrix} 0 \\ 0 \\ 2 \end{bmatrix}, \quad \mathbf{u}'_3 = \begin{bmatrix} -1 \\ -1 \\ -2 \end{bmatrix}.$$

Monte a matriz X' . Determine seu posto e interprete quantos modos POD são necessários para reconstruir exatamente os dados.

Exercício 2. Para a matriz do Exercício 1, calcule $X'^T X'$. Explique por que essa matriz contém informações sobre correlações temporais entre snapshots.

Exercício 3. Uma matriz de snapshots centrados possui valores singulares

$$\sigma_1 = 30, \quad \sigma_2 = 20, \quad \sigma_3 = 5, \quad \sigma_4 = 2, \quad \sigma_5 = 1.$$

Calcule a fração de energia de cada modo e a energia acumulada pelos dois primeiros modos.

Exercício 4. Explique a diferença entre aplicar POD ao campo completo X e aplicar POD às flutuações $X' = X - \bar{\mathbf{u}}\mathbf{1}^T$. Em que situação a primeira escolha pode ser útil? Em que situação a segunda é mais adequada?

Exercício 5. Em uma esteira de cilindro periódica, os dois primeiros coeficientes temporais POD formam aproximadamente um círculo no plano (a_1, a_2) . O que isso sugere sobre a dinâmica dominante?

Exercício 6. Mostre que, se $X'^T X' \mathbf{v}_j = \sigma_j^2 \mathbf{v}_j$, então $\phi_j = X' \mathbf{v}_j / \sigma_j$ é autovetor de $X' X'^T$. Por que esse resultado é útil quando $n \gg m$?

Exercício 7. Discuta por que uma onda viajante pode exigir muitos modos POD, mesmo sendo descrita por uma estrutura física simples.

Exercício 8. Em uma malha não uniforme, por que o produto interno euclidiano pode ser inadequado para interpretar energia modal? Qual é o papel de uma matriz de pesos ou matriz de massa?

15. Referências

- BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2. ed. Cambridge University Press, 2022.