

Aula 8: Modelos de Ordem Reduzida e Consolidação do Módulo 1

Projeção em subespaços de baixa dimensão, Galerkin-POD conceitual e síntese de
SVD-PCA-POD

Prof. Dr. Rodrigo Figueiredo Abdo

1. Ideia central da aula

Nas aulas anteriores, construímos a base matemática para representar dados de alta dimensão por poucos padrões dominantes. A SVD mostrou que uma matriz pode ser decomposta em direções ordenadas por importância; o truncamento mostrou como aproximar uma matriz por poucos termos de posto 1; a PCA mostrou como interpretar, para dados centrados, as direções singulares como direções de máxima variância; e a POD transportou essa leitura para campos espaço-temporais, como velocidades, pressões e vorticidades em escoamentos.

A pergunta natural agora é mais forte. Até aqui, reduzimos dados. Mas, em mecânica dos fluidos computacional, não queremos apenas armazenar menos dados: queremos também simular, prever, controlar e investigar a dinâmica com menor custo. Essa é a motivação dos modelos de ordem reduzida, ou *Reduced-Order Models* (ROMs).

A ideia central de um ROM é representar o estado completo de um sistema por poucos coeficientes temporais. Em vez de descrever um escoamento por milhões de valores de velocidade e pressão em uma malha, buscamos escrever o campo como combinação de poucos modos espaciais:

$$\mathbf{u}(\mathbf{x}, t) \approx \bar{\mathbf{u}}(\mathbf{x}) + \sum_{j=1}^r a_j(t) \phi_j(\mathbf{x}), \quad r \ll n.$$

A alta dimensão fica nos modos espaciais ϕ_j , calculados uma vez a partir de dados ou de simulações. A evolução passa a ser descrita pelos poucos coeficientes $a_j(t)$. Assim, o problema deixa de ser: “qual é o valor do campo em todos os pontos da malha?” e passa a ser: “como evoluem os poucos coeficientes que multiplicam os modos dominantes?”

Essa mudança de pergunta é a essência da modelagem de ordem reduzida. Ela não elimina a física. Ao contrário, tenta preservar a física dominante em um subespaço menor.

2. Do sistema contínuo ao sistema de alta dimensão

Considere uma equação evolutiva genérica, escrita simbolicamente como

$$\frac{\partial u}{\partial t} = \mathcal{N}(u, u_x, u_{xx}, \dots, x, t; \beta),$$

onde $\mathcal{N}$ representa o operador que governa a evolução do sistema e β representa algum parâmetro físico ou geométrico. Em uma equação de difusão, β poderia ser a difusividade; em um escoamento, poderia envolver o número de Reynolds; em um problema térmico, poderia envolver propriedades do material.

Para resolver numericamente a equação, discretizamos o domínio espacial. Se o campo é avaliado nos pontos

$$x_1, x_2, \dots, x_n,$$

o estado numérico no instante t pode ser escrito como

$$\mathbf{u}(t) = \begin{bmatrix} u(x_1, t) \\ u(x_2, t) \\ \vdots \\ u(x_n, t) \end{bmatrix} \in \mathbb{R}^n.$$

O problema contínuo dá origem a um sistema de EDOs de alta dimensão:

$$\frac{d}{dt}\mathbf{u}(t) = \mathbf{F}(\mathbf{u}(t), t; \beta), \quad \mathbf{u}(t) \in \mathbb{R}^n.$$

Aqui, n pode ser muito grande. Em simulações bidimensionais, n pode estar na casa de milhares ou milhões. Em simulações tridimensionais, pode facilmente chegar a milhões ou bilhões de graus de liberdade.

O ROM parte dessa forma discreta. O objetivo não é descartar a equação governante, mas projetá-la em uma base menor.

3. A aproximação por subespaço de baixa dimensão

Suponha que, por POD, tenhamos encontrado r modos ortonormais

$$\phi_1, \phi_2, \dots, \phi_r \in \mathbb{R}^n, \quad r \ll n.$$

Agrupando esses modos como colunas, definimos

$$\Phi = \begin{bmatrix} | & | & & | \\ \phi_1 & \phi_2 & \cdots & \phi_r \\ | & | & & | \end{bmatrix} \in \mathbb{R}^{n \times r}.$$

Como os modos são ortonormais,

$$\Phi^T \Phi = I_r.$$

Em todo o tratamento matricial desta aula, assumimos o produto interno euclidiano, o caso de malha uniforme, a menos da constante de quadratura; as Seções 7 e 8 trabalham com o produto interno contínuo correspondente. Em malha não uniforme, com a matriz de massa M da Aula 7 e modos M -ortonormais ($\Phi^T M \Phi = I_r$), as projeções desta aula trocam Φ^T por $\Phi^T M$; em particular, o ROM de Galerkin fica $\dot{\mathbf{a}} = \Phi^T M \mathbf{F}(\Phi \mathbf{a})$.

A hipótese de baixa dimensão é

$$\mathbf{u}(t) \approx \Phi \mathbf{a}(t),$$

em que

$$\mathbf{a}(t) = \begin{bmatrix} a_1(t) \\ a_2(t) \\ \vdots \\ a_r(t) \end{bmatrix} \in \mathbb{R}^r.$$

Quando há campo médio, usamos

$$\mathbf{u}(t) \approx \bar{\mathbf{u}} + \Phi \mathbf{a}(t).$$

Para simplificar a exposição, omitiremos a média em boa parte das contas. Ela pode ser adicionada sem alterar a lógica central. Quando a média é mantida, $\mathbf{u} \approx \bar{\mathbf{u}} + \Phi \mathbf{a}$ e a projeção de Galerkin produz $\dot{\mathbf{a}} = \Phi^T \mathbf{F}(\bar{\mathbf{u}} + \Phi \mathbf{a})$, com o estado médio entrando como deslocamento constante no argumento de $\mathbf{F}$.

A aproximação $\mathbf{u} \approx \Phi \mathbf{a}$ diz que o estado do sistema está sendo aproximado por um vetor pertencente ao subespaço

$$\mathcal{S}_r = \text{span}\{\phi_1, \dots, \phi_r\}.$$

O ROM não tenta representar qualquer vetor de $\mathbb{R}^n$. Ele restringe a dinâmica a $\mathcal{S}_r$. Esse é o ganho e também o risco: se a solução real permanecer próxima desse subespaço, o modelo reduzido pode funcionar muito bem; se a solução sair dele, o erro cresce. Na prática, a construção de um ROM separa-se em duas etapas: uma etapa *offline*, na qual os modos e os operadores reduzidos são calculados uma única vez a partir de dados ou simulações, e uma etapa *online*, na qual o sistema reduzido é integrado repetidamente a baixo custo, com uma ressalva importante, discutida na Seção 9: isso vale plenamente no caso linear.

4. Coeficientes reduzidos como coordenadas no subespaço

Se $\mathbf{u}$ pertence exatamente ao subespaço gerado por Φ , então existe $\mathbf{a}$ com

$$\mathbf{u} = \Phi \mathbf{a}.$$

Como $\Phi^T \Phi = I_r$, multiplicando à esquerda por Φ^T obtemos

$$\Phi^T \mathbf{u} = \Phi^T \Phi \mathbf{a} = \mathbf{a}.$$

Assim,

$$\mathbf{a} = \Phi^T \mathbf{u}.$$

Essa é a projeção do estado completo nas coordenadas reduzidas.

Em geral, $\Phi \Phi^T \mathbf{u}$ é a projeção ortogonal de $\mathbf{u}$ em $\mathcal{S}_r$, quando $\mathbf{u}$ já pertence ao subespaço, ela devolve o próprio $\mathbf{u}$:

$$\mathbf{u}_r = \Phi \Phi^T \mathbf{u}.$$

O erro de projeção é

$$\mathbf{e} = \mathbf{u} - \mathbf{u}_r = \mathbf{u} - \Phi \Phi^T \mathbf{u}.$$

Por construção, esse erro é ortogonal ao subespaço:

$$\Phi^T \mathbf{e} = \mathbf{0}.$$

Essa condição de ortogonalidade é a ponte para a projeção de Galerkin.

Exemplo 1: coordenadas reduzidas em uma base ortonormal

Considere os dois vetores

$$\phi_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \phi_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Eles são ortonormais, pois

$$\phi_1^T \phi_1 = 1, \quad \phi_2^T \phi_2 = 1, \quad \phi_1^T \phi_2 = 0.$$

Logo,

$$\Phi = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 0 \\ 0 & 1 \end{bmatrix}.$$

Para o estado

$$\mathbf{u} = \begin{bmatrix} 2 \\ 4 \\ 3 \end{bmatrix},$$

as coordenadas reduzidas são

$$\mathbf{a} = \Phi^T \mathbf{u} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \\ 3 \end{bmatrix} = \begin{bmatrix} 6/\sqrt{2} \\ 3 \end{bmatrix} = \begin{bmatrix} 3\sqrt{2} \\ 3 \end{bmatrix}.$$

A reconstrução projetada é

$$\mathbf{u}_r = \Phi \mathbf{a} = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 3\sqrt{2} \\ 3 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \\ 3 \end{bmatrix}.$$

O erro é

$$\mathbf{e} = \mathbf{u} - \mathbf{u}_r = \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}.$$

De fato,

$$\Phi^T \mathbf{e} = \mathbf{0}.$$

O subespaço escolhido consegue representar exatamente a componente média entre as duas primeiras coordenadas e a terceira coordenada, mas não representa a diferença entre as duas primeiras coordenadas. A projeção substituiu $(2, 4)$ por seu valor médio $(3, 3)$.

5. Da aproximação do estado à aproximação da dinâmica

A aproximação $\mathbf{u} \approx \Phi \mathbf{a}$ reduz o armazenamento do estado. Porém, um ROM precisa de algo a mais: uma equação para $\mathbf{a}(t)$. Partimos do sistema completo

$$\frac{d}{dt} \mathbf{u} = \mathbf{F}(\mathbf{u}, t; \beta).$$

Substituindo $\mathbf{u} \approx \Phi \mathbf{a}$, temos

$$\frac{d}{dt} (\Phi \mathbf{a}) \approx \mathbf{F}(\Phi \mathbf{a}, t; \beta).$$

Como Φ é fixo no tempo,

$$\Phi \frac{d}{dt} \mathbf{a} \approx \mathbf{F}(\Phi \mathbf{a}, t; \beta).$$

Em geral, o lado direito $\mathbf{F}(\Phi \mathbf{a}, t; \beta)$ é um vetor em $\mathbb{R}^n$. Ele não precisa pertencer exatamente ao subespaço gerado por Φ . Assim, a igualdade exata pode não ser possível dentro do subespaço reduzido.

Definimos o resíduo

$$\mathbf{R}(\mathbf{a}, \dot{\mathbf{a}}, t) = \Phi \dot{\mathbf{a}} - \mathbf{F}(\Phi \mathbf{a}, t; \beta).$$

A projeção de Galerkin impõe que esse resíduo seja ortogonal ao subespaço dos modos:

$$\Phi^T \mathbf{R} = \mathbf{0}.$$

Logo,

$$\Phi^T (\Phi \dot{\mathbf{a}} - \mathbf{F}(\Phi \mathbf{a}, t; \beta)) = \mathbf{0}.$$

Usando $\Phi^T \Phi = I_r$, obtemos

$$\dot{\mathbf{a}} = \Phi^T \mathbf{F}(\Phi \mathbf{a}, t; \beta).$$

Portanto, o ROM Galerkin-POD é

$$\dot{\mathbf{a}}(t) = \Phi^T \mathbf{F}(\Phi \mathbf{a}(t), t; \beta), \quad \mathbf{a}(t) \in \mathbb{R}^r.$$

Essa é a fórmula central da aula.

O sistema original tinha dimensão n . O sistema reduzido tem dimensão r . Se $r \ll n$, o ganho potencial é grande. Entretanto, há uma sutileza importante: mesmo que $\mathbf{a}$ tenha dimensão r , o termo $\mathbf{F}(\Phi \mathbf{a}, t; \beta)$ ainda pode exigir reconstruir um vetor em $\mathbb{R}^n$. Em sistemas lineares, isso pode ser tratado de forma muito eficiente. Em sistemas não lineares, pode surgir um gargalo computacional.

6. Caso linear: redução clara e fechada

Considere o caso linear autônomo

$$\frac{d}{dt} \mathbf{u} = A \mathbf{u}, \quad A \in \mathbb{R}^{n \times n}.$$

Usando $\mathbf{u} \approx \Phi \mathbf{a}$, temos

$$\Phi \dot{\mathbf{a}} \approx A \Phi \mathbf{a}.$$

Projetando por Φ^T , obtemos

$$\dot{\mathbf{a}} = \Phi^T A \Phi \mathbf{a}.$$

Definimos

$$A_r = \Phi^T A \Phi \in \mathbb{R}^{r \times r}.$$

Assim, o modelo reduzido é

$$\dot{\mathbf{a}} = A_r \mathbf{a}.$$

Esse resultado mostra por que ROMs são particularmente transparentes em sistemas lineares: a matriz grande A é substituída pela matriz pequena A_r . Uma vez calculado A_r , a evolução pode ser realizada inteiramente no espaço reduzido.

Se houver termo fonte,

$$\frac{d}{dt} \mathbf{u} = A \mathbf{u} + \mathbf{f}(t),$$

então

$$\dot{\mathbf{a}} = A_r \mathbf{a} + \mathbf{f}_r(t), \quad \mathbf{f}_r(t) = \Phi^T \mathbf{f}(t).$$

Exemplo 2: projeção de um sistema linear

Considere

$$A = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & -10 \end{bmatrix}$$

e os modos do Exemplo 1:

$$\Phi = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 0 \\ 0 & 1 \end{bmatrix}.$$

Calculamos

$$A\Phi = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & -10 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} -1/\sqrt{2} & 0 \\ -2/\sqrt{2} & 0 \\ 0 & -10 \end{bmatrix}.$$

Logo,

$$A_r = \Phi^T A \Phi = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} -1/\sqrt{2} & 0 \\ -2/\sqrt{2} & 0 \\ 0 & -10 \end{bmatrix} = \begin{bmatrix} -3/2 & 0 \\ 0 & -10 \end{bmatrix}.$$

Assim, o ROM é

$$\begin{cases} \dot{a}_1 = -\frac{3}{2}a_1, \\ \dot{a}_2 = -10a_2. \end{cases}$$

Esse exemplo mostra que a projeção reduziu um sistema de dimensão 3 para um sistema de dimensão 2. O primeiro modo representa a média entre as duas primeiras coordenadas; por isso, as taxas -1 e -2 foram combinadas em uma taxa efetiva $-3/2$. O segundo modo coincide com a terceira coordenada, preservando a taxa -10 .

Note uma sutileza: o subespaço gerado por Φ não é invariante por A , pois $A\phi_1 = (-1/\sqrt{2}, -2/\sqrt{2}, 0)^T$ não pertence a $\mathcal{S}_r$, como sua terceira componente é nula, para estar no subespaço ele teria de ser múltiplo de ϕ_1 , mas as duas primeiras componentes não são iguais. A projeção Galerkin escolhe, dentro do subespaço, a taxa de variação que melhor aproxima *instantaneamente* a dinâmica original, em norma euclidiana, o que não garante que a trajetória resultante seja a melhor possível. Portanto, o ROM é uma aproximação da dinâmica original, não uma simples cópia exata em coordenadas menores.

7. Forma contínua da projeção Galerkin–POD

Em problemas de mecânica dos fluidos, é comum escrever a aproximação diretamente na forma contínua:

$$u(x, t) \approx \sum_{j=1}^r a_j(t) \phi_j(x).$$

Para campos vetoriais,

$$\mathbf{u}(\mathbf{x}, t) \approx \sum_{j=1}^r a_j(t) \phi_j(\mathbf{x}).$$

Considere uma equação escalar abstrata

$$\frac{\partial u}{\partial t} = \mathcal{N}(u, u_x, u_{xx}, \dots).$$

Substituindo a expansão modal,

$$\sum_{j=1}^r \dot{a}_j(t) \phi_j(x) \approx \mathcal{N} \left(\sum_{j=1}^r a_j(t) \phi_j(x), \dots \right).$$

A condição de Galerkin impõe que o resíduo seja ortogonal a cada modo ϕ_i . Assim,

$$\left\langle \sum_{j=1}^r \dot{a}_j \phi_j - \mathcal{N} \left(\sum_{j=1}^r a_j \phi_j, \dots \right), \phi_i \right\rangle = 0, \quad i = 1, \dots, r.$$

Se os modos são ortonormais,

$$\langle \phi_j, \phi_i \rangle = \delta_{ij},$$

então

$$\dot{a}_i(t) = \left\langle \mathcal{N} \left(\sum_{j=1}^r a_j(t) \phi_j, \dots \right), \phi_i \right\rangle, \quad i = 1, \dots, r.$$

Essa é a versão contínua da fórmula matricial

$$\dot{\mathbf{a}} = \Phi^T \mathbf{F}(\Phi \mathbf{a}).$$

O ponto conceitual importante é que Galerkin não significa apenas “substituir e torcer para funcionar”. Galerkin escolhe as equações reduzidas impondo que o erro da equação, medido pelo resíduo, não tenha componente nas direções retidas. Em outras palavras, dentro das direções que decidimos preservar, o modelo reduzido deve obedecer à dinâmica da melhor forma possível.

8. Exemplo conceitual: equação do calor em base modal

Considere a equação do calor unidimensional

$$\frac{\partial u}{\partial t} = \alpha \frac{\partial^2 u}{\partial x^2}, \quad 0 < x < L, \quad \alpha > 0,$$

com condições de contorno homogêneas

$$u(0, t) = u(L, t) = 0.$$

Uma base natural para esse problema é dada por funções seno:

$$\phi_j(x) = \sqrt{\frac{2}{L}} \sin\left(\frac{j\pi x}{L}\right).$$

Essas funções são ortonormais em $[0, L]$: a ortogonalidade $\int_0^L \phi_i \phi_j dx = 0$ para $i \neq j$ segue das fórmulas de produto de senos e, como $\int_0^L \sin^2(j\pi x/L) dx = L/2$, o fator $\sqrt{2/L}$ garante $\int_0^L \phi_j^2 dx = 1$. Vale lembrar que a ortonormalidade discreta $\Phi^T \Phi = I$ corresponde a essa ortonormalidade contínua apenas a menos do peso de quadratura da malha; em malha uniforme, os dois pontos de vista coincidem a menos de uma constante. Elas também satisfazem

$$\frac{\partial^2 \phi_j}{\partial x^2} = -\left(\frac{j\pi}{L}\right)^2 \phi_j.$$

Suponha a expansão reduzida

$$u(x, t) \approx \sum_{j=1}^r a_j(t) \phi_j(x).$$

Como os modos $\phi_j(x)$ são fixos no tempo, derivar u em t atinge apenas os coeficientes:

$$\frac{\partial u}{\partial t} = \sum_{j=1}^r \dot{a}_j(t) \phi_j(x).$$

Substituindo na equação do calor, e aqui a igualdade exata é legítima, não apenas $\approx$, porque o operador leva cada ϕ_j em múltiplo de si mesmo, de modo que o subespaço dos senos é invariante,

$$\sum_{j=1}^r \dot{a}_j(t) \phi_j(x) = \alpha \sum_{j=1}^r a_j(t) \frac{\partial^2 \phi_j}{\partial x^2}.$$

Logo,

$$\sum_{j=1}^r \dot{a}_j(t) \phi_j(x) = -\alpha \sum_{j=1}^r a_j(t) \left(\frac{j\pi}{L}\right)^2 \phi_j(x).$$

Projetando no modo ϕ_i , isto é, tomando o produto interno com ϕ_i , a ortonormalidade $\langle \phi_j, \phi_i \rangle = \delta_{ij}$ anula todos os termos com $j \neq i$ e isola o coeficiente de índice i , de modo que sobra

$$\dot{a}_i(t) = -\alpha \left(\frac{i\pi}{L}\right)^2 a_i(t).$$

Portanto,

$$\dot{a}_i = -\alpha \left(\frac{i\pi}{L}\right)^2 a_i, \quad i = 1, \dots, r.$$

Cada modo decai exponencialmente:

$$a_i(t) = a_i(0) \exp\left[-\alpha \left(\frac{i\pi}{L}\right)^2 t\right].$$

Esse exemplo mostra um caso em que a base modal está perfeitamente alinhada ao operador da equação. Os modos não se misturam: cada coeficiente evolui independentemente. Em problemas mais complexos, especialmente com não linearidade, essa separação perfeita raramente acontece.

9. O que muda quando a equação é não linear

Considere agora uma dinâmica da forma

$$\frac{d}{dt}\mathbf{u} = A\mathbf{u} + \mathbf{N}(\mathbf{u}),$$

onde $A \in \mathbb{R}^{n \times n}$ é a parte linear, o mesmo papel que A desempenhou na Seção 6, e $\mathbf{N}$ é a parte não linear. Usando $\mathbf{u} \approx \Phi\mathbf{a}$, o ROM Galerkin fica

$$\dot{\mathbf{a}} = \Phi^T A \Phi \mathbf{a} + \Phi^T \mathbf{N}(\Phi \mathbf{a}).$$

Reconhecemos no primeiro termo o mesmo operador reduzido da Seção 6,

$$A_r = \Phi^T A \Phi \in \mathbb{R}^{r \times r},$$

e obtemos

$$\dot{\mathbf{a}} = A_r \mathbf{a} + \Phi^T \mathbf{N}(\Phi \mathbf{a}).$$

A parte linear fica realmente reduzida. O termo não linear, entretanto, pode continuar exigindo a reconstrução de $\Phi\mathbf{a} \in \mathbb{R}^n$, a avaliação de $\mathbf{N}$ em n pontos e, só depois, a projeção por Φ^T . Assim, embora o estado reduzido tenha dimensão r , o custo de avaliar a não linearidade pode continuar dependente de n .

Esse é um dos pontos mais importantes para não romantizar ROMs. Reduzir a dimensão do estado não significa automaticamente reduzir todo o custo computacional. Em problemas não lineares, frequentemente é necessário usar estratégias adicionais para aproximar ou amostrar a não linearidade de forma eficiente. Métodos como EIM e DEIM foram desenvolvidos justamente para esse gargalo; o gappy POD, criado originalmente para reconstruir dados incompletos, também foi adaptado a ele. Nesta aula, eles aparecem apenas como horizonte conceitual: a mensagem principal é que ROMs lineares são mais diretos, enquanto ROMs não lineares exigem cuidado adicional.

Exemplo 3: não linearidade cúbica

Considere uma não linearidade componente a componente

$$\mathbf{N}(\mathbf{u}) = \mathbf{u}^{\circ 3},$$

onde

$$\mathbf{u}^{\circ 3} = \begin{bmatrix} u_1^3 \\ u_2^3 \\ \vdots \\ u_n^3 \end{bmatrix}.$$

O ROM escreve

$$\mathbf{u} \approx \Phi \mathbf{a}.$$

Logo,

$$\mathbf{N}(\Phi \mathbf{a}) = (\Phi \mathbf{a})^{\circ 3}.$$

Mesmo que $\mathbf{a} \in \mathbb{R}^r$, o vetor $\Phi \mathbf{a}$ tem dimensão n . Portanto, calcular $(\Phi \mathbf{a})^{\circ 3}$ explicitamente ainda envolve n avaliações. O termo reduzido é

$$\Phi^T (\Phi \mathbf{a})^{\circ 3},$$

mas o caminho para obtê-lo pode passar pelo espaço completo.

Em algumas não linearidades polinomiais e em algumas estruturas específicas, é possível pré-computar tensores reduzidos. Por exemplo, em uma não linearidade quadrática, podem aparecer coeficientes do tipo

$$C_{ijk} = \langle \phi_i, \phi_j \phi_k \rangle,$$

calculados uma vez antes da simulação reduzida. Vale ser preciso quanto ao caso deste exemplo: a cúbica componente a componente também admite pré-computação, com um tensor de quatro índices $T_{ijkl} = \sum_p \Phi_{pi} \Phi_{pj} \Phi_{pk} \Phi_{pl}$ e custo online $O(r^4)$, independente de n . O gargalo genuíno, aquele que motivou EIM e DEIM, aparece nas não linearidades *não polinomiais*, como e^u , $1/u$ ou tabelas de propriedades, e nos polinômios de grau alto, para os quais o número de coeficientes cresce rápido demais, sem falar nos problemas parametrizados, em que os tensores teriam de ser recalculados a cada novo parâmetro.

10. POD não é automaticamente ROM

A POD fornece uma base espacial. O ROM fornece uma dinâmica para os coeficientes temporais. Essa distinção é fundamental.

A POD responde à pergunta:

quais modos aproximam melhor os snapshots observados?

O ROM responde à pergunta:

como os coeficientes desses modos evoluem no tempo?

Portanto, uma base POD pode ser excelente para reconstruir dados já observados e, ainda assim,

não gerar um bom modelo preditivo quando usada em uma projeção dinâmica. Há várias razões para isso.

Primeiro, a POD é otimizada para erro de reconstrução, não para estabilidade dinâmica. Segundo, os snapshots usados para construir a base podem cobrir apenas parte do comportamento possível. Terceiro, a truncagem pode remover modos de baixa energia que são dinamicamente importantes. Quarto, em sistemas não lineares, a interação entre modos retidos e modos descartados pode afetar a evolução futura.

Em linguagem simples: energia pequena não significa sempre importância dinâmica pequena. Um modo pode ter baixa energia média e ainda assim influenciar a estabilidade, a transição, a transferência de energia ou a resposta a perturbações.

Essa observação é especialmente relevante em mecânica dos fluidos. Escoamentos podem ter estruturas coerentes dominantes, mas também podem possuir mecanismos de instabilidade, cascata, acoplamento modal e sensibilidade a parâmetros. Um ROM útil precisa equilibrar compactação, fidelidade física e estabilidade temporal.

11. Relação entre SVD, PCA, POD e ROM

O Módulo 1 construiu uma sequência de ideias. A tabela abaixo organiza os conceitos principais.

Ferramenta	Objeto principal	Interpretação
SVD	Matriz qualquer X	Decomposição em direções ortogonais ponderadas por valores singulares.
SVD truncada	Aproximação X_r	Melhor aproximação de posto r nas normas de Frobenius e espectral (Eckart–Young).
PCA	Dados centrados	Direções de máxima variância; redução de dimensão estatística.
POD	Snapshots de campos	Modos espaciais dominantes e coeficientes temporais em sistemas espaço-temporais.
ROM	Dinâmica reduzida	Equações para os coeficientes temporais em um subespaço de baixa dimensão.

A passagem de SVD para PCA e POD é uma mudança de interpretação dos fatores. A passagem de POD para ROM é uma mudança de natureza: saímos de uma decomposição de dados e entramos em uma aproximação de dinâmica.

Essa passagem pode ser resumida assim:

dados de alta dimensão $\xrightarrow{\text{SVD/POD}}$ modos dominantes $\xrightarrow{\text{projecção}}$ dinâmica reduzida.

12. Exemplo 4: truncagem por coordenadas e ROM linear

Considere um sistema linear simples em $\mathbb{R}^3$:

$$\frac{d}{dt}\mathbf{u} = A\mathbf{u}, \quad A = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & -8 \end{bmatrix}.$$

Suponha que os snapshots revelem que a terceira coordenada decai muito rapidamente, enquanto as duas primeiras dominam a evolução observada após um curto tempo. Uma base reduzida didaticamente conveniente, escolhida para deixar a conta transparente, e não a base POD desses snapshots, que misturaria as três coordenadas, é

$$\Phi = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

Então

$$A_r = \Phi^T A \Phi = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & -8 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} -1 & 0 \\ 0 & -2 \end{bmatrix}.$$

O ROM é

$$\dot{a}_1 = -a_1, \quad \dot{a}_2 = -2a_2.$$

A terceira coordenada foi descartada. Se o estado inicial tiver componente relevante na terceira direção, o ROM errará no início. Mas, como essa direção decai com taxa -8 , a contribuição desaparece rapidamente. Em muitos problemas dissipativos, essa é a razão pela qual ROMs funcionam bem: modos associados a escalas rápidas ou pequenas podem ter pouca influência na dinâmica de longo prazo.

Esse raciocínio não é uma regra universal. Em um sistema instável, ou em um sistema no qual modos descartados alimentam os modos retidos, a truncagem pode gerar erro importante. O ROM deve ser validado contra dados ou simulações de referência.

13. O papel da validação

Um ROM só é útil se for testado. A validação deve comparar a solução reduzida com uma referência: simulação de alta fidelidade, solução analítica, experimento ou conjunto de snapshots não usados na construção da base.

Algumas métricas comuns são:

$$\varepsilon(t) = \frac{\|\mathbf{u}(t) - \mathbf{u}_r(t)\|_2}{\|\mathbf{u}(t)\|_2},$$

para erro relativo instantâneo, e

$$\varepsilon_F = \frac{\|X - X_r\|_F}{\|X\|_F},$$

para erro global em uma matriz de snapshots, em que X_r reúne, coluna a coluna, os estados aproximados: na validação de um ROM, as soluções $\mathbf{u}_r(t_k)$ do modelo; na leitura de compressão, a truncagem SVD.

Três observações de notação e uso. Primeiro, aqui $\mathbf{u}_r(t) = \Phi \mathbf{a}(t)$ denota a solução do ROM, não a projeção $\Phi \Phi^T \mathbf{u}(t)$ do estado verdadeiro, da Seção 4; em geral, o erro do ROM pode superar o erro de projeção. Segundo, grafamos o erro com ε porque, nas Aulas 5 e 7, E denotava fração de *energia*; as duas quantidades se conectam: quando X_r vem da truncagem SVD, vale $\varepsilon_F^2 = 1 - \eta_r$, onde η_r é a fração de energia retida pelos r primeiros modos, a mesma quantidade que a Aula 5 chamou E_k e a Aula 7, $E_{\text{acum}}(r)$, a fração de energia descartada é o erro relativo *ao quadrado*, como estabelecido na Aula 5. Terceiro, uma cautela prática: o quociente $\varepsilon(t)$ fica mal condicionado quando $\|\mathbf{u}(t)\|_2 \rightarrow 0$, regime comum em sistemas que decaem; nesses casos, usa-se o erro absoluto ou normaliza-se por $\max_t \|\mathbf{u}(t)\|_2$.

Também é importante comparar grandezas físicas. Em escoamentos, isso pode incluir energia cinética, frequência de desprendimento de vórtices, força de arrasto, força de sustentação, pressão média, vazão ou perfis de velocidade. Um ROM pode ter erro pequeno em norma global e ainda falhar em uma grandeza física relevante. Da mesma forma, pode ter erro moderado em norma global e ainda capturar bem a quantidade de interesse.

A validação deve respeitar a finalidade do modelo. Um ROM para compressão de dados pode ser julgado por erro de reconstrução. Um ROM para previsão precisa ser julgado por sua capacidade de avançar no tempo. Um ROM para controle precisa ser julgado pela resposta a entradas e perturbações.

14. Consolidação do Módulo 1

O primeiro módulo do curso teve uma função estrutural: construir a linguagem mínima para que os métodos posteriores não pareçam uma coleção de receitas computacionais. Abaixo está a síntese conceitual que deve permanecer.

A multiplicação $A\mathbf{x}$ pode ser vista como combinação das colunas de A . Essa visão explica espaço coluna, posto, solução de sistemas lineares, regressão e aproximações em subespaços. A transposta permite formar produtos internos matriciais e aparece em projeções, equações normais, covariância e matrizes como $A^T A$.

Autovalores e autovetores descrevem direções preservadas por matrizes quadradas. Matrizes simétricas possuem uma estrutura especialmente favorável: admitem uma base ortonormal

de autovetores e decomposição espectral. É dessa estrutura que vem a leitura geométrica da SVD, com estiramentos organizados ao longo de direções ortogonais. Já a não negatividade dos autovalores de $A^T A$ vem de outra propriedade, a semidefinição positiva, $\mathbf{v}^T A^T A \mathbf{v} = \|A\mathbf{v}\|^2 \geq 0$, e não da simetria, como destacamos na Aula 6.

A SVD generaliza a decomposição espectral para matrizes retangulares. Ela escreve

$$X = U\Sigma V^T,$$

separando direções de entrada (V), valores de estiramento (Σ) e direções de saída (U). A SVD truncada

$$X_r = U_r \Sigma_r V_r^T$$

fornece uma aproximação de posto baixo, com erro controlado pelos valores singulares descartados.

A PCA aplica essa estrutura a dados centrados. Suas direções principais são direções de máxima variância. A POD aplica a mesma estrutura a snapshots de campos físicos. Seus modos são padrões espaciais dominantes, e seus coeficientes temporais descrevem como esses padrões aparecem ao longo do tempo.

O ROM usa esses modos como base para aproximar a dinâmica. Se $\mathbf{u} \approx \Phi \mathbf{a}$, a questão passa a ser determinar $\dot{\mathbf{a}}$. A projeção Galerkin–POD fornece uma forma sistemática de obter equações reduzidas:

$$\dot{\mathbf{a}} = \Phi^T \mathbf{F}(\Phi \mathbf{a}).$$

Essa fórmula fecha o ciclo do Módulo 1: começamos com vetores e matrizes e chegamos à ideia de projetar a física em um subespaço de baixa dimensão.

15. Síntese da aula

Um modelo de ordem reduzida é uma aproximação dinâmica construída em um subespaço de baixa dimensão. A POD fornece uma escolha orientada por dados para esse subespaço. A projeção de Galerkin fornece um modo de converter a equação original em equações para os coeficientes reduzidos.

A fórmula

$$\mathbf{u}(t) \approx \Phi \mathbf{a}(t)$$

reduz a representação do estado. A fórmula

$$\dot{\mathbf{a}} = \Phi^T \mathbf{F}(\Phi \mathbf{a})$$

reduz a dinâmica. A primeira é uma aproximação geométrica; a segunda é uma aproximação evolutiva. Confundir essas duas etapas é um erro comum.

ROMs são atraentes porque podem acelerar simulações, permitir estudos paramétricos,

apoiar controle em tempo real e fornecer modelos interpretáveis. Mas eles dependem de uma base representativa, de uma truncagem adequada, de uma projeção bem formulada e de validação cuidadosa. Em sistemas não lineares, o custo de avaliar a não linearidade pode continuar alto, exigindo métodos adicionais.

16. Exercícios propostos

Exercício 1. Considere

$$\phi_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \phi_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \quad \Phi = [\phi_1 \quad \phi_2].$$

Para

$$\mathbf{u} = \begin{bmatrix} 5 \\ 1 \\ 2 \end{bmatrix},$$

calcule $\mathbf{a} = \Phi^T \mathbf{u}$, a reconstrução projetada $\mathbf{u}_r = \Phi \mathbf{a}$ e o erro $\mathbf{e} = \mathbf{u} - \mathbf{u}_r$. Verifique que $\Phi^T \mathbf{e} = \mathbf{0}$.

Exercício 2. Considere

$$A = \begin{bmatrix} -2 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & -6 \end{bmatrix}$$

e

$$\Phi = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

Calcule o operador reduzido $A_r = \Phi^T A \Phi$ e escreva o sistema reduzido $\dot{\mathbf{a}} = A_r \mathbf{a}$.

Exercício 3. Considere novamente a matriz do Exercício 2, mas agora use

$$\Phi = \begin{bmatrix} 1/\sqrt{2} & 0 \\ 1/\sqrt{2} & 0 \\ 0 & 1 \end{bmatrix}.$$

Calcule A_r . Interprete fisicamente ou geometricamente por que o primeiro coeficiente reduzido possui uma taxa efetiva que combina as duas primeiras taxas do sistema original.

Exercício 4. Considere a equação do calor

$$\frac{\partial u}{\partial t} = \alpha \frac{\partial^2 u}{\partial x^2}, \quad 0 < x < L, \quad \alpha > 0,$$

com $u(0, t) = u(L, t) = 0$. Usando os modos

$$\phi_j(x) = \sqrt{\frac{2}{L}} \sin\left(\frac{j\pi x}{L}\right),$$

mostre que a projeção Galerkin conduz a

$$\dot{a}_j = -\alpha \left(\frac{j\pi}{L}\right)^2 a_j.$$

Exercício 5. Explique, em um parágrafo, a diferença entre POD e ROM. Use obrigatoriamente as palavras: *snapshots*, *modos*, *coeficientes temporais* e *dinâmica*.

Exercício 6. Suponha que a SVD de uma matriz de snapshots centrados tenha valores singulares

$$\sigma_1 = 10, \quad \sigma_2 = 4, \quad \sigma_3 = 1, \quad \sigma_4 = 0.5.$$

Calcule a fração de energia preservada com $r = 1$, $r = 2$ e $r = 3$, usando

$$\eta_r = \frac{\sum_{j=1}^r \sigma_j^2}{\sum_{j=1}^4 \sigma_j^2}.$$

Discuta qual truncagem parece razoável, dependendo de o objetivo ser compressão de dados ou construção de um ROM.

Exercício 7. Considere a dinâmica não linear

$$\dot{\mathbf{u}} = A\mathbf{u} + \mathbf{u}^{\circ 3}.$$

Escreva a forma Galerkin-POD para $\mathbf{u} \approx \Phi \mathbf{a}$. Explique por que a avaliação direta do termo não linear continua dependente da dimensão original n , mesmo que $\mathbf{a} \in \mathbb{R}^r$, e indique, com base no Exemplo 3, que estrutura permitiria contornar essa dependência neste caso particular.

Exercício 8. Escreva uma síntese do Módulo 1 conectando, em uma sequência lógica, os seguintes termos: matriz, posto, autovalores, SVD, SVD truncada, PCA, POD e ROM. O texto deve ter entre 10 e 15 linhas.

17. Referências

- BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2. ed. Cambridge University Press, 2022.