

Aula 9: Regressão Linear e Mínimos Quadrados

Formulação matricial, interpretação geométrica, equações normais, pseudoinversa e ajuste polinomial

Prof. Dr. Rodrigo Figueiredo Abdo

1. Ideia central da aula

O segundo módulo do curso começa com regressão porque quase todas as técnicas que aparecerão depois podem ser lidas, em alguma escala, como problemas de ajuste. Em DMD, ajustamos um operador que avança snapshots no tempo. Em SINDy, ajustamos poucos termos de uma biblioteca de funções candidatas. Em PINNs, ajustamos os pesos de uma rede neural para reduzir simultaneamente erro de dados, erro de equação diferencial e erro de contorno. Em todos esses casos existe uma ideia comum: escolhemos uma classe de modelos e procuramos os parâmetros que tornam esse modelo compatível com dados, equações ou medições.

A regressão linear é o caso mais simples e mais instrutivo dessa ideia. O adjetivo “linear” não significa que a curva ajustada precisa ser uma reta em relação à variável física. Ele significa que o modelo é linear em relação aos parâmetros desconhecidos. Por isso, um ajuste polinomial como

$$y \approx \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

continua sendo uma regressão linear nos parâmetros $\beta_0, \beta_1, \beta_2, \beta_3$, embora a função seja não linear em x .

O objetivo da aula é entender, com precisão, o problema

$$A\beta \approx \mathbf{b},$$

quando o sistema possui mais equações do que incógnitas e, portanto, em geral não possui solução exata. A solução de mínimos quadrados será interpretada de três formas equivalentes: como minimização de erro, como projeção ortogonal e como solução algébrica obtida por equações normais ou por pseudoinversa via SVD.

2. De dados para um sistema matricial

Considere um conjunto de m medições

$$(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m).$$

Queremos ajustar uma função simples aos dados. Se a hipótese for uma reta,

$$y \approx \beta_0 + \beta_1 x,$$

então cada ponto medido fornece uma equação aproximada:

$$\begin{aligned}\beta_0 + \beta_1 x_1 &\approx y_1, \\ \beta_0 + \beta_1 x_2 &\approx y_2, \\ &\vdots \\ \beta_0 + \beta_1 x_m &\approx y_m.\end{aligned}$$

Em forma matricial,

$$\underbrace{\begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_m \end{bmatrix}}_A \underbrace{\begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}}_{\boldsymbol{\beta}} \approx \underbrace{\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}}_{\mathbf{b}}.$$

A matriz A recebe o nome de matriz de projeto, matriz de desenho ou matriz de regressão. Suas colunas representam as funções usadas no modelo. Para a reta, as colunas são

$$1, \quad x.$$

Para um polinômio de grau d , as colunas serão

$$1, \quad x, \quad x^2, \quad \dots, \quad x^d.$$

Assim, a regressão linear pode ser entendida como uma pergunta sobre combinações lineares de colunas: é possível combinar as colunas de A para produzir exatamente o vetor de dados $\mathbf{b}$?

Se $\mathbf{b} \in \text{Col}(A)$, existe uma solução exata. Se $\mathbf{b} \notin \text{Col}(A)$, não existe solução exata, e o problema passa a ser encontrar o vetor $A\boldsymbol{\beta}$ que fique o mais próximo possível de $\mathbf{b}$.

3. O problema de mínimos quadrados

O erro de ajuste associado a um vetor de parâmetros $\boldsymbol{\beta}$ é

$$\mathbf{e} = \mathbf{b} - A\boldsymbol{\beta}.$$

O método de mínimos quadrados escolhe $\boldsymbol{\beta}$ de modo a minimizar a soma dos quadrados dos resíduos:

$$\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta} \in \mathbb{R}^n} \|A\boldsymbol{\beta} - \mathbf{b}\|_2^2.$$

Como

$$\|A\boldsymbol{\beta} - \mathbf{b}\|_2^2 = \sum_{i=1}^m ((A\boldsymbol{\beta})_i - b_i)^2,$$

o método penaliza fortemente erros grandes. Isso torna o ajuste ℓ_2 eficiente e matematicamente tratável, mas também explica sua sensibilidade a outliers. Um ponto muito distante da tendência geral pode influenciar bastante o resultado, justamente porque o erro aparece ao quadrado. Critérios alternativos, como a norma ℓ_1 (mais robusta a outliers) e a norma ℓ_∞ (que controla o maior desvio), existem e levam a outros problemas de otimização, mas a norma ℓ_2 é a que admite a solução fechada estudada nesta aula.

A escolha do erro quadrático não é apenas uma conveniência computacional. Ela tem interpretação geométrica limpa, leva a um problema convexo e fornece uma solução fechada quando A tem posto coluna completo. Por esse motivo, mínimos quadrados aparece repetidamente em ciência de dados, métodos numéricos e aprendizado de máquina científico.

4. Interpretação geométrica: projetar $\mathbf{b}$ no espaço coluna de A

O vetor $A\boldsymbol{\beta}$ sempre pertence ao espaço coluna de A , pois é uma combinação linear de suas colunas. Portanto, ao variar $\boldsymbol{\beta}$, não percorremos todo o $\mathbb{R}^m$, mas apenas o subespaço

$$\text{Col}(A) = \{A\boldsymbol{\beta} : \boldsymbol{\beta} \in \mathbb{R}^n\}.$$

Quando $\mathbf{b} \notin \text{Col}(A)$, não conseguimos acertar $\mathbf{b}$ exatamente. O melhor que podemos fazer é encontrar o vetor

$$\mathbf{p} = A\hat{\boldsymbol{\beta}}$$

que pertence a $\text{Col}(A)$ e está mais próximo de $\mathbf{b}$. Esse vetor $\mathbf{p}$ é a projeção ortogonal de $\mathbf{b}$ sobre $\text{Col}(A)$.

A condição geométrica central é

$$\mathbf{e} = \mathbf{b} - \mathbf{p} \perp \text{Col}(A).$$

Como as colunas de A geram $\text{Col}(A)$, dizer que $\mathbf{e}$ é ortogonal a $\text{Col}(A)$ equivale a dizer que $\mathbf{e}$ é ortogonal a cada coluna de A . Em forma matricial,

$$A^T \mathbf{e} = \mathbf{0}.$$

Substituindo $\mathbf{e} = \mathbf{b} - A\hat{\boldsymbol{\beta}}$, obtemos

$$A^T(\mathbf{b} - A\hat{\boldsymbol{\beta}}) = \mathbf{0}.$$

Logo,

$$A^T A \hat{\boldsymbol{\beta}} = A^T \mathbf{b}.$$

Essas são as equações normais.

A palavra “normal” aqui não é acidental. Ela indica que o erro residual é normal, isto é, perpendicular, ao espaço de aproximação. O ajuste de mínimos quadrados não torna o erro nulo; ele torna o erro invisível para todas as direções que o modelo consegue representar.

5. Dedução algébrica das equações normais

A mesma condição pode ser obtida por cálculo. Defina a função objetivo

$$J(\beta) = \|A\beta - \mathbf{b}\|_2^2.$$

Expandindo,

$$\begin{aligned} J(\beta) &= (A\beta - \mathbf{b})^T (A\beta - \mathbf{b}) \\ &= \beta^T A^T A \beta - 2\beta^T A^T \mathbf{b} + \mathbf{b}^T \mathbf{b}. \end{aligned}$$

Tomando o gradiente em relação a β , obtemos

$$\nabla_{\beta} J = 2A^T A \beta - 2A^T \mathbf{b}.$$

No ponto de mínimo,

$$\nabla_{\beta} J = \mathbf{0}.$$

Portanto,

$$A^T A \hat{\beta} = A^T \mathbf{b}.$$

A dedução por gradiente e a dedução geométrica chegam à mesma condição. A primeira mostra que estamos minimizando uma função quadrática. A segunda mostra o que essa minimização faz no espaço: ela projeta $\mathbf{b}$ em $\text{Col}(A)$.

6. Quando as equações normais têm solução única

As equações normais são

$$A^T A \hat{\beta} = A^T \mathbf{b}.$$

Se as colunas de A são linearmente independentes, então $A^T A$ é invertível. Nesse caso,

$$\hat{\beta} = (A^T A)^{-1} A^T \mathbf{b}.$$

A hipótese importante é

$$\text{rank}(A) = n,$$

ou seja, A tem posto coluna completo. Isso significa que nenhuma coluna de A pode ser escrita como combinação linear das outras. Em termos de regressão, significa que não há redundância perfeita entre as funções usadas no modelo.

Se $A^T A$ é invertível, a projeção de $\mathbf{b}$ sobre $\text{Col}(A)$ é

$$\mathbf{p} = A\hat{\boldsymbol{\beta}} = A(A^T A)^{-1} A^T \mathbf{b}.$$

Assim, a matriz

$$P_A = A(A^T A)^{-1} A^T$$

é a matriz de projeção ortogonal sobre $\text{Col}(A)$. Ela satisfaz duas propriedades fundamentais:

$$P_A^2 = P_A, \quad P_A^T = P_A.$$

A primeira propriedade diz que projetar duas vezes é o mesmo que projetar uma vez. A segunda diz que a projeção é ortogonal.

Exemplo 1: ajuste de uma reta por mínimos quadrados

Considere os quatro pontos

$$(0, 1), \quad (1, 2), \quad (2, 2), \quad (3, 4).$$

Queremos ajustar uma reta

$$y \approx \beta_0 + \beta_1 x.$$

A matriz de projeto e o vetor de dados são

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 2 \\ 4 \end{bmatrix}.$$

Calculamos

$$A^T A = \begin{bmatrix} 4 & 6 \\ 6 & 14 \end{bmatrix}, \quad A^T \mathbf{b} = \begin{bmatrix} 9 \\ 18 \end{bmatrix}.$$

As equações normais ficam

$$\begin{bmatrix} 4 & 6 \\ 6 & 14 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} = \begin{bmatrix} 9 \\ 18 \end{bmatrix}.$$

Resolvendo,

$$\hat{\boldsymbol{\beta}} = \begin{bmatrix} 9/10 \\ 9/10 \end{bmatrix}.$$

Logo, a reta de mínimos quadrados é

$$\hat{y} = \frac{9}{10} + \frac{9}{10}x.$$

Os valores ajustados são

$$A\hat{\boldsymbol{\beta}} = \begin{bmatrix} 9/10 \\ 9/5 \\ 27/10 \\ 18/5 \end{bmatrix},$$

e o resíduo é

$$\mathbf{e} = \mathbf{b} - A\hat{\boldsymbol{\beta}} = \begin{bmatrix} 1/10 \\ 1/5 \\ -7/10 \\ 2/5 \end{bmatrix}.$$

A condição de mínimos quadrados exige

$$A^T \mathbf{e} = \mathbf{0}.$$

De fato,

$$A^T \mathbf{e} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1/10 \\ 1/5 \\ -7/10 \\ 2/5 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Essa verificação é mais importante do que parece. Ela mostra que o erro restante não possui componente na direção das colunas de A . Portanto, nenhuma alteração em β_0 ou β_1 consegue reduzir mais o erro quadrático.

7. Ajuste polinomial como regressão linear

Agora considere um modelo polinomial de grau d :

$$y \approx \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_d x^d.$$

Embora o modelo seja não linear em x , ele continua linear nos coeficientes β_j . Para os pontos (x_i, y_i) , a matriz de projeto é

$$A = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^d \\ 1 & x_2 & x_2^2 & \cdots & x_2^d \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_m & x_m^2 & \cdots & x_m^d \end{bmatrix}.$$

Essa é uma matriz de Vandermonde. O vetor de parâmetros é

$$\boldsymbol{\beta} = [\beta_0 \quad \beta_1 \quad \cdots \quad \beta_d]^T.$$

O problema continua sendo

$$\hat{\beta} = \arg \min_{\beta} \|A\beta - \mathbf{b}\|_2^2.$$

O ajuste polinomial é, portanto, uma aplicação direta de mínimos quadrados. A escolha do grau d altera o subespaço de aproximação. Quanto maior d , maior o número de colunas de A e maior a capacidade de ajuste. Mas maior capacidade não significa melhor modelo. Um polinômio de grau alto pode reproduzir ruído, oscilar entre pontos e extrapolar mal.

Exemplo 2: ajuste quadrático aos mesmos dados

Usando novamente os pontos

$$(0, 1), \quad (1, 2), \quad (2, 2), \quad (3, 4),$$

agora ajustamos

$$y \approx \beta_0 + \beta_1 x + \beta_2 x^2.$$

A matriz de projeto é

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 2 \\ 4 \end{bmatrix}.$$

Calculamos

$$A^T A = \begin{bmatrix} 4 & 6 & 14 \\ 6 & 14 & 36 \\ 14 & 36 & 98 \end{bmatrix}, \quad A^T \mathbf{b} = \begin{bmatrix} 9 \\ 18 \\ 46 \end{bmatrix}.$$

A solução de mínimos quadrados é

$$\hat{\beta} = \begin{bmatrix} 23/20 \\ 3/20 \\ 1/4 \end{bmatrix}.$$

Logo,

$$\hat{y} = \frac{23}{20} + \frac{3}{20}x + \frac{1}{4}x^2.$$

Os valores ajustados são

$$A\hat{\beta} = \begin{bmatrix} 23/20 \\ 31/20 \\ 49/20 \\ 77/20 \end{bmatrix},$$

e o resíduo é

$$\mathbf{e} = \begin{bmatrix} -3/20 \\ 9/20 \\ -9/20 \\ 3/20 \end{bmatrix}.$$

Como antes,

$$A^T \mathbf{e} = \mathbf{0}.$$

A diferença é que agora o espaço coluna de A é maior. Em vez de aproximar $\mathbf{b}$ por combinações de 1 e x , aproximamos $\mathbf{b}$ por combinações de 1, x e x^2 . Geometricamente, mudamos o subespaço no qual projetamos o vetor de dados.

8. Pseudoinversa e solução via SVD

As equações normais são conceitualmente importantes, mas nem sempre são a melhor forma numérica de resolver o problema. A SVD oferece uma maneira mais estável e mais geral de obter a solução de mínimos quadrados.

Considere a SVD reduzida de uma matriz $A \in \mathbb{R}^{m \times n}$ (Aula 4), que retém apenas os $r = \text{rank}(A)$ valores singulares positivos:

$$A = U \Sigma V^T,$$

em que as colunas de U e V são ortonormais e

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r), \quad \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0.$$

A pseudoinversa de Moore–Penrose é

$$A^+ = V \Sigma^+ U^T,$$

onde

$$\Sigma^+ = \text{diag}\left(\frac{1}{\sigma_1}, \frac{1}{\sigma_2}, \dots, \frac{1}{\sigma_r}\right).$$

A solução de mínimos quadrados pode ser escrita como

$$\hat{\boldsymbol{\beta}} = A^+ \mathbf{b}.$$

Se A tem posto coluna completo, essa expressão coincide com

$$\hat{\boldsymbol{\beta}} = (A^T A)^{-1} A^T \mathbf{b} \quad (\text{posto coluna completo}).$$

A vantagem da pseudoinversa é que ela também trata matrizes retangulares, singulares ou mal condicionadas de forma mais clara. Ela revela quais direções são bem determinadas e quais direções são perigosas. Além disso, quando o problema é subdeterminado ou A tem posto deficiente, há infinitas soluções de mínimos quadrados, e $A^+ \mathbf{b}$ seleciona aquela de *norma mínima* $\|\boldsymbol{\beta}\|_2$.

Para ver isso, escreva

$$\hat{\boldsymbol{\beta}} = V \Sigma^+ U^T \mathbf{b}.$$

Primeiro, $U^T \mathbf{b}$ projeta os dados nas direções de saída associadas a A . Depois, Σ^+ divide cada componente por seu valor singular. Por fim, V reconstrói a solução no espaço dos parâmetros. Se algum σ_j é muito pequeno, a divisão por σ_j amplifica ruído naquela direção.

Esse é um ponto central para aprendizado de máquina científico: problemas inversos e ajustes de modelos podem falhar não porque o algoritmo está errado, mas porque certas direções dos parâmetros são pouco observáveis nos dados. A SVD mostra isso de forma direta.

9. Por que não confiar cegamente nas equações normais

As equações normais envolvem a matriz $A^T A$. Se A é mal condicionada, $A^T A$ é ainda pior. Na norma 2,

$$\kappa_2(A^T A) = \kappa_2(A)^2,$$

onde κ_2 é o número de condição na norma 2, que definimos a partir dos valores singulares (vistos na Aula 4) como $\kappa_2(A) = \sigma_{\max}/\sigma_{\min}$, a razão entre o maior e o menor valor singular de A . A identidade fica então transparente: como os valores singulares de $A^T A$ são os σ_i^2 , temos $\kappa_2(A^T A) = \sigma_{\max}^2/\sigma_{\min}^2 = \kappa_2(A)^2$. Portanto, se A tem número de condição 10^4 , então $A^T A$ tem número de condição 10^8 .

Isso importa porque erros de arredondamento, ruído experimental e pequenas perturbações nos dados podem ser amplificados na solução. Em problemas bem comportados e pequenos, resolver as equações normais pode funcionar. Em problemas mal condicionados, grandes ou ruidosos, a solução via SVD ou via fatoração QR é mais segura.

O mal condicionamento aparece com frequência em ajuste polinomial. A matriz de Vandermonde pode ter colunas quase dependentes, principalmente quando o grau do polinômio é alto ou quando os valores de x não são escalonados. Por isso, em aplicações computacionais, é comum centralizar e normalizar os dados antes do ajuste.

10. Ajuste linear geral em funções de base

O que fizemos para polinômios vale para qualquer conjunto de funções de base. Suponha que queremos aproximar

$$y \approx \beta_1 \varphi_1(x) + \beta_2 \varphi_2(x) + \cdots + \beta_n \varphi_n(x).$$

A matriz de projeto passa a ser

$$A = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \cdots & \varphi_n(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \cdots & \varphi_n(x_2) \\ \vdots & \vdots & & \vdots \\ \varphi_1(x_m) & \varphi_2(x_m) & \cdots & \varphi_n(x_m) \end{bmatrix}.$$

O modelo é linear nos parâmetros mesmo que as funções φ_j sejam não lineares em x . Por exemplo,

$$\varphi_1(x) = 1, \quad \varphi_2(x) = x, \quad \varphi_3(x) = \sin x, \quad \varphi_4(x) = e^{-x}$$

geram um modelo linear nos coeficientes:

$$y \approx \beta_1 + \beta_2 x + \beta_3 \sin x + \beta_4 e^{-x}.$$

Isso permite interpretar regressão linear como projeção de dados sobre um espaço gerado por funções escolhidas. O que muda de um problema para outro é a escolha das colunas de A , isto é, a escolha das funções de base.

Essa ideia será essencial quando estudarmos SINDy. Lá, construímos uma biblioteca de funções candidatas e buscamos uma combinação pequena delas capaz de representar a dinâmica observada.

11. Regressão, modelos físicos e aprendizado de máquina científico

Em mecânica dos fluidos e transferência de calor, modelos frequentemente aparecem com parâmetros desconhecidos. Por exemplo, uma lei empírica pode relacionar uma grandeza observada y a variáveis medidas $x_1, x_2, \dots, x_p$. Se o modelo é linear nos parâmetros,

$$y \approx \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p,$$

então cada experimento fornece uma linha da matriz A . A regressão encontra os coeficientes que melhor explicam os dados no sentido ℓ_2 .

Em problemas de dinâmica, podemos ajustar relações entre estados sucessivos. Se $\mathbf{x}_{k+1} \approx K \mathbf{x}_k$, a matriz K pode ser encontrada por mínimos quadrados a partir de snapshots. Esse princípio está por trás da ideia de ajustar operadores de evolução, que aparecerá com mais força em DMD.

Em PINNs, a situação é mais geral: os parâmetros são pesos de uma rede neural, e a função objetivo não é mais quadrática simples nos parâmetros. Mesmo assim, a estrutura conceitual permanece: definimos resíduos, medimos seu tamanho e ajustamos parâmetros para reduzi-los. A diferença é que, em regressão linear, conseguimos resolver o problema por álgebra linear; em redes neurais, precisamos de otimização iterativa.

12. Mínimos quadrados ponderados

Nem todas as medições precisam ter a mesma confiabilidade. Se algumas medições têm maior incerteza, pode ser inadequado tratá-las com o mesmo peso. Uma extensão natural é o problema

de mínimos quadrados ponderados:

$$\hat{\beta} = \arg \min_{\beta} \|W(A\beta - \mathbf{b})\|_2^2,$$

em que W é uma matriz de pesos. Se W é diagonal,

$$W = \text{diag}(w_1, w_2, \dots, w_m),$$

então cada resíduo é ponderado por um peso diferente. A função objetivo é

$$J(\beta) = \sum_{i=1}^m w_i^2 ((A\beta)_i - b_i)^2.$$

As equações normais ponderadas são

$$A^T W^T W A \hat{\beta} = A^T W^T W \mathbf{b}.$$

Esse caso aparece naturalmente quando dados possuem variâncias diferentes. Medições mais confiáveis recebem maior peso; medições menos confiáveis recebem menor peso.

13. O papel do resíduo

O resíduo

$$\mathbf{e} = \mathbf{b} - A\hat{\beta}$$

não deve ser visto apenas como “erro que sobrou”. Ele contém informação sobre a adequação do modelo. Se os resíduos têm padrão sistemático, isso sugere que o espaço de aproximação escolhido não captura alguma estrutura presente nos dados. Se os resíduos parecem ruído sem padrão, o modelo pode estar capturando a tendência dominante.

Em um ajuste polinomial, por exemplo, resíduos alternando de modo estruturado podem indicar que o grau escolhido é baixo demais. Resíduos muito pequenos nos dados de treino, mas instabilidade fora deles, podem indicar excesso de flexibilidade. Essa diferença entre capacidade de ajuste e capacidade de generalização será aprofundada quando estudarmos regularização.

Na linguagem geométrica, o resíduo ótimo é ortogonal ao espaço coluna de A . Portanto, se ainda há padrão no resíduo, esse padrão não está no subespaço escolhido. A conclusão não é necessariamente “calcule melhor”. Pode ser “escolha melhor as funções de base”.

14. Exemplo 3: ajuste de uma lei de potência por linearização

Nem todo modelo aparentemente não linear exige regressão não linear. Considere uma lei de potência

$$y = Cx^\alpha,$$

com $C > 0$ e $x > 0$. Tomando logaritmo,

$$\ln y = \ln C + \alpha \ln x.$$

Se definirmos

$$Y = \ln y, \quad X = \ln x, \quad \beta_0 = \ln C, \quad \beta_1 = \alpha,$$

então obtemos uma regressão linear:

$$Y \approx \beta_0 + \beta_1 X.$$

Após ajustar β_0 e β_1 , recuperamos

$$C = e^{\beta_0}, \quad \alpha = \beta_1.$$

Esse procedimento é comum em engenharia, mas exige cuidado. Ao aplicar logaritmo, mudamos a estrutura do erro. Minimizar erro quadrático em $\ln y$ não é o mesmo que minimizar erro quadrático em y ; de fato, o ajuste no espaço logarítmico equivale, aproximadamente, a um problema de mínimos quadrados ponderado em y , no qual pontos de menor magnitude recebem peso relativo maior. A linearização é útil quando o erro relativo é mais natural do que o erro absoluto, ou quando os dados variam em várias ordens de grandeza.

15. Síntese da aula

A regressão linear transforma um problema de ajuste em um problema matricial:

$$A\beta \approx \mathbf{b}.$$

Quando $\mathbf{b}$ não pertence ao espaço coluna de A , não existe solução exata. O método de mínimos quadrados escolhe

$$\hat{\beta} = \arg \min_{\beta} \|A\beta - \mathbf{b}\|_2^2.$$

Geometricamente, isso significa projetar $\mathbf{b}$ em $\text{Col}(A)$. O erro ótimo satisfaz

$$A^T(\mathbf{b} - A\hat{\beta}) = \mathbf{0},$$

e, por isso, a solução satisfaz as equações normais

$$A^T A \hat{\beta} = A^T \mathbf{b}.$$

Se A tem posto coluna completo,

$$\hat{\beta} = (A^T A)^{-1} A^T \mathbf{b}.$$

De forma mais geral e mais estável, usando a SVD,

$$\hat{\beta} = A^+ \mathbf{b}.$$

O ajuste polinomial é um caso particular de regressão linear, no qual a matriz A é formada por colunas $1, x, x^2, \dots, x^d$. O conteúdo essencial da aula é perceber que regressão, projeção, pseudoinversa e SVD não são assuntos separados: são formas diferentes de enxergar o mesmo problema de aproximação.

16. Exercícios propostos

1. Considere os pontos

$$(0, 1), \quad (1, 1), \quad (2, 3), \quad (3, 4).$$

Monte a matriz de projeto para ajustar uma reta $y \approx \beta_0 + \beta_1 x$. Calcule $A^T A$, $A^T \mathbf{b}$, resolva as equações normais e escreva a reta ajustada.

2. Para o exercício anterior, calcule o vetor de resíduos

$$\mathbf{e} = \mathbf{b} - A\hat{\beta}$$

e verifique explicitamente que

$$A^T \mathbf{e} = \mathbf{0}.$$

Explique o significado geométrico dessa igualdade.

3. Considere

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}.$$

Calcule a projeção $\mathbf{p} = A\hat{\beta}$ de $\mathbf{b}$ sobre $\text{Col}(A)$. Em seguida, calcule o resíduo $\mathbf{e} = \mathbf{b} - \mathbf{p}$.

4. Mostre que, se A tem posto coluna completo, então $A^T A$ é invertível. Sugestão: use

$$\mathbf{x}^T A^T A \mathbf{x} = \|A\mathbf{x}\|_2^2.$$

5. Prove que a matriz

$$P_A = A(A^T A)^{-1} A^T$$

satisfaz

$$P_A^2 = P_A \quad \text{e} \quad P_A^T = P_A,$$

supondo que A tenha posto coluna completo.

6. Monte a matriz de projeto para ajustar um polinômio quadrático

$$y \approx \beta_0 + \beta_1 x + \beta_2 x^2$$

aos pontos

$$(-1, 2), \quad (0, 1), \quad (1, 2), \quad (2, 6).$$

Resolva o problema de mínimos quadrados.

7. Explique por que o ajuste

$$y \approx \beta_0 + \beta_1 \sin x + \beta_2 e^{-x}$$

é uma regressão linear nos parâmetros, embora contenha funções não lineares de x .

8. Considere a lei

$$y = Ce^{\alpha x}.$$

Mostre como transformar o problema em uma regressão linear. Quais cuidados devem ser tomados ao interpretar o erro depois da transformação logarítmica?

9. Suponha que uma matriz A possua valores singulares

$$100, 10, 1, 10^{-3}.$$

Explique por que a pseudoinversa pode amplificar ruído. Qual componente da solução é mais sensível?

10. Em uma aplicação física, os resíduos de um ajuste apresentam padrão oscilatório claro. O que isso sugere sobre o modelo escolhido? A solução é necessariamente usar mais pontos experimentais? Justifique.

17. Referências

- BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2. ed. Cambridge University Press, 2022.
- STRANG, G. *Introduction to Linear Algebra*. 6. ed. Wellesley-Cambridge Press, 2023.