

NeuroFluidos

Aula 1

Panorama: IA e Mecânica dos Fluidos

Fundamentos de Aprendizado de Máquina Científico para Mecânica dos Fluidos




Prof. Dr. Rodrigo Figueiredo Abdo – IFB

O que vamos fazer hoje


Objetivo da aula

Construir um **mapa mental** do curso: de onde viemos, por que inteligência artificial entrou na engenharia e como ela pode dialogar com a física.

- ▶ motivação histórica;
- ▶ o que é aprendizado de máquina;
- ▶ o que é aprendizado de máquina científico;
- ▶ ideias iniciais de PINNs, SINDy e modelos substitutos;
- ▶ bibliografia e uso de cada referência.



Como usar inteligência artificial em problemas físicos sem abandonar as leis da física?



Por que este tema agora?

Mudanças recentes

- ▶ mais dados experimentais e numéricos;
- ▶ sensores, câmeras e simulações em grande escala;
- ▶ bibliotecas abertas em Python;
- ▶ GPUs acessíveis em computadores e nuvem;
- ▶ avanço de redes neurais e otimização.

Mas a engenharia tem uma exigência própria

- ▶ previsões precisam fazer sentido físico;
- ▶ extrapolações ruins podem ser perigosas;
- ▶ interpretabilidade importa;
- ▶ leis de conservação não são opcionais.


O desafio não é apenas prever. É prever respeitando estrutura física.

Uma motivação histórica: antes da inteligência artificial

Por muito tempo, a pergunta foi:

Como transformar fenômenos observados na natureza em **equações** capazes de prever o comportamento de sistemas físicos?

- ▶ Newton formaliza leis do movimento;
- ▶ Euler escreve equações para fluidos ideais;
- ▶ Navier e Stokes incorporam viscosidade;
- ▶ Fourier modela a condução de calor.



A primeira grande revolução foi perceber que a natureza podia ser escrita em linguagem matemática.


Curiosidade histórica: uma previsão do tempo feita à mão

Lewis Fry Richardson, 1922

Richardson imaginou prever o tempo resolvendo numericamente equações da atmosfera antes da era dos computadores eletrônicos.

Weather Prediction by Numerical Process.

- ▶ a ideia era dividir o espaço em uma malha;
- ▶ calcular a evolução das variáveis atmosféricas;
- ▶ repetir o processo passo a passo no tempo;
- ▶ uma “fábrica de previsão” teria milhares de pessoas calculando em paralelo.



malha + equações + cálculo repetido

A CFD nasceu, em espírito, antes de existir computador capaz de executá-la.

Dos computadores à CFD: a terceira perna da engenharia

- ▶ experimentos continuam indispensáveis;
- ▶ soluções analíticas existem apenas para casos especiais;
- ▶ computadores permitem resolver modelos discretizados;
- ▶ CFD transforma equações em campos aproximados.

Equações diferenciais



Discretização



Sistema algébrico



Campo numérico

A mudança conceitual

Não precisamos resolver a equação “de uma vez”. Podemos aproximá-la em muitos pontos, passo a passo.


A simulação numérica não eliminou teoria nem experimento: ela passou a conversar com ambos.

Outra curiosidade: caos e sensibilidade às condições iniciais

Edward Lorenz, 1963

Ao estudar um modelo simplificado da atmosfera, Lorenz mostrou que pequenas diferenças nas condições iniciais podiam produzir trajetórias muito diferentes.

- ▶ nem todo sistema determinístico é facilmente previsível;
- ▶ erro pequeno pode crescer com o tempo;
- ▶ dados, modelo e incerteza precisam ser tratados com cuidado.



Em fluidos, previsão não é apenas cálculo: também envolve estabilidade, dados e incerteza.

Um grande problema da física clássica

"Finally, there is a physical problem that is common to many fields, that is very old, and that has not been solved. It is not the problem of finding new fundamental particles, but something left over from a long time ago—over a hundred years. Nobody in physics has really been able to analyze it mathematically satisfactorily in spite of its importance to the sister sciences. It is the analysis of circulating or turbulent fluids." R. Feynman (Feynman Lectures on Physics Vol. I)

- Conseguimos descrever desde órbitas planetárias até semicondutores, mas ainda não sabemos prever, em todos os detalhes, a evolução da fumaça de uma vela.

Ideia central

A dificuldade não é a falta de equações. O problema é que as equações que temos são **não lineares, sensíveis às condições iniciais e multiescala.**

As equações de Navier-Stokes

O movimento de um fluido newtoniano incompressível, com propriedades constantes, pode ser descrito por:

$$\rho \left(\frac{\partial \mathbf{u}}{\partial t} + \mathbf{u} \cdot \nabla \mathbf{u} \right) = -\nabla p + \mu \nabla^2 \mathbf{u} + \rho \mathbf{g}$$

$$\nabla \cdot \mathbf{u} = 0$$

incompressibilidade

- ▶ $\mathbf{u} \cdot \nabla \mathbf{u}$ é o termo **não linear**.
- ▶ $-\nabla p$ é o termo da pressão.
- ▶ $\mu \nabla^2 \mathbf{u}$ representa a difusão viscosa.

Problema do Milênio

Provar existência e suavidade das soluções 3D das equações de Navier-Stokes vale **US\$ 1 milhão**.

Clay Mathematics Institute. Em aberto desde 2000.

E onde a inteligência artificial entra nessa história?


- ▶ o perceptron populariza a ideia de máquina que aprende padrões;
- ▶ backpropagation torna viável treinar redes multicamadas;
- ▶ GPUs e grandes bases de dados impulsionam redes profundas;
- ▶ na ciência, surge a pergunta: como unir redes, dados e equações?



A virada para este curso

A IA deixa de ser apenas uma ferramenta de classificação e passa a ser usada para representar funções, acelerar simulações, resolver EDPs e descobrir modelos.

Uma motivação histórica em quatro atos



Ideia central

A engenharia sempre combinou **modelos**, **medições** e **computação**. O aprendizado de máquina científico é uma nova forma de organizar essa combinação.

O caminho clássico da engenharia

1. observamos um fenômeno físico;
2. escrevemos hipóteses e leis de conservação;
3. obtemos um modelo matemático;
4. resolvemos analítica ou numericamente;
5. comparamos com experimentos ou dados reais.

Exemplos conhecidos

- ▶ condução de calor: equação do calor;
- ▶ ondas: equação da onda;
- ▶ escoamentos viscosos: Navier–Stokes;
- ▶ difusão e transporte: advecção–difusão.



Onde a abordagem clássica encontra dificuldade?

Quando resolver é caro

- ▶ simulações CFD podem exigir muitas horas ou dias;
- ▶ varrer muitos parâmetros pode ser inviável;
- ▶ otimização e controle exigem muitas avaliações.

Quando os dados são incompletos

- ▶ poucas medições;
- ▶ ruído experimental;
- ▶ campos físicos parcialmente observados.

Quando o modelo é incerto

- ▶ parâmetros desconhecidos;
- ▶ condições de contorno mal conhecidas;
- ▶ leis constitutivas complexas;
- ▶ efeitos não modelados.

Aqui dados, física e aprendizado se encontram.

O que é aprendizado de máquina?

Definição operacional

Aprendizado de máquina é uma família de métodos em que um modelo ajusta seus parâmetros a partir de dados para realizar uma tarefa: prever, classificar, reconstruir, agrupar ou controlar.

Supervisionado

Usa exemplos de entrada e saída.

Ex.: prever temperatura a partir de posição e tempo.

Não supervisionado

Procura estrutura nos dados.

Ex.: encontrar padrões dominantes em snapshots de escoamento.

Reforço

Aprende por tentativa, erro e recompensa.

Ex.: controlar um atuador em um escoamento.

Programação tradicional versus aprendizado de máquina



Um exemplo simples: ajustar uma lei

Imagine que medimos pares (x, y) e queremos aproximar a relação entre eles.

$$y \approx ax + b$$

O treinamento procura os parâmetros a e b que tornam a previsão mais próxima dos dados.

Ideia que será repetida no curso

- ▶ escolher uma família de modelos;
- ▶ medir o erro por uma função de perda;
- ▶ ajustar parâmetros;
- ▶ avaliar se o modelo generaliza.

Redes neurais fazem algo parecido, mas com modelos muito mais flexíveis.

Por que fluidos são difíceis?

- ▶ as equações podem ser não lineares;
- ▶ há múltiplas escalas de espaço e tempo;
- ▶ condições de contorno importam muito;
- ▶ turbulência e instabilidades podem surgir;
- ▶ propriedades materiais podem ser complexas;
- ▶ campos físicos são funções de várias variáveis.

Campos típicos

$$\mathbf{u}(x, y, z, t), \quad p(x, y, z, t) \\ T(x, y, z, t)$$

Velocidade, pressão, temperatura, concentração, tensão, vorticidade.

Consequência

Pequenas mudanças em geometria, parâmetros ou contorno podem alterar bastante a resposta.

Definição de trabalho

Aprendizado de máquina científico é o uso de modelos de aprendizado de máquina para **resolver**, **acelerar**, **reconstruir** ou **descobrir** modelos de sistemas físicos, incorporando conhecimento científico sempre que possível.

Resolver

Acelerar

Reconstruir

Descobrir

- ▶ resolver uma EDP com uma rede neural;
- ▶ acelerar uma simulação cara;
- ▶ reconstruir um campo a partir de medições parciais;
- ▶ descobrir termos de uma equação a partir de dados.

Três ideias que aparecerão muitas vezes

Problema direto	Problema inverso	Regularização
Dadas as causas, prever os efeitos.	Dados os efeitos, estimar causas ou parâmetros.	Usar informação adicional para evitar soluções ruins, instáveis ou sem sentido físico.
parâmetros $\rightarrow$ campo	campo $\rightarrow$ parâmetro	


Em problemas físicos, nem todo ajuste matemático é uma boa solução física.

O que é uma rede neural neste curso?

Uma rede neural será tratada, inicialmente, como uma **função parametrizada**.

$$u_{\theta}(x, t)$$

Ela recebe entradas, combina operações simples e produz uma saída.




Interpretação

θ representa os parâmetros ajustáveis: pesos e vieses.

PINN: a ideia em uma frase

Physics-Informed Neural Network

Uma PINN é uma rede neural treinada para ajustar dados e, ao mesmo tempo, respeitar uma equação física, condições iniciais e condições de contorno.



A física entra no treinamento como parte do erro que a rede tenta reduzir.

PINN: função de perda

$$\mathcal{L} = \mathcal{L}_{\text{dados}} + \mathcal{L}_{\text{física}} + \mathcal{L}_{\text{contorno}}$$

- ▶ erro contra dados observados;
- ▶ erro da equação diferencial;
- ▶ erro nas condições iniciais e de contorno.

Exemplo abstrato

Se a física exige

$$\mathcal{N}[u](x, t) = 0,$$

a rede propõe $u_{\theta}(x, t)$. Então medimos o resíduo:

$$\mathcal{N}[u_{\theta}](x, t).$$

PINNs em problemas diretos e inversos

Problema direto

Conhecemos a equação, os parâmetros e as condições. Queremos obter a solução.

$$\alpha \text{ conhecido} \Rightarrow T(x, t)$$

Problema inverso

Temos dados parciais da solução. Queremos estimar parâmetros desconhecidos.


$$T(x, t) \text{ medido} \Rightarrow \alpha$$

Uma das forças das PINNs é tratar solução e parâmetros dentro do mesmo processo de treinamento.

SINDy: descobrir equações a partir de dados

Sparse Identification of Nonlinear Dynamics

SINDy procura uma equação simples, interpretável e esparsa que explique a dinâmica observada nos dados.




PINN: equação conhecida. SINDy: equação descoberta.

Modelos substitutos: acelerar o que é caro

Surrogate models

Um modelo substituto é treinado para imitar um simulador, experimento ou modelo caro, produzindo aproximações rápidas para novas entradas.



POD, DMD e redução de ordem: por que aparecem antes?

Antes de chegar às PINNs, o curso passa por decomposições e modelos reduzidos.

- ▶ **SVD**: decompor dados em estruturas dominantes;
- ▶ **PCA**: encontrar direções de maior variância;
- ▶ **POD**: modos coerentes em escoamentos;
- ▶ **DMD**: modos com informação temporal.

Mensagem

Nem todo aprendizado científico começa com redes neurais. Antes de redes profundas, precisamos entender como dados podem ser organizados, comprimidos e interpretados.

Mapa do curso

Módulo	Papel dentro da formação
Fundamentos matemáticos e de composições	Construir a linguagem de matrizes, SVD, PCA, POD e modelos reduzidos.
Regressão, EDPs e DMD	Entender ajuste de modelos, regularização, problemas diretos/inversos e dinâmica em dados.
Redes neurais artificiais	Apresentar redes, treinamento, função de perda, backpropagation e regularização.
PINNs: fundamentos	Mostrar como uma rede neural pode incorporar equações diferenciais na perda.
PINNs: aplicações	Resolver e interpretar exemplos em calor, Navier–Stokes e fluidos não newtonianos.
SINDy e tópicos avançados	Descobrir equações, construir surrogates e visualizar direções futuras.

Subprojetos

Subprojeto	Ideia física/computacional	Perfil
Burgers 1D	Benchmark para aprender PINNs, solução de referência e validação.	Iniciante
Calor 2D inverso	Estimar difusividade térmica a partir de dados sintéticos ruidosos.	Iniciante / intermediário
Poiseuille não newtoniano	Aplicar PINN a fluido de lei de potência e validar com solução semi-analítica.	Intermediário
Obstáculo	Treinar modelo substituto para prever campos de velocidade e pressão.	Interm.-avançado
SINDy constitutivo	Recuperar modelo constitutivo a partir de dados sintéticos e testar robustez a ruído.	Avançado

Linguagem e bibliotecas

- ▶ Python;
- ▶ NumPy, SciPy e Matplotlib;
- ▶ PyTorch;
- ▶ DeepXDE;
- ▶ PySINDy.

Ambiente de trabalho

- ▶ Google Colab para experimentos iniciais;
- ▶ Git e GitHub para versionamento;
- ▶ notebooks documentados;
- ▶ códigos reproduzíveis.

O objetivo não é apenas rodar código: é entender, validar e documentar.

Bibliografia principal: visão geral

Referência	Uso no curso
Brunton & Kutz, <i>Data-Driven Science and Engineering</i>	Base para SVD, PCA, POD, DMD, SINDy, modelos reduzidos e visão computacional da ciência orientada por dados.
Goodfellow, Bengio & Courville, <i>Deep Learning</i>	Base conceitual para redes neurais, treinamento, funções de perda, otimização e regularização.
Strang, <i>Linear Algebra and Learning from Data</i>	Apoio para álgebra linear, autovalores, SVD e interpretação geométrica dos métodos.

Estas referências formam a base matemática e computacional do curso.

Bibliografia para PINNs e aprendizado físico

Referência	Uso no curso
Raissi, Perdikaris & Karniadakis (2019)	Artigo fundador das PINNs modernas; referência central para problemas diretos e inversos com EDPs.
Cai et al. (2021)	Revisão de PINNs para mecânica dos fluidos; ponte entre formulação geral e aplicações em escoamentos.
Karniadakis et al. (2021)	Panorama amplo de physics-informed machine learning; situa PINNs dentro de uma área maior.
Lu et al. (2021), DeepXDE	Referência prática para implementar PINNs em uma biblioteca voltada a equações diferenciais.

Bibliografia para tópicos avançados e subprojetos

Referência	Uso no curso
Brunton, Proctor & Kutz (2016)	Artigo-base do SINDy; usado para descoberta de equações a partir de dados.
Wang, Yu & Perdikaris (2022)	Limitações de treinamento de PINNs; importante para entender falhas e diagnósticos.
Zhai, Yin & Pang (2023)	PINNs para fluidos de lei de potência; conexão direta com fluido não newtoniano.
Raissi, Yazdani & Karniadakis (2020)	Inferência de campos de velocidade e pressão a partir de visualizações de escoamento.

Como estudar durante o curso

Em cada semana

- ▶ assistir à aula;
- ▶ ler trechos selecionados;
- ▶ executar notebooks;
- ▶ modificar exemplos;
- ▶ registrar dúvidas e resultados.

Três níveis de tutorial

1. replicar um exemplo pronto;
2. modificar parâmetros e interpretar mudanças;
3. estender para uma pequena variação do problema.

Autonomia científica se constrói por repetição, modificação e extensão.

O que é esperado do estudante


- ▶ curiosidade para aprender matemática, física e programação de forma integrada;
- ▶ disposição para errar, depurar e tentar novamente;
- ▶ cuidado com validação: comparar com solução analítica, referência numérica ou teste conhecido;
- ▶ organização do código e dos resultados;
- ▶ escrita técnica clara;
- ▶ participação nas reuniões e seminários internos.

Mensagem

O objetivo não é apenas “fazer uma rede rodar”. O objetivo é formar alguém capaz de formular, implementar, validar e explicar um problema científico-computacional.

A pergunta não é se a inteligência artificial vai substituir a física.

A pergunta é como vamos usar dados e modelos para fazer física e engenharia melhor.



dados + física + computação

Referências citadas e usadas no curso I

1. Brunton, S. L. & Kutz, J. N. (2022). *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2. ed. Cambridge University Press.
2. Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press.
3. Strang, G. (2019). *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press.
4. Raissi, M., Perdikaris, P. & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707.
5. Cai, S. et al. (2021). Physics-informed neural networks (PINNs) for fluid mechanics: A review. *Acta Mechanica Sinica*, 37, 1727–1738.
6. Karniadakis, G. E. et al. (2021). Physics-informed machine learning. *Nature Reviews Physics*, 3, 422–440.
7. Lu, L. et al. (2021). DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, 63(1), 208–228.
8. Brunton, S. L., Proctor, J. L. & Kutz, J. N. (2016). Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *PNAS*, 113(15), 3932–3937.

Referências citadas e usadas no curso II

- 
9. Wang, S., Yu, X. & Perdikaris, P. (2022). When and why PINNs fail to train: A neural tangent kernel perspective. *Journal of Computational Physics*, 449, 110768.
 10. Zhai, R., Yin, D. & Pang, G. (2023). A deep learning framework for solving forward and inverse problems of power-law fluids. *Physics of Fluids*, 35(9), 093115.
 11. Raissi, M., Yazdani, A. & Karniadakis, G. E. (2020). Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations. *Science*, 367, 1026–1030.

NeuroFluidos

Fundamentos de Aprendizado de Máquina Científico para Mecânica dos Fluidos

