

Aula 2 — Revisão de Álgebra Linear I

Matrizes, vetores, multiplicação, transposta, inversa, posto, espaço coluna e espaço nulo

Prof. Dr. Rodrigo Figueiredo Abdo

1. Ideia central da aula

A Aula 1 apresentou o curso em perspectiva ampla: aprendizado de máquina científico, PINNs, SINDy, modelos substitutos e aplicações em mecânica dos fluidos. A partir de agora, a construção deixa de ser panorâmica e passa a ser matemática. Esta aula inicia a base de álgebra linear que será usada nas decomposições, nos modelos de ordem reduzida, na regressão, nas redes neurais e nos métodos de descoberta de equações.

O conteúdo desta aula é deliberadamente restrito. Não se pretende revisar toda a álgebra linear. O objetivo é consolidar os conceitos que serão usados de forma recorrente nas próximas aulas: vetores, matrizes, multiplicação em três leituras, transposta, inversa, posto, espaço coluna, espaço nulo e teorema do núcleo e da imagem. Esses conceitos formam a linguagem mínima para entender por que uma matriz pode representar uma coleção de dados, uma transformação linear, um sistema de equações ou uma aproximação de baixa dimensão.

Em aprendizado de máquina científico, quase sempre lidamos com objetos discretizados. Um campo de temperatura amostrado em uma malha pode ser reorganizado como um vetor. Vários campos de velocidade obtidos em instantes diferentes podem formar uma matriz de snapshots. Os pesos de uma camada de rede neural formam uma matriz. Um problema inverso linearizado pode ser escrito como um sistema matricial. Por isso, a álgebra linear não aparece como um tema isolado; ela é a gramática de boa parte do curso.

2. Vetores, escalares e combinação linear

Um escalar é um único número, normalmente pertencente a $\mathbb{R}$. Um vetor em $\mathbb{R}^n$ é uma coleção ordenada de n números. Nesta aula, adotaremos a convenção de escrever vetores como colunas:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^n.$$

As componentes $x_1, x_2, \dots, x_n$ podem representar coordenadas geométricas, medições experimentais, valores de uma variável física em pontos de uma malha, coeficientes de uma expansão ou variáveis de estado de um sistema.

A transposta de um vetor coluna é um vetor linha:

$$\mathbf{x}^T = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix}.$$

Essa distinção será importante porque, em notação matricial, $\mathbf{x}$ e $\mathbf{x}^T$ não têm a mesma dimensão: se $\mathbf{x} \in \mathbb{R}^n$, então $\mathbf{x}$ pode ser visto como uma matriz $n \times 1$, enquanto $\mathbf{x}^T$ é uma matriz $1 \times n$.

Se $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ e $c, d \in \mathbb{R}$, então

$$c\mathbf{u} + d\mathbf{v}$$

é uma combinação linear de $\mathbf{u}$ e $\mathbf{v}$. Escrevendo componente a componente,

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix},$$

temos

$$c\mathbf{u} + d\mathbf{v} = \begin{bmatrix} cu_1 + dv_1 \\ cu_2 + dv_2 \\ \vdots \\ cu_n + dv_n \end{bmatrix}.$$

Apesar de elementar, essa operação é uma das ideias centrais de toda a álgebra linear. Quando afirmamos que um vetor pode ser produzido a partir de outros vetores, geralmente estamos afirmando que ele pode ser escrito como combinação linear deles.

Exemplo 1

Considere

$$\mathbf{u} = \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 3 \\ 0 \\ 4 \end{bmatrix}.$$

Então

$$2\mathbf{u} - \mathbf{v} = 2 \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} - \begin{bmatrix} 3 \\ 0 \\ 4 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ -2 \end{bmatrix} - \begin{bmatrix} 3 \\ 0 \\ 4 \end{bmatrix} = \begin{bmatrix} -1 \\ 4 \\ -6 \end{bmatrix}.$$

O resultado ainda pertence a $\mathbb{R}^3$. O conjunto $\mathbb{R}^3$ é fechado por soma de vetores e multiplicação por escalares.

Se $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$, o conjunto de todas as combinações lineares desses vetores é chamado de espaço gerado por eles:

$$\text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \{c_1\mathbf{v}_1 + \cdots + c_k\mathbf{v}_k : c_1, \dots, c_k \in \mathbb{R}\}.$$

A palavra “gerado” deve ser tomada literalmente: variando os coeficientes $c_1, \dots, c_k$, os vetores do conjunto produzem todos os vetores do subespaço gerado.

3. Independência linear

Os vetores $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$ são linearmente independentes quando a equação

$$c_1 \mathbf{v}_1 + c_2 \mathbf{v}_2 + \dots + c_k \mathbf{v}_k = \mathbf{0}$$

tem apenas a solução trivial

$$c_1 = c_2 = \dots = c_k = 0.$$

Se existir uma solução não trivial, isto é, se pelo menos um dos coeficientes for diferente de zero, os vetores são linearmente dependentes.

Essa definição é mais forte do que parece. Ela diz que, em um conjunto independente, nenhum vetor pode ser fabricado a partir dos demais. Em um conjunto dependente, existe redundância: pelo menos uma direção já estava contida nas anteriores.

Exemplo 2

Considere

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Como

$$\mathbf{v}_2 = 2\mathbf{v}_1,$$

os vetores são linearmente dependentes. Equivalentemente,

$$2\mathbf{v}_1 - \mathbf{v}_2 = \mathbf{0},$$

e essa combinação linear que produz o vetor zero tem coeficientes não triviais.

Agora considere

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

A equação

$$c_1 \mathbf{e}_1 + c_2 \mathbf{e}_2 = \mathbf{0}$$

leva a

$$\begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Portanto, $c_1 = c_2 = 0$ e os vetores são linearmente independentes.

4. Matrizes e notação

Uma matriz $A \in \mathbb{R}^{m \times n}$ possui m linhas e n colunas:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}.$$

O elemento a_{ij} está na linha i e na coluna j .

A mesma matriz pode ser lida por colunas:

$$A = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_n \\ | & | & & | \end{bmatrix}, \quad \mathbf{a}_j \in \mathbb{R}^m,$$

ou por linhas:

$$A = \begin{bmatrix} \mathbf{r}_1^T \\ \mathbf{r}_2^T \\ \vdots \\ \mathbf{r}_m^T \end{bmatrix}, \quad \mathbf{r}_i \in \mathbb{R}^n.$$

A leitura por linhas é útil para calcular componentes de uma saída. A leitura por colunas é mais importante para compreender sistemas lineares, posto, espaço coluna, espaço nulo e decomposições matriciais.

Em aplicações de dados, uma matriz pode representar uma tabela de observações. Por exemplo, se cada linha representa um experimento e cada coluna representa uma variável medida, então uma matriz $X \in \mathbb{R}^{m \times n}$ contém m amostras e n características. Em mecânica dos fluidos computacional, uma matriz também pode ser formada colocando em cada coluna um snapshot de um campo físico discretizado. Essa segunda leitura será essencial para PCA, POD e SVD.

5. Multiplicação matriz-vetor em três visões

Há três modos úteis de ler a multiplicação. Dois deles são formas de *cálculo* — o produto linha por coluna e a combinação linear das colunas — e o terceiro é uma *leitura conceitual*: a matriz como transformação linear. Mais adiante veremos ainda uma quarta leitura, por soma de produtos externos, especialmente útil para as decomposições.

Se $A \in \mathbb{R}^{m \times n}$ e $\mathbf{x} \in \mathbb{R}^n$, então o produto $A\mathbf{x}$ está definido e pertence a $\mathbb{R}^m$:

$$A\mathbf{x} = \mathbf{y}, \quad \mathbf{y} \in \mathbb{R}^m.$$

A condição dimensional é indispensável: o número de colunas de A deve coincidir com o número

de componentes de $\mathbf{x}$.

5.1 Visão 1: produto linha por coluna

A i -ésima componente de $\mathbf{y} = A\mathbf{x}$ é

$$y_i = a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n = \sum_{j=1}^n a_{ij}x_j.$$

Portanto, cada componente da saída é um produto interno entre uma linha de A e o vetor de entrada:

$$y_i = \mathbf{r}_i^T \mathbf{x}.$$

Essa é a forma mais direta de executar a conta.

5.2 Visão 2: combinação linear das colunas

Como A pode ser escrita por colunas,

$$A = \begin{bmatrix} | & | & & | \\ \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_n \\ | & | & & | \end{bmatrix},$$

temos

$$A\mathbf{x} = \begin{bmatrix} | & | & & | \\ \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_n \\ | & | & & | \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \cdots + x_n\mathbf{a}_n.$$

Assim,

$$A\mathbf{x} = \sum_{j=1}^n x_j \mathbf{a}_j.$$

Esta identidade é central na aula: multiplicar uma matriz por um vetor significa combinar as colunas da matriz usando as componentes do vetor como coeficientes. Desse modo, qualquer vetor da forma $A\mathbf{x}$ pertence necessariamente ao espaço gerado pelas colunas de A .

5.3 Visão 3: transformação linear

A multiplicação por A também define uma transformação

$$T : \mathbb{R}^n \rightarrow \mathbb{R}^m, \quad T(\mathbf{x}) = A\mathbf{x}.$$

Essa transformação é linear porque, para quaisquer $\mathbf{x}, \mathbf{z} \in \mathbb{R}^n$ e quaisquer $\alpha, \beta \in \mathbb{R}$,

$$T(\alpha\mathbf{x} + \beta\mathbf{z}) = A(\alpha\mathbf{x} + \beta\mathbf{z}) = \alpha A\mathbf{x} + \beta A\mathbf{z} = \alpha T(\mathbf{x}) + \beta T(\mathbf{z}).$$

Essa visão é essencial para a sequência do curso: matrizes podem esticar, comprimir, rotacionar, cisalhar, projetar ou anular direções. Nas próximas aulas, autovalores, SVD, PCA e POD serão maneiras de descrever essas ações de forma organizada.

Exemplo 3

Considere

$$A = \begin{bmatrix} 1 & -1 \\ 2 & 0 \\ 0 & 3 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Pela visão linha por coluna,

$$A\mathbf{x} = \begin{bmatrix} 1 \cdot 2 + (-1)(-1) \\ 2 \cdot 2 + 0(-1) \\ 0 \cdot 2 + 3(-1) \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \\ -3 \end{bmatrix}.$$

Pela visão de combinação das colunas,

$$A\mathbf{x} = 2 \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} - 1 \begin{bmatrix} -1 \\ 0 \\ 3 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ -3 \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \\ -3 \end{bmatrix}.$$

Pela visão de transformação, A leva uma entrada em $\mathbb{R}^2$ para uma saída em $\mathbb{R}^3$. A imagem de todos os vetores $\mathbf{x} \in \mathbb{R}^2$ não pode preencher todo o $\mathbb{R}^3$; ela fica restrita, no máximo, ao plano gerado pelas duas colunas de A .

6. Multiplicação matriz-matriz em três visões

Se $A \in \mathbb{R}^{m \times n}$ e $B \in \mathbb{R}^{n \times p}$, então o produto AB está definido e pertence a $\mathbb{R}^{m \times p}$. Se $C = AB$, o elemento c_{ij} é

$$c_{ij} = \sum_{k=1}^n a_{ik} b_{kj}.$$

Essa é a regra linha por coluna.

A segunda visão lê AB por colunas. Se

$$B = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{b}_1 & \mathbf{b}_2 & \cdots & \mathbf{b}_p \\ | & | & & | \end{bmatrix},$$

então

$$AB = \begin{bmatrix} | & | & & | \\ Ab_1 & Ab_2 & \cdots & Ab_p \\ | & | & & | \end{bmatrix}.$$

Ou seja, multiplicar A por B equivale a aplicar A a cada coluna de B .

A terceira visão é a de composição de transformações. Se B leva vetores de $\mathbb{R}^p$ para $\mathbb{R}^n$ e A leva vetores de $\mathbb{R}^n$ para $\mathbb{R}^m$, então AB representa aplicar primeiro B e depois A :

$$\mathbf{x} \in \mathbb{R}^p \xrightarrow{B} B\mathbf{x} \in \mathbb{R}^n \xrightarrow{A} A(B\mathbf{x}) = (AB)\mathbf{x} \in \mathbb{R}^m.$$

A ordem importa: AB e BA geralmente não representam a mesma operação. Em muitos casos, um dos produtos sequer está definido.

6.1 Visão adicional: soma de produtos externos (posto um)

Há ainda uma quarta leitura, anunciada antes e agora aplicada à multiplicação matriz-matriz, especialmente importante para as decomposições que virão. Escrevendo A por colunas e B por linhas,

$$A = \begin{bmatrix} | & & | \\ \mathbf{a}_1 & \cdots & \mathbf{a}_n \\ | & & | \end{bmatrix}, \quad B = \begin{bmatrix} \beta_1^T \\ \vdots \\ \beta_n^T \end{bmatrix},$$

o produto pode ser escrito como uma soma de produtos externos:

$$AB = \sum_{k=1}^n \mathbf{a}_k \beta_k^T,$$

em que cada parcela multiplica a k -ésima coluna de A pela k -ésima linha de B . Cada produto externo $\mathbf{a}_k \beta_k^T$ é uma matriz $m \times p$ de *posto no máximo um*, pois todas as suas colunas são múltiplas de $\mathbf{a}_k$ — e de posto exatamente um sempre que $\mathbf{a}_k \neq \mathbf{0}$ e $\beta_k \neq \mathbf{0}$. Aqui β_k^T denota a k -ésima *linha* de B , em contraste com $\mathbf{b}_j$ na visão por colunas, que representava a j -ésima *coluna* de B .

Essa visão revela uma ideia estrutural: toda matriz de posto r pode ser escrita como soma de r matrizes de posto um. Guardar apenas as parcelas mais relevantes dessa soma produz uma aproximação de baixo posto da matriz original — exatamente o princípio que sustentará a SVD e a POD nas próximas aulas.

Como ilustração, com $\mathbf{a} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e $\mathbf{b} = \begin{bmatrix} 3 \\ -1 \end{bmatrix}$,

$$\mathbf{a}\mathbf{b}^T = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \begin{bmatrix} 3 & -1 \end{bmatrix} = \begin{bmatrix} 3 & -1 \\ 6 & -2 \end{bmatrix},$$

cujas duas colunas são múltiplas de $\mathbf{a}$; portanto, a matriz tem posto um.

Exemplo 4

Considere

$$A = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \end{bmatrix}, \quad B = \begin{bmatrix} 2 & 1 \\ 0 & -1 \\ 1 & 4 \end{bmatrix}.$$

Como $A \in \mathbb{R}^{2 \times 3}$ e $B \in \mathbb{R}^{3 \times 2}$, temos $AB \in \mathbb{R}^{2 \times 2}$. Calculando,

$$AB = \begin{bmatrix} 1 \cdot 2 + 2 \cdot 0 + 0 \cdot 1 & 1 \cdot 1 + 2(-1) + 0 \cdot 4 \\ -1 \cdot 2 + 1 \cdot 0 + 3 \cdot 1 & -1 \cdot 1 + 1(-1) + 3 \cdot 4 \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ 1 & 10 \end{bmatrix}.$$

O produto BA também está definido, mas pertence a $\mathbb{R}^{3 \times 3}$. Portanto, neste exemplo, AB e BA não podem ser iguais: eles têm tamanhos diferentes.

7. Transposta e produto interno

A transposta de uma matriz $A \in \mathbb{R}^{m \times n}$ é a matriz $A^T \in \mathbb{R}^{n \times m}$ obtida trocando linhas por colunas. Se

$$A = \begin{bmatrix} 1 & 2 & 0 \\ -1 & 1 & 3 \end{bmatrix},$$

então

$$A^T = \begin{bmatrix} 1 & -1 \\ 2 & 1 \\ 0 & 3 \end{bmatrix}.$$

As propriedades básicas são

$$(A^T)^T = A, \quad (A + B)^T = A^T + B^T, \quad (\alpha A)^T = \alpha A^T,$$

e

$$(AB)^T = B^T A^T.$$

A última identidade merece atenção: a transposta de um produto inverte a ordem dos fatores.

Para $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, o produto interno é escrito como

$$\mathbf{x}^T \mathbf{y} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \sum_{i=1}^n x_i y_i.$$

O produto interno mede alinhamento. Se $\mathbf{x}^T \mathbf{y} = 0$, os vetores são ortogonais. Essa ideia será retomada na Aula 3 ao estudar normas e matrizes ortogonais.

Uma matriz que aparecerá repetidamente é $A^T A$. Se as colunas de A são $\mathbf{a}_1, \dots, \mathbf{a}_n$,

então

$$A^T A = \begin{bmatrix} \mathbf{a}_1^T \mathbf{a}_1 & \mathbf{a}_1^T \mathbf{a}_2 & \cdots & \mathbf{a}_1^T \mathbf{a}_n \\ \mathbf{a}_2^T \mathbf{a}_1 & \mathbf{a}_2^T \mathbf{a}_2 & \cdots & \mathbf{a}_2^T \mathbf{a}_n \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{a}_n^T \mathbf{a}_1 & \mathbf{a}_n^T \mathbf{a}_2 & \cdots & \mathbf{a}_n^T \mathbf{a}_n \end{bmatrix}.$$

Portanto, $A^T A$ guarda os produtos internos entre todas as colunas de A . Essa observação antecipa ideias importantes: ortogonalidade de colunas, mínimos quadrados, SVD e PCA.

8. Matriz identidade e matriz inversa

A matriz identidade $I_n \in \mathbb{R}^{n \times n}$ é definida por

$$I_n = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}.$$

Ela satisfaz

$$I_n \mathbf{x} = \mathbf{x}$$

para todo $\mathbf{x} \in \mathbb{R}^n$.

Uma matriz quadrada $A \in \mathbb{R}^{n \times n}$ é invertível se existe uma matriz $A^{-1} \in \mathbb{R}^{n \times n}$ tal que

$$A^{-1} A = A A^{-1} = I_n.$$

Quando A é invertível, o sistema linear

$$A\mathbf{x} = \mathbf{b}$$

tem solução única para todo $\mathbf{b} \in \mathbb{R}^n$, dada por

$$\mathbf{x} = A^{-1} \mathbf{b}.$$

Do ponto de vista geométrico, uma matriz invertível é uma transformação que não colapsa dimensões. Ela pode alongar, comprimir, rotacionar ou cisalhar o espaço, mas não destrói informação. Por isso, existe uma transformação inversa capaz de desfazer sua ação.

Para uma matriz 2×2 ,

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

a inversa, quando existe, é

$$A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

A condição é

$$ad - bc \neq 0.$$

O número $ad - bc$ é o determinante de A . Embora o determinante não seja o foco da aula, aqui ele fornece um critério simples para matrizes 2×2 : determinante zero significa que a transformação colapsa área, as colunas são dependentes e a matriz não possui inversa.

Exemplo 5

Considere o sistema

$$\begin{cases} 2x + y = 1, \\ 5x + 3y = 4. \end{cases}$$

Na forma matricial,

$$\begin{bmatrix} 2 & 1 \\ 5 & 3 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \end{bmatrix}.$$

Aqui

$$A = \begin{bmatrix} 2 & 1 \\ 5 & 3 \end{bmatrix}, \quad \det(A) = 2 \cdot 3 - 1 \cdot 5 = 1.$$

Logo,

$$A^{-1} = \begin{bmatrix} 3 & -1 \\ -5 & 2 \end{bmatrix}.$$

Assim,

$$\begin{bmatrix} x \\ y \end{bmatrix} = A^{-1} \mathbf{b} = \begin{bmatrix} 3 & -1 \\ -5 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 4 \end{bmatrix} = \begin{bmatrix} -1 \\ 3 \end{bmatrix}.$$

Portanto, $x = -1$ e $y = 3$.

O conceito de inversa é fundamental teoricamente, mas em computação científica raramente se recomenda calcular explicitamente A^{-1} apenas para resolver $A\mathbf{x} = \mathbf{b}$. Em geral, resolve-se o sistema por eliminação, fatoração ou métodos iterativos. Nesta aula, a inversa é usada principalmente para interpretar quando uma transformação pode ser desfeita de modo único.

9. Espaço coluna

Se $A \in \mathbb{R}^{m \times n}$ possui colunas $\mathbf{a}_1, \dots, \mathbf{a}_n \in \mathbb{R}^m$, o espaço coluna de A é

$$\text{Col}(A) = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\}.$$

Como

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \dots + x_n\mathbf{a}_n,$$

todo vetor da forma $A\mathbf{x}$ pertence a $\text{Col}(A)$. Reciprocamente, todo vetor de $\text{Col}(A)$ pode ser escrito como $A\mathbf{x}$ para alguma escolha de $\mathbf{x}$. Portanto,

$$\text{Col}(A) = \{A\mathbf{x} : \mathbf{x} \in \mathbb{R}^n\}.$$

Essa igualdade dá uma leitura precisa do sistema

$$A\mathbf{x} = \mathbf{b}.$$

Resolver esse sistema é perguntar se $\mathbf{b}$ pode ser construído como combinação linear das colunas de A :

$$A\mathbf{x} = \mathbf{b} \text{ tem solução} \iff \mathbf{b} \in \text{Col}(A).$$

Quando $\mathbf{b} \notin \text{Col}(A)$, o sistema não possui solução exata. Essa situação será central em mínimos quadrados: quando $\mathbf{b}$ não pode ser atingido, busca-se o vetor de $\text{Col}(A)$ mais próximo de $\mathbf{b}$.

Exemplo 6

Considere

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}.$$

Logo,

$$\text{Col}(A) = \left\{ \alpha \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + \beta \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} : \alpha, \beta \in \mathbb{R} \right\}.$$

Calculando,

$$\alpha \mathbf{a}_1 + \beta \mathbf{a}_2 = \begin{bmatrix} \alpha \\ \beta \\ \alpha + \beta \end{bmatrix}.$$

Assim, um vetor $\mathbf{b} = \begin{bmatrix} b_1 & b_2 & b_3 \end{bmatrix}^T$ pertence a $\text{Col}(A)$ se, e somente se,

$$b_3 = b_1 + b_2.$$

Por exemplo,

$$\begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix} \in \text{Col}(A), \quad \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix} \notin \text{Col}(A).$$

O sistema $A\mathbf{x} = \begin{bmatrix} 2 & 3 & 5 \end{bmatrix}^T$ tem solução. O sistema $A\mathbf{x} = \begin{bmatrix} 2 & 3 & 4 \end{bmatrix}^T$ não tem solução exata.

10. Espaço nulo

O espaço nulo de $A \in \mathbb{R}^{m \times n}$ é o conjunto de todos os vetores de entrada que são enviados para o vetor zero:

$$\text{Nul}(A) = \{\mathbf{x} \in \mathbb{R}^n : A\mathbf{x} = \mathbf{0}\}.$$

Ele é o conjunto de soluções do sistema homogêneo

$$A\mathbf{x} = \mathbf{0}.$$

O espaço nulo mede as direções que a matriz anula. Se $\mathbf{x} \in \text{Nul}(A)$, então a entrada $\mathbf{x}$ desaparece na saída. Em problemas inversos, isso tem uma consequência direta: se duas entradas diferentes produzem a mesma saída, a diferença entre elas pertence ao espaço nulo. De fato, se

$$A\mathbf{x}_1 = A\mathbf{x}_2,$$

então

$$A(\mathbf{x}_1 - \mathbf{x}_2) = \mathbf{0},$$

logo

$$\mathbf{x}_1 - \mathbf{x}_2 \in \text{Nul}(A).$$

Portanto, um espaço nulo não trivial está associado à perda de informação e à não unicidade.

Exemplo 7

Considere

$$A = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{bmatrix}.$$

Queremos resolver

$$A\mathbf{x} = \mathbf{0}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}.$$

O sistema é

$$\begin{cases} x_1 + 2x_2 + x_3 = 0, \\ x_2 + x_3 = 0, \\ x_1 + 3x_2 + 2x_3 = 0. \end{cases}$$

Da segunda equação,

$$x_2 = -x_3.$$

Substituindo na primeira,

$$x_1 + 2(-x_3) + x_3 = 0,$$

logo

$$x_1 = x_3.$$

A terceira equação fica automaticamente satisfeita:

$$x_1 + 3x_2 + 2x_3 = x_3 - 3x_3 + 2x_3 = 0.$$

Tomando $x_3 = t$, obtemos

$$\mathbf{x} = \begin{bmatrix} t \\ -t \\ t \end{bmatrix} = t \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}.$$

Assim,

$$\text{Nul}(A) = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix} \right\}.$$

Nesse exemplo, existe uma direção não nula que a matriz leva ao zero. A transformação perde informação nessa direção.

11. Posto

Antes de definir o posto, convém precisar a noção de dimensão. Uma base de um subespaço é um conjunto de vetores linearmente independentes que o geram, e a dimensão do subespaço é o número de vetores de qualquer uma de suas bases — equivalentemente, o número máximo de vetores linearmente independentes que ele contém.

O posto de uma matriz A , denotado por $\text{rank}(A)$, é a dimensão do espaço coluna:

$$\text{rank}(A) = \dim(\text{Col}(A)).$$

Equivalentemente, o posto é o número máximo de colunas linearmente independentes de A . Se $A \in \mathbb{R}^{m \times n}$, então

$$\text{rank}(A) \leq \min\{m, n\}.$$

Quando $\text{rank}(A) = n$, dizemos que A tem posto coluna completo. Quando $\text{rank}(A) = m$, dizemos que A tem posto linha completo. Quando $A \in \mathbb{R}^{n \times n}$ e $\text{rank}(A) = n$, a matriz é invertível. Vale ainda um fato notável: o número de colunas linearmente independentes é sempre igual ao número de linhas linearmente independentes, isto é, o posto-coluna coincide com o posto-linha. Isso pode ser visto pela eliminação de Gauss: as colunas *de* A situadas nas posições de pivô da forma escalonada formam uma base do espaço coluna (atenção: são as colunas da matriz original, e não as da forma escalonada, pois operações de linha alteram o espaço coluna), enquanto as

linhas não nulas da forma escalonada formam uma base do espaço linha — e aqui as operações de linha são inofensivas, pois elas *preservam* o espaço linha, ainda que alterem o espaço coluna. Como cada linha não nula da forma escalonada contém exatamente um pivô, e cada pivô ocupa exatamente uma coluna-pivô, as duas bases têm o mesmo número de vetores: o número de pivôs. Por isso falamos simplesmente em *posto*.

No exemplo anterior,

$$A = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{bmatrix}.$$

As colunas são

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}, \quad \mathbf{a}_3 = \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix}.$$

Observe que

$$\mathbf{a}_2 = \mathbf{a}_1 + \mathbf{a}_3.$$

Logo, as três colunas são linearmente dependentes. Contudo, $\mathbf{a}_1$ e $\mathbf{a}_3$ são linearmente independentes, pois não são múltiplas uma da outra. Assim,

$$\text{rank}(A) = 2.$$

O posto mede quantas direções independentes a matriz consegue produzir na saída. Uma matriz de posto baixo possui colunas redundantes. Em SVD, PCA e POD, essa ideia será usada em sentido construtivo: se muitos dados estão próximos de um subespaço de baixa dimensão, podemos representá-los de forma compacta com pouca perda de informação.

Exemplo 8

Considere

$$B = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 0 & 1 & 1 \end{bmatrix}.$$

As colunas são

$$\mathbf{b}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{b}_3 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

Como

$$\mathbf{b}_3 = \mathbf{b}_1 + \mathbf{b}_2,$$

as três colunas são dependentes. As duas primeiras são independentes. Portanto,

$$\text{rank}(B) = 2.$$

A imagem de B é um plano em $\mathbb{R}^3$, não o espaço inteiro $\mathbb{R}^3$.

12. Teorema do núcleo e da imagem

Para uma matriz $A \in \mathbb{R}^{m \times n}$, a transformação

$$T(\mathbf{x}) = A\mathbf{x}$$

tem domínio $\mathbb{R}^n$ e imagem $\text{Col}(A) \subseteq \mathbb{R}^m$. O teorema do núcleo e da imagem afirma que

$$\boxed{\text{rank}(A) + \dim(\text{Nul}(A)) = n.}$$

Esse resultado também é conhecido como teorema posto-nulidade.

A interpretação é direta. As n dimensões do espaço de entrada se dividem em duas categorias: direções que aparecem efetivamente na saída, contadas pelo posto, e direções que são anuladas pela matriz, contadas pela dimensão do espaço nulo.

No exemplo

$$A = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{bmatrix},$$

obtivemos

$$\text{rank}(A) = 2$$

e

$$\text{Nul}(A) = \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix} \right\}.$$

Logo,

$$\dim(\text{Nul}(A)) = 1.$$

Como A possui $n = 3$ colunas,

$$\text{rank}(A) + \dim(\text{Nul}(A)) = 2 + 1 = 3 = n.$$

Uma forma prática de entender esse teorema é pensar em variáveis pivô e variáveis livres. Ao resolver $A\mathbf{x} = \mathbf{0}$, cada coluna pivô corresponde a uma variável determinada pelas equações. Cada variável livre gera uma direção independente no espaço nulo. Como toda variável é pivô ou livre,

$$\#(\text{variáveis pivô}) + \#(\text{variáveis livres}) = n.$$

O número de variáveis pivô é o posto. O número de variáveis livres é a dimensão do espaço nulo.

Daí vem a identidade

$$\text{rank}(A) + \dim(\text{Nul}(A)) = n.$$

Esse teorema não é apenas uma igualdade de dimensões. Ele organiza a interpretação de problemas diretos e inversos. O posto indica quantas direções de entrada a matriz consegue transformar em saídas independentes. O espaço nulo indica quantas direções são invisíveis para a matriz. Quanto maior o espaço nulo, maior a possibilidade de não unicidade em um problema inverso.

13. Síntese da aula

Os conceitos desta aula formam um único arcabouço. O espaço coluna descreve o que uma matriz consegue produzir na saída; o espaço nulo descreve o que ela anula na entrada; o posto mede quantas direções independentes sobrevivem à transformação; e o teorema do núcleo e da imagem, $\text{rank}(A) + \dim(\text{Nul}(A)) = n$, mostra que o que é preservado e o que é perdido somam exatamente a dimensão do espaço de entrada. Ler a multiplicação como combinação de colunas e como soma de produtos externos de posto um já antecipa a ideia de representar dados por poucas direções dominantes. Na Aula 3, esse arcabouço será refinado com autovalores, autovetores e normas, que medem o quanto cada direção é esticada ou comprimida e preparam o terreno para a SVD, a PCA e a POD.

14. Exercícios propostos

Exercício 1. Considere

$$\mathbf{u} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 0 \\ 4 \\ 1 \end{bmatrix}.$$

Calcule $3\mathbf{u} - 2\mathbf{v}$ e interprete o resultado como uma combinação linear de $\mathbf{u}$ e $\mathbf{v}$.

Exercício 2. Seja

$$A = \begin{bmatrix} 1 & 2 \\ 0 & -1 \\ 3 & 1 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} 2 \\ -1 \end{bmatrix}.$$

Calcule $A\mathbf{x}$ de duas formas: primeiro por linha por coluna; depois como combinação linear das colunas de A .

Exercício 3. Considere

$$A = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 3 & 1 \\ -1 & 2 \end{bmatrix}.$$

Calcule AB e BA . Verifique se os produtos são iguais e explique o significado da diferença.

Exercício 4. Determine se a matriz

$$A = \begin{bmatrix} 4 & 2 \\ 6 & 3 \end{bmatrix}$$

é invertível. Em seguida, interprete o resultado em termos de dependência linear das colunas.

Exercício 5. Para a matriz

$$A = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 1 \\ 1 & 3 & 2 \end{bmatrix},$$

verifique diretamente que

$$\mathbf{x} = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

pertence a $\text{Nul}(A)$. Depois, usando o fato de que $\text{rank}(A) = 2$, confirme o teorema do núcleo e da imagem.

Exercício 6. Considere

$$C = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 2 \end{bmatrix}.$$

Determine uma relação de dependência linear entre as colunas de C . Em seguida, determine $\text{rank}(C)$ e descreva geometricamente $\text{Col}(C)$.

Exercício 7. Sejam

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix}.$$

Calcule $(AB)^T$ e verifique diretamente a identidade $(AB)^T = B^T A^T$.

15. Referências

- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.
- STRANG, G. *Introduction to Linear Algebra*. 6. ed. Wellesley-Cambridge Press, 2023.