

Aula 3 — Revisão de Álgebra Linear II

Autovalores, autovetores, decomposição espectral, matrizes ortogonais e normas

Prof. Dr. Rodrigo Figueiredo Abdo

1. Ideia central da aula

Na aula anterior, uma matriz foi estudada principalmente por meio de suas colunas. A igualdade

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \cdots + x_n\mathbf{a}_n$$

mostrou que multiplicar uma matriz por um vetor é construir uma combinação linear de suas colunas. A partir disso, discutimos espaço coluna, espaço nulo, posto e a relação entre o número de direções efetivas de entrada e o número de direções que a matriz destrói.

Nesta aula, a matriz será vista de outro modo: como uma transformação que pode alongar, comprimir, inverter, rotacionar ou misturar direções. A pergunta central será a seguinte:

existem direções que a matriz transforma sem mudar de direção?

Essa pergunta leva aos autovalores e autovetores. Eles não são apenas mais uma técnica algébrica. Eles permitem entender a ação de uma matriz por meio de direções especiais. Em problemas físicos, essas direções frequentemente aparecem como modos. Em vibrações, são modos naturais. Em difusão, são modos de decaimento. Em sistemas dinâmicos lineares, indicam crescimento, decaimento ou estabilidade. Em ciência de dados, aparecem no estudo de matrizes de covariância, PCA, POD e, indiretamente, na SVD.

O conteúdo programado para esta aula é: autovalores e autovetores, definição, cálculo e significado geométrico; decomposição espectral; matrizes ortogonais; normas de vetor e de matriz, com ênfase nas normas de Frobenius e espectral.

2. Produto interno, norma e ortogonalidade

Autovalores e autovetores tratam de direções. Para falar de direção com precisão, precisamos antes fixar três conceitos: produto interno, norma e ortogonalidade.

Para vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, o produto interno usual é

$$\mathbf{x}^T \mathbf{y} = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n.$$

A norma euclidiana de $\mathbf{x}$ é

$$\|\mathbf{x}\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2} = \sqrt{\mathbf{x}^T \mathbf{x}}.$$

O produto interno se relaciona com o ângulo entre dois vetores pela identidade

$$\mathbf{x}^T \mathbf{y} = \|\mathbf{x}\|_2 \|\mathbf{y}\|_2 \cos \theta.$$

Portanto, se $\mathbf{x}$ e $\mathbf{y}$ são não nulos, então

$$\mathbf{x}^T \mathbf{y} = 0$$

é equivalente a $\theta = 90^\circ$. Nesse caso, os vetores são ortogonais.

Um vetor é unitário quando tem norma igual a um:

$$\|\mathbf{x}\|_2 = 1.$$

Um conjunto de vetores é ortonormal quando seus vetores são unitários e mutuamente ortogonais.

Em símbolos, $\mathbf{q}_1, \dots, \mathbf{q}_k$ são ortonormais se

$$\mathbf{q}_i^T \mathbf{q}_j = \delta_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

Vale separar as duas informações contidas em δ_{ij} . A parte $i \neq j$, que pede $\mathbf{q}_i^T \mathbf{q}_j = 0$, é a *ortogonalidade*, e ela não depende da norma dos vetores. A parte $i = j$, que pede $\mathbf{q}_i^T \mathbf{q}_i = 1$, é a *normalização*, pois $\mathbf{q}_i^T \mathbf{q}_i = \|\mathbf{q}_i\|_2^2$ só vale um quando o vetor é unitário. Em termos da *matriz de Gram* $G_{ij} = \mathbf{v}_i^T \mathbf{v}_j$: uma base apenas ortogonal dá G *diagonal* (zeros fora da diagonal, mas $\|\mathbf{v}_i\|_2^2$ na diagonal); uma base ortonormal dá $G = I$, isto é, exatamente δ_{ij} ; e uma base qualquer dá G cheia, com produtos internos não nulos fora da diagonal — para vetores unitários mas não ortogonais, por exemplo, $\mathbf{v}_i^T \mathbf{v}_j = \cos \theta_{ij} \in [-1, 1]$.

A ortonormalidade é uma das condições mais importantes em métodos numéricos. Bases ortonormais evitam escalas artificiais, facilitam projeções, preservam distâncias e tornam mudanças de coordenadas mais estáveis.

Exemplo 1. Considere

$$\mathbf{u} = \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} -4 \\ 3 \end{bmatrix}.$$

Temos

$$\mathbf{u}^T \mathbf{v} = 3(-4) + 4(3) = 0.$$

Logo, os vetores são ortogonais. Além disso,

$$\|\mathbf{u}\|_2 = \sqrt{3^2 + 4^2} = 5, \quad \|\mathbf{v}\|_2 = \sqrt{(-4)^2 + 3^2} = 5.$$

Os vetores normalizados são

$$\mathbf{q}_1 = \frac{1}{5} \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{5} \begin{bmatrix} -4 \\ 3 \end{bmatrix}.$$

Eles satisfazem

$$\mathbf{q}_1^T \mathbf{q}_2 = 0, \quad \|\mathbf{q}_1\|_2 = \|\mathbf{q}_2\|_2 = 1.$$

Portanto, $\mathbf{q}_1$ e $\mathbf{q}_2$ formam um par ortonormal.

3. Normas de vetores

Embora a norma euclidiana seja a mais geométrica, outras normas aparecem em aprendizado de máquina, otimização e cálculo numérico. Para $\mathbf{x} \in \mathbb{R}^n$, as três normas mais comuns são

$$\begin{aligned} \|\mathbf{x}\|_1 &= \sum_{i=1}^n |x_i|, \\ \|\mathbf{x}\|_2 &= \left(\sum_{i=1}^n x_i^2 \right)^{1/2}, \\ \|\mathbf{x}\|_\infty &= \max_{1 \leq i \leq n} |x_i|. \end{aligned}$$

A norma ℓ_1 soma magnitudes. Ela será importante quando falarmos de esparsidade, pois penaliza a presença de muitos coeficientes não nulos. A norma ℓ_2 mede comprimento euclidiano e aparece em mínimos quadrados, energia e erro quadrático. A norma ℓ_∞ mede o maior erro componente a componente.

Exemplo 2. Para

$$\mathbf{x} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix},$$

temos

$$\begin{aligned} \|\mathbf{x}\|_1 &= |2| + |-1| + |3| = 6, \\ \|\mathbf{x}\|_2 &= \sqrt{2^2 + (-1)^2 + 3^2} = \sqrt{14}, \\ \|\mathbf{x}\|_\infty &= \max\{2, 1, 3\} = 3. \end{aligned}$$

As três normas medem o tamanho do mesmo vetor, mas respondem a perguntas diferentes. A norma ℓ_1 mede soma total de amplitudes, a norma ℓ_2 mede comprimento geométrico e a norma

ℓ_∞ mede a maior componente individual.

4. Matrizes ortogonais

Uma matriz $Q \in \mathbb{R}^{n \times n}$ é chamada de ortogonal quando

$$Q^T Q = I.$$

Essa definição significa que as colunas de Q formam uma base ortonormal de $\mathbb{R}^n$. Se

$$Q = \begin{bmatrix} | & | & & | \\ \mathbf{q}_1 & \mathbf{q}_2 & \cdots & \mathbf{q}_n \\ | & | & & | \end{bmatrix},$$

então a igualdade $Q^T Q = I$ equivale a

$$\mathbf{q}_i^T \mathbf{q}_j = \delta_{ij},$$

onde δ_{ij} é igual a 1 quando $i = j$ e igual a 0 quando $i \neq j$.

Da igualdade $Q^T Q = I$, segue que

$$Q^{-1} = Q^T.$$

Essa propriedade é algébrica e computacionalmente importante: inverter uma matriz ortogonal é apenas transpor a matriz.

O fato mais importante é que matrizes ortogonais preservam produtos internos. Para quaisquer $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$,

$$(Q\mathbf{x})^T (Q\mathbf{y}) = \mathbf{x}^T Q^T Q \mathbf{y} = \mathbf{x}^T \mathbf{y}.$$

Como consequência, preservam normas:

$$\|Q\mathbf{x}\|_2^2 = (Q\mathbf{x})^T (Q\mathbf{x}) = \mathbf{x}^T Q^T Q \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|_2^2.$$

Portanto,

$$\|Q\mathbf{x}\|_2 = \|\mathbf{x}\|_2.$$

Geometricamente, matrizes ortogonais representam rotações, reflexões ou combinações dessas operações. Elas podem mudar a orientação de um vetor, mas não mudam comprimentos nem ângulos.

Exemplo 3. A matriz de rotação no plano é

$$R(\theta) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

Suas colunas são

$$\mathbf{r}_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}, \quad \mathbf{r}_2 = \begin{bmatrix} -\sin \theta \\ \cos \theta \end{bmatrix}.$$

Calculando,

$$\|\mathbf{r}_1\|_2^2 = \cos^2 \theta + \sin^2 \theta = 1,$$

$$\|\mathbf{r}_2\|_2^2 = \sin^2 \theta + \cos^2 \theta = 1,$$

e

$$\mathbf{r}_1^T \mathbf{r}_2 = -\cos \theta \sin \theta + \sin \theta \cos \theta = 0.$$

Logo, as colunas são ortonormais e

$$R(\theta)^T R(\theta) = I.$$

Assim, $R(\theta)$ é ortogonal.

Essa discussão será retomada na SVD. A interpretação geométrica da SVD é justamente decompor uma transformação linear em uma rotação ou reflexão, seguida de estiramentos em direções principais, seguida de outra rotação ou reflexão.

5. Autovalores e autovetores

Seja $A \in \mathbb{R}^{n \times n}$. Um vetor não nulo $\mathbf{v} \in \mathbb{R}^n$ é um autovetor de A se existe um escalar λ tal que

$$A\mathbf{v} = \lambda\mathbf{v}.$$

O escalar λ é o autovalor associado ao autovetor $\mathbf{v}$.

A condição $\mathbf{v} \neq \mathbf{0}$ é indispensável. O vetor nulo satisfaz $A\mathbf{0} = \lambda\mathbf{0}$ para qualquer λ , mas não possui direção. Um autovetor representa uma direção especial da transformação.

A equação

$$A\mathbf{v} = \lambda\mathbf{v}$$

diz que $A\mathbf{v}$ permanece na mesma reta gerada por $\mathbf{v}$. A matriz pode alongar, comprimir, inverter ou anular essa direção, mas não a desvia para outra reta. O autovalor mede o fator de escala nessa direção.

Se $\lambda > 1$, a direção é alongada. Se $0 < \lambda < 1$, é comprimida. Se $\lambda < 0$, a direção é invertida e escalada. Se $\lambda = 0$, a direção é destruída: o autovetor vai para o vetor nulo.

Para uma matriz genérica, um vetor qualquer muda de direção. Os autovetores são as direções particulares nas quais a transformação se comporta como uma simples multiplicação

por escalar.

Exemplo 4. Considere a matriz diagonal

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}.$$

Para os vetores canônicos

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

temos

$$A\mathbf{e}_1 = \begin{bmatrix} 3 \\ 0 \end{bmatrix} = 3\mathbf{e}_1, \quad A\mathbf{e}_2 = \begin{bmatrix} 0 \\ 2 \end{bmatrix} = 2\mathbf{e}_2.$$

Portanto, $\mathbf{e}_1$ e $\mathbf{e}_2$ são autovetores, com autovalores 3 e 2. A matriz estica a direção horizontal por 3 e a direção vertical por 2.

Exemplo 5. Considere agora

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Essa matriz mistura as duas coordenadas, mas ainda possui direções especiais. Para

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

temos

$$A\mathbf{v}_1 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} = 3\mathbf{v}_1.$$

Logo, $\mathbf{v}_1$ é autovetor associado a $\lambda_1 = 3$.

Para

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

temos

$$A\mathbf{v}_2 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 1\mathbf{v}_2.$$

Logo, $\mathbf{v}_2$ é autovetor associado a $\lambda_2 = 1$.

A matriz mistura coordenadas na base canônica, mas fica simples nas direções $(1, 1)$ e $(1, -1)$. Essa é a ideia que sustenta a diagonalização: procurar uma base na qual a transformação tenha a forma mais simples possível.

6. Cálculo de autovalores e autovetores

A equação de autovalor é

$$A\mathbf{v} = \lambda\mathbf{v}.$$

Como $\lambda\mathbf{v} = \lambda I\mathbf{v}$, podemos escrever

$$(A - \lambda I)\mathbf{v} = \mathbf{0}.$$

Para existir autovetor não nulo, o sistema homogêneo acima precisa ter solução não trivial. Isso ocorre quando $A - \lambda I$ é singular. Para matrizes quadradas, essa condição é

$$\det(A - \lambda I) = 0.$$

Essa é a equação característica. O polinômio

$$p(\lambda) = \det(A - \lambda I)$$

é o polinômio característico.

Depois de encontrar um autovalor λ , os autovetores associados são os vetores não nulos do espaço nulo de $A - \lambda I$:

$$\mathbf{v} \in \text{Nul}(A - \lambda I), \quad \mathbf{v} \neq \mathbf{0}.$$

Para uma matriz 2×2 ,

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

temos

$$A - \lambda I = \begin{bmatrix} a - \lambda & b \\ c & d - \lambda \end{bmatrix}.$$

Logo,

$$\det(A - \lambda I) = (a - \lambda)(d - \lambda) - bc.$$

Expandindo,

$$\det(A - \lambda I) = \lambda^2 - (a + d)\lambda + (ad - bc).$$

Como

$$\text{tr}(A) = a + d, \quad \det(A) = ad - bc,$$

segue que os autovalores de uma matriz 2×2 satisfazem

$$\lambda^2 - \text{tr}(A)\lambda + \det(A) = 0.$$

Assim, a soma dos autovalores é o traço e o produto dos autovalores é o determinante:

$$\lambda_1 + \lambda_2 = \text{tr}(A), \quad \lambda_1 \lambda_2 = \det(A).$$

Essas relações são úteis para verificar contas, mas não substituem o cálculo dos autovetores. Mais geralmente, para qualquer matriz $n \times n$ valem

$$\sum_{i=1}^n \lambda_i = \text{tr}(A), \quad \prod_{i=1}^n \lambda_i = \det(A),$$

contando os autovalores com multiplicidade.

Exemplo 6. Para

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

temos

$$A - \lambda I = \begin{bmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix}.$$

Logo,

$$\det(A - \lambda I) = (2 - \lambda)^2 - 1.$$

A equação característica é

$$(2 - \lambda)^2 - 1 = 0.$$

Então

$$(2 - \lambda)^2 = 1, \quad 2 - \lambda = \pm 1.$$

Portanto,

$$\lambda_1 = 3, \quad \lambda_2 = 1.$$

Para $\lambda_1 = 3$,

$$A - 3I = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix}.$$

O sistema

$$(A - 3I)\mathbf{v} = \mathbf{0}$$

fornece

$$-v_1 + v_2 = 0,$$

isto é,

$$v_2 = v_1.$$

Uma escolha simples é

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para $\lambda_2 = 1$,

$$A - I = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

O sistema

$$(A - I)\mathbf{v} = \mathbf{0}$$

fornece

$$v_1 + v_2 = 0,$$

isto é,

$$v_2 = -v_1.$$

Uma escolha simples é

$$\mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Autovetores não são únicos. Qualquer múltiplo não nulo de um autovetor continua sendo autovetor. O que importa é a direção.

7. Autovalor zero, singularidade e espaço nulo

O autovalor zero merece atenção especial. Se

$$A\mathbf{v} = 0\mathbf{v} = \mathbf{0}$$

para algum $\mathbf{v} \neq \mathbf{0}$, então

$$\mathbf{v} \in \text{Nul}(A).$$

Logo, 0 é autovalor de A se e somente se A possui espaço nulo não trivial. Para uma matriz quadrada, isso equivale a dizer que A é singular, isto é, não possui inversa.

Essa observação conecta a aula atual diretamente à aula anterior. Uma matriz quadrada tem autovalor zero quando destrói alguma direção não nula de entrada. Nesse caso, ela perde informação e seu posto é menor que n .

Exemplo 7. Considere

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}.$$

As colunas são dependentes, pois

$$\begin{bmatrix} 2 \\ 4 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Logo, $\text{rank}(A) = 1$ e a matriz não é invertível.

O polinômio característico é

$$\det(A - \lambda I) = \det \begin{bmatrix} 1 - \lambda & 2 \\ 2 & 4 - \lambda \end{bmatrix}.$$

Calculando,

$$\det(A - \lambda I) = (1 - \lambda)(4 - \lambda) - 4 = \lambda^2 - 5\lambda.$$

Portanto,

$$\lambda(\lambda - 5) = 0.$$

Os autovalores são

$$\lambda_1 = 5, \quad \lambda_2 = 0.$$

Para $\lambda = 0$, os autovetores satisfazem

$$A\mathbf{v} = \mathbf{0}.$$

Isso fornece

$$v_1 + 2v_2 = 0.$$

Tomando $v_2 = 1$, obtemos

$$\mathbf{v} = \begin{bmatrix} -2 \\ 1 \end{bmatrix}.$$

Assim,

$$\text{Nul}(A) = \text{span} \left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right\}.$$

A direção $(-2, 1)$ é destruída pela matriz. Essa é a interpretação geométrica do autovalor zero.

8. Diagonalização

Suponha que $A \in \mathbb{R}^{n \times n}$ possua n autovetores linearmente independentes,

$$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n,$$

associados aos autovalores

$$\lambda_1, \lambda_2, \dots, \lambda_n.$$

Reunimos os autovetores nas colunas de uma matriz

$$V = \begin{bmatrix} | & | & & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \\ | & | & & | \end{bmatrix}$$

e os autovalores em uma matriz diagonal

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

Como

$$A\mathbf{v}_j = \lambda_j \mathbf{v}_j,$$

então, coluna a coluna,

$$AV = V\Lambda.$$

Se os autovetores são linearmente independentes, V é invertível. Logo,

$$A = V\Lambda V^{-1}.$$

Essa fatoração é chamada de diagonalização.

O significado da diagonalização é mais importante que a fórmula. Na base original, A pode misturar coordenadas. Na base dos autovetores, a transformação fica diagonal: cada coordenada é multiplicada por um autovalor e não interfere nas demais. A matriz deixa de ser uma transformação acoplada e passa a ser uma coleção de escalamentos independentes.

Exemplo 8. Para

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

encontramos

$$\lambda_1 = 3, \quad \mathbf{v}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \lambda_2 = 1, \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Assim,

$$V = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

Vamos verificar $AV = V\Lambda$. Primeiro,

$$AV = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 3 & -1 \end{bmatrix}.$$

Por outro lado,

$$V\Lambda = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 3 & -1 \end{bmatrix}.$$

Portanto,

$$AV = V\Lambda.$$

Como

$$\det(V) = -2 \neq 0,$$

a matriz V é invertível e

$$A = V\Lambda V^{-1}.$$

A diagonalização simplifica potências da matriz. Se

$$A = V\Lambda V^{-1},$$

então

$$A^2 = V\Lambda V^{-1}V\Lambda V^{-1} = V\Lambda^2 V^{-1}.$$

Por repetição,

$$A^k = V\Lambda^k V^{-1}.$$

Como Λ é diagonal,

$$\Lambda^k = \text{diag}(\lambda_1^k, \lambda_2^k, \dots, \lambda_n^k).$$

Por isso, autovalores controlam o crescimento ou decaimento de sistemas lineares discretos como

$$\mathbf{x}_{k+1} = A\mathbf{x}_k.$$

A solução é

$$\mathbf{x}_k = A^k \mathbf{x}_0,$$

e o comportamento de longo prazo depende das potências dos autovalores.

Nem toda matriz é diagonalizável. A construção acima pressupõe a existência de n autovetores linearmente independentes. Convém distinguir duas multiplicidades de um autovalor: a *multiplicidade algébrica* é o número de vezes que ele aparece como raiz do polinômio característico; a *multiplicidade geométrica* é a dimensão do espaço de autovetores associado, $\dim \text{Nul}(A - \lambda I)$, com a geométrica sempre entre 1 e a algébrica. Quando a multiplicidade geométrica de algum autovalor é menor que a sua multiplicidade algébrica, faltam autovetores para formar uma base de $\mathbb{R}^n$, e a matriz V não pode ser invertida. Nesse caso, a matriz é dita defeituosa e não admite diagonalização. Um exemplo é

$$A = \begin{bmatrix} 3 & 1 \\ 0 & 3 \end{bmatrix},$$

que possui o único autovalor 3, mas apenas uma direção de autovetores. A diagonalização, portanto, não é garantida para qualquer matriz: ela depende de haver autovetores independentes em quantidade suficiente.

9. Matrizes simétricas e decomposição espectral

Uma matriz $A \in \mathbb{R}^{n \times n}$ é simétrica quando

$$A^T = A.$$

Matrizes simétricas aparecem com frequência em problemas físicos e computacionais: matrizes de covariância, matrizes de energia, matrizes de rigidez em problemas mecânicos, matrizes de Gram, matrizes $A^T A$ e operadores discretizados de difusão em certas formulações.

O resultado central é o teorema espectral para matrizes reais simétricas, que admitiremos aqui sem demonstração: toda matriz real simétrica possui autovalores reais e uma base

ortonormal de autovetores.¹ Portanto, se $A = A^T$, podemos escrever

$$A = Q\Lambda Q^T,$$

onde Q é ortogonal e Λ é diagonal real.

Essa forma é a decomposição espectral. Ela é uma versão particularmente bem comportada da diagonalização. Na diagonalização geral,

$$A = V\Lambda V^{-1}.$$

No caso simétrico, a matriz de autovetores V da diagonalização geral pode ser escolhida ortogonal, e passamos a chamá-la Q :

$$V = Q \quad \text{e} \quad V^{-1} = Q^T.$$

Ou seja, a mesma fatoração $A = V\Lambda V^{-1}$ da seção anterior torna-se $A = Q\Lambda Q^T$, com a mudança de base sendo agora uma transformação ortogonal, que preserva comprimentos e ângulos.

Exemplo 9. Retomemos

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Essa matriz é simétrica. Os autovetores encontrados foram

$$\begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Eles são ortogonais, pois

$$\begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0.$$

Normalizando,

$$\mathbf{q}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{q}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Logo,

$$Q = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \Lambda = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

A decomposição espectral é

$$A = Q\Lambda Q^T.$$

Verifiquemos a reconstrução:

$$Q\Lambda = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 3 & 1 \\ 3 & -1 \end{bmatrix}.$$

¹STRANG, G. *Introduction to Linear Algebra*. 6. ed. Wellesley-Cambridge Press, 2023.

Então

$$Q\Lambda Q^T = \frac{1}{2} \begin{bmatrix} 3 & 1 \\ 3 & -1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 4 & 2 \\ 2 & 4 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

A decomposição espectral também pode ser escrita como soma de matrizes de posto 1:

$$A = \lambda_1 \mathbf{q}_1 \mathbf{q}_1^T + \lambda_2 \mathbf{q}_2 \mathbf{q}_2^T + \cdots + \lambda_n \mathbf{q}_n \mathbf{q}_n^T.$$

No exemplo,

$$A = 3\mathbf{q}_1 \mathbf{q}_1^T + 1\mathbf{q}_2 \mathbf{q}_2^T.$$

Essa forma antecipa a próxima aula. A SVD também escreverá matrizes como soma de contribuições elementares de posto 1, ordenadas por sua importância.

10. A interpretação geométrica da decomposição espectral

Para uma matriz simétrica, a decomposição

$$A = Q\Lambda Q^T$$

pode ser lida da direita para a esquerda. Primeiro, Q^T expressa o vetor na base ortonormal dos autovetores. Em seguida, Λ escala cada coordenada por um autovalor. Por fim, Q retorna o vetor à base original.

Assim, a ação de A pode ser entendida como três operações sucessivas:

mudar para a base dos autovetores
 $\longrightarrow$ escalar cada direção
 $\longrightarrow$ voltar à base original.

Essa leitura evidencia que uma matriz simétrica não mistura permanentemente as direções: existe uma base ortonormal em que sua ação é completamente desacoplada. Essa é a razão pela qual matrizes simétricas são tão importantes em ciência de dados. Matrizes de covariância, por exemplo, têm autovetores que indicam direções principais de variação e autovalores que medem a intensidade dessa variação.

11. Norma de Frobenius

Assim como uma norma vetorial mede o tamanho de um vetor, uma norma matricial mede o tamanho de uma matriz. A norma de Frobenius de $A \in \mathbb{R}^{m \times n}$ é

$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 \right)^{1/2}.$$

Ela é a norma euclidiana aplicada à lista de todas as entradas da matriz. Também pode ser escrita como

$$\|A\|_F = \sqrt{\text{tr}(A^T A)}.$$

A norma de Frobenius será importante quando medirmos erro global de aproximação de matrizes. Por exemplo, se A é uma matriz de dados e A_k é uma aproximação de posto baixo, então

$$\|A - A_k\|_F$$

mede o erro total entre a matriz original e sua aproximação.

Exemplo 10. Para

$$A = \begin{bmatrix} 1 & 2 & 0 \\ 0 & -1 & 3 \end{bmatrix},$$

temos

$$\|A\|_F = \sqrt{1^2 + 2^2 + 0^2 + 0^2 + (-1)^2 + 3^2} = \sqrt{15}.$$

Agora,

$$A^T A = \begin{bmatrix} 1 & 0 \\ 2 & -1 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 & 0 \\ 0 & -1 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 5 & -3 \\ 0 & -3 & 9 \end{bmatrix}.$$

Logo,

$$\text{tr}(A^T A) = 1 + 5 + 9 = 15$$

e, portanto,

$$\|A\|_F = \sqrt{\text{tr}(A^T A)} = \sqrt{15}.$$

12. Norma espectral

A norma espectral de uma matriz $A \in \mathbb{R}^{m \times n}$ é definida por

$$\|A\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|_2}{\|\mathbf{x}\|_2}.$$

De forma equivalente,

$$\|A\|_2 = \max_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2.$$

Essa definição mede o maior fator de amplificação que A pode produzir em um vetor. Se $\|A\|_2 = 10$, existe uma direção unitária que é ampliada por fator 10, e nenhuma direção é ampliada por fator maior que 10.

Para conectar essa definição a autovalores, observamos que

$$\|A\mathbf{x}\|_2^2 = (A\mathbf{x})^T (A\mathbf{x}) = \mathbf{x}^T A^T A \mathbf{x}.$$

A matriz $A^T A$ é sempre simétrica e, além disso, semidefinida positiva, pois

$$\mathbf{x}^T A^T A \mathbf{x} = \|A\mathbf{x}\|_2^2 \geq 0$$

para todo $\mathbf{x}$; logo, seus autovalores são reais e não negativos ($\lambda \geq 0$), o que garante a raiz real. Pelo teorema espectral, $A^T A = Q\Lambda Q^T$ com Q ortogonal; pondo $\mathbf{y} = Q^T \mathbf{x}$, que preserva a norma, a forma quadrática torna-se $\sum_i \lambda_i y_i^2$, cujo máximo sobre vetores unitários é exatamente $\lambda_{\max}(A^T A)$, atingido na direção do autovetor correspondente. Portanto,

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}.$$

Na próxima aula, veremos que os números

$$\sigma_i = \sqrt{\lambda_i(A^T A)}$$

são os valores singulares de A . Assim, a norma espectral será o maior valor singular:

$$\|A\|_2 = \sigma_1.$$

Quando A é simétrica, há uma relação ainda mais direta. Se

$$A = Q\Lambda Q^T,$$

então

$$\|A\|_2 = \max_i |\lambda_i|.$$

Isto é, para matrizes simétricas, a norma espectral é o maior módulo entre os autovalores.

Exemplo 11. Considere

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}.$$

A norma de Frobenius é

$$\|A\|_F = \sqrt{3^2 + 0^2 + 0^2 + 2^2} = \sqrt{13}.$$

Para a norma espectral,

$$A^T A = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 9 & 0 \\ 0 & 4 \end{bmatrix}.$$

Os autovalores de $A^T A$ são 9 e 4. Logo,

$$\|A\|_2 = \sqrt{9} = 3.$$

Geometricamente, a matriz alonga uma direção por 3 e outra por 2. A maior amplificação possível é 3.

Exemplo 12. Considere a matriz de cisalhamento

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}.$$

A norma de Frobenius é

$$\|A\|_F = \sqrt{1^2 + 2^2 + 0^2 + 1^2} = \sqrt{6}.$$

Para calcular a norma espectral,

$$A^T A = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 5 \end{bmatrix}.$$

O polinômio característico de $A^T A$ é

$$\det \begin{bmatrix} 1 - \lambda & 2 \\ 2 & 5 - \lambda \end{bmatrix} = (1 - \lambda)(5 - \lambda) - 4.$$

Expandindo,

$$(1 - \lambda)(5 - \lambda) - 4 = \lambda^2 - 6\lambda + 1.$$

Logo,

$$\lambda = \frac{6 \pm \sqrt{36 - 4}}{2} = 3 \pm 2\sqrt{2}.$$

O maior autovalor é

$$\lambda_{\max} = 3 + 2\sqrt{2}.$$

Portanto,

$$\|A\|_2 = \sqrt{3 + 2\sqrt{2}} = 1 + \sqrt{2}.$$

Esse exemplo mostra que a maior amplificação não precisa ocorrer ao longo de um eixo coordenado. Em matrizes não diagonais, a direção de maior alongamento é determinada pelos autovetores de $A^T A$, não necessariamente pelas colunas ou pelos eixos originais.

13. Síntese da aula

Esta aula olhou a matriz como transformação. Autovalores e autovetores revelam direções invariantes, nas quais a ação se reduz a um escalamento; a diagonalização $A = V\Lambda V^{-1}$ desacopla essas direções e, no caso simétrico, a decomposição espectral $A = Q\Lambda Q^T$ torna essa base ortogonal, escrevendo A como soma de contribuições de posto um ordenadas pelos autovalores. As normas de Frobenius e espectral medem o tamanho de uma matriz e o seu maior fator de amplificação, com $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$. Na Aula 4, esses fios se unem na decomposição em valores singulares (SVD): $A = U\Sigma V^T$ generaliza a decomposição espectral para matrizes retangulares e fornece a melhor aproximação de baixo posto, base de PCA e POD.

14. Exercícios propostos

Exercício 1. Considere

$$A = \begin{bmatrix} 4 & 0 \\ 0 & -2 \end{bmatrix}.$$

Determine os autovalores e autovetores de A . Interprete geometricamente o efeito da matriz sobre as direções dos eixos coordenados.

Exercício 2. Para

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix},$$

calcule o polinômio característico, os autovalores e uma base de autovetores. Verifique se os autovetores associados a autovalores distintos são ortogonais.

Exercício 3. Considere

$$A = \begin{bmatrix} 3 & 1 \\ 0 & 3 \end{bmatrix}.$$

Calcule o autovalor de A e determine o espaço de autovetores associado. A matriz possui dois autovetores linearmente independentes? Ela é diagonalizável?

Exercício 4. Seja

$$Q = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 & -2 \\ 2 & 1 \end{bmatrix}.$$

Verifique que $Q^T Q = I$. Em seguida, mostre que $\|Q\mathbf{x}\|_2 = \|\mathbf{x}\|_2$ para

$$\mathbf{x} = \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

Exercício 5. Considere

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}.$$

Calcule $A^T A$, encontre os autovalores de $A^T A$ e determine $\|A\|_2$. Calcule também $\|A\|_F$. Em seguida, verifique os resultados em Python.

15. Referências

- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.
- STRANG, G. *Introduction to Linear Algebra*. 6. ed. Wellesley-Cambridge Press, 2023.