

## Aula 4 — SVD: definição e interpretação geométrica

Valores singulares, vetores singulares, SVD econômica e relação com  $A^T A$

Prof. Dr. Rodrigo Figueiredo Abdo

### 1. Ideia central da aula

Nas duas aulas anteriores, a álgebra linear foi organizada em torno de duas perguntas complementares. A primeira foi: que vetores podem ser produzidos por uma matriz? Essa pergunta levou ao espaço coluna, ao espaço nulo e ao posto. A segunda foi: existem direções que uma matriz transforma sem mudar de direção? Essa pergunta levou a autovalores, autovetores e decomposição espectral.

A decomposição espectral é poderosa, mas tem limitações. Ela exige uma matriz quadrada e, em sua forma mais simples e geometricamente limpa, funciona muito bem para matrizes simétricas. No entanto, em ciência de dados e em mecânica dos fluidos computacional, as matrizes que aparecem nem sempre são quadradas. Um conjunto de dados pode ter milhares de graus de liberdade espaciais e apenas algumas centenas de amostras no tempo. Uma matriz de snapshots pode ter a forma

$$X = \begin{bmatrix} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_m \\ | & | & & | \end{bmatrix} \in \mathbb{R}^{n \times m},$$

onde cada coluna  $\mathbf{x}_k$  representa uma medição, uma imagem, um campo de velocidade discretizado ou um estado físico em um instante de tempo.

A pergunta da aula é: existe uma decomposição que funcione para qualquer matriz real, quadrada ou retangular, e que ainda preserve uma interpretação geométrica clara?

A resposta é a decomposição em valores singulares, ou *Singular Value Decomposition*, usualmente abreviada por SVD. A SVD é uma das decomposições matriciais mais importantes da matemática computacional moderna. Ela permite interpretar uma matriz como uma sequência de três operações: uma mudança ortogonal de coordenadas no espaço de entrada, um estiramento ou compressão em direções coordenadas e uma mudança ortogonal de coordenadas no espaço de saída.

Nesta aula, o objetivo não é ainda discutir truncamento ótimo, compressão ou denoising. Esses temas dependem da SVD truncada e do teorema de Eckart–Young. O objetivo aqui é mais fundamental: entender o que é a SVD, o que significam seus fatores e por que ela deve ser vista como a decomposição geométrica natural de uma matriz geral.

## 2. Da decomposição espectral para a SVD

Para uma matriz quadrada diagonalizável  $A \in \mathbb{R}^{n \times n}$ , a diagonalização escreve

$$A = V\Lambda V^{-1},$$

onde as colunas de  $V$  são autovetores e os elementos diagonais de  $\Lambda$  são autovalores. Quando  $A$  é simétrica, a situação fica particularmente simples e recebe o nome de *decomposição espectral* (Aula 3):

$$A = Q\Lambda Q^T,$$

com  $Q$  ortogonal. Nesse caso, a matriz  $A$  atua esticando ou comprimindo o espaço ao longo de direções ortogonais.

O problema é que essa descrição não serve para todas as matrizes. Se  $A$  é retangular, a equação de autovalores

$$A\mathbf{v} = \lambda\mathbf{v}$$

sempre faz sentido em geral, pois  $A\mathbf{v}$  e  $\mathbf{v}$  podem pertencer a espaços de dimensões diferentes. Se  $A \in \mathbb{R}^{m \times n}$ , então

$$\mathbf{v} \in \mathbb{R}^n, \quad A\mathbf{v} \in \mathbb{R}^m.$$

Portanto, uma matriz retangular transforma vetores de um espaço em vetores de outro espaço. A SVD respeita exatamente essa estrutura: ela usa uma base ortonormal no espaço de entrada  $\mathbb{R}^n$  e outra base ortonormal no espaço de saída  $\mathbb{R}^m$ .

A ideia central é substituir a pergunta dos autovalores,

$$A\mathbf{v} = \lambda\mathbf{v},$$

por uma pergunta mais geral:

$$A\mathbf{v}_i = \sigma_i\mathbf{u}_i.$$

Aqui,  $\mathbf{v}_i$  é uma direção no espaço de entrada,  $\mathbf{u}_i$  é uma direção no espaço de saída e  $\sigma_i \geq 0$  mede quanto a matriz estica essa direção. Essa é a essência da SVD.

## 3. Enunciado da SVD

Seja

$$A \in \mathbb{R}^{m \times n}.$$

Então existem matrizes ortogonais

$$U \in \mathbb{R}^{m \times m}, \quad V \in \mathbb{R}^{n \times n},$$

e uma matriz diagonal retangular

$$\Sigma \in \mathbb{R}^{m \times n}$$

tais que

$$A = U\Sigma V^T.$$

Essa fatora  o   chamada de decomposi  o em valores singulares de  $A$ .

As matrizes  $U$  e  $V$  satisfazem

$$U^T U = U U^T = I_m, \quad V^T V = V V^T = I_n.$$

As colunas de  $U$  s o chamadas de vetores singulares   esquerda de  $A$ . As colunas de  $V$  s o chamadas de vetores singulares   direita de  $A$ . A matriz  $\Sigma$  possui entradas n o negativas na diagonal principal e zeros fora dela:

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & \cdots \\ 0 & \sigma_2 & 0 & \cdots \\ 0 & 0 & \sigma_3 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix},$$

com

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_p \geq 0, \quad p = \min\{m, n\}.$$

O arranjo acima   esquem tico: como  $\Sigma \in \mathbb{R}^{m \times n}$ , al m dos  $p = \min\{m, n\}$  valores singulares na diagonal, h  um bloco de zeros que completa as dimens es  $m \times n$  (linhas extras de zeros se  $m > n$ , colunas extras de zeros se  $m < n$ ). Os n meros  $\sigma_i$  s o os valores singulares de  $A$ .

H  tr s informa  es importantes nesse enunciado. Primeiro, a SVD existe para qualquer matriz real. Segundo, os valores singulares s o sempre n o negativos. Terceiro, as bases envolvidas s o ortonormais, o que preserva a interpreta  o geom trica de comprimento,  ngulo e proje  o.

A forma

$$A = U\Sigma V^T$$

deve ser lida da direita para a esquerda. Dado um vetor  $\mathbf{x} \in \mathbb{R}^n$ , temos

$$A\mathbf{x} = U\Sigma V^T \mathbf{x}.$$

A opera  o  $V^T \mathbf{x}$  reescreve  $\mathbf{x}$  nas coordenadas da base  $\mathbf{v}_1, \dots, \mathbf{v}_n$ . A opera  o  $\Sigma$  estica ou comprime cada coordenada por  $\sigma_i$ . Por fim, a opera  o  $U$  escreve o resultado na base de sa da  $\mathbf{u}_1, \dots, \mathbf{u}_m$ .

A express o mais importante para interpretar a SVD  

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i, \quad 1 \leq i \leq p = \min\{m, n\}.$$

Ela diz que a direção de entrada  $\mathbf{v}_i$  é levada pela matriz  $A$  à direção de saída  $\mathbf{u}_i$ , com fator de escala  $\sigma_i$ . Duas ressalvas sobre a faixa de índices. Para  $i > p$  não há  $\sigma_i$  nem  $\mathbf{u}_i$  definidos; o que vale, nesse caso, é  $A\mathbf{v}_i = \mathbf{0}$ . E quando  $\sigma_i = 0$  a relação se reduz a  $A\mathbf{v}_i = \mathbf{0}$ , de modo que ela *não determina*  $\mathbf{u}_i$  — por isso o procedimento de construção precisa, ao final, completar  $U$  com uma base ortonormal do complemento.

Vale notar que a SVD não é única: trocar o sinal de um par  $(\mathbf{u}_i, \mathbf{v}_i)$  ou reordenar vetores singulares associados a valores singulares iguais produz outra SVD válida. Únicos, de fato, são os valores singulares  $\sigma_i$ .

## 4. Interpretação geométrica: rotação, estiramento e rotação

A SVD permite interpretar qualquer matriz como uma sequência de três operações geométricas:

$$A = U\Sigma V^T.$$

A matriz  $V^T$  representa uma rotação ou reflexão no espaço de entrada. A matriz  $\Sigma$  representa um estiramento, uma compressão ou uma anulação ao longo dos eixos coordenados. A matriz  $U$  representa uma rotação ou reflexão no espaço de saída.

Em linguagem geométrica:

$$\text{entrada} \xrightarrow{V^T} \text{coordenadas singulares} \xrightarrow{\Sigma} \text{eixos esticados} \xrightarrow{U} \text{saída}.$$

Essa interpretação é mais precisa quando pensamos na imagem da esfera unitária. Considere todos os vetores  $\mathbf{x} \in \mathbb{R}^n$  com

$$\|\mathbf{x}\|_2 = 1.$$

Como  $V$  é ortogonal, qualquer vetor unitário pode ser escrito como

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_n \mathbf{v}_n,$$

com

$$\alpha_1^2 + \alpha_2^2 + \cdots + \alpha_n^2 = 1.$$

Aplicando  $A$ , temos


$$A\mathbf{x} = A \left( \sum_{i=1}^n \alpha_i \mathbf{v}_i \right) = \sum_{i=1}^n \alpha_i A\mathbf{v}_i.$$

Como  $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$  para  $i \leq p$ , e  $A\mathbf{v}_i = \mathbf{0}$  para  $i > p$ , segue que

$$A\mathbf{x} = \sum_{i=1}^p \sigma_i \alpha_i \mathbf{u}_i,$$

onde  $p = \min\{m, n\}$ , e os termos associados a valores singulares nulos não contribuem.

Portanto, a esfera unitária no espaço de entrada é transformada em uma elipse, ou em um elipsoide, no espaço de saída. Os eixos principais desse elipsoide são as direções  $\mathbf{u}_i$ , e os comprimentos dos semieixos são os valores singulares  $\sigma_i$ . Uma ressalva sobre essa imagem: ela vale como *superfície* de um elipsoide quando  $A$  é injetiva, isto é, quando  $r = n$  (o que exige  $m \geq n$ ). Se  $A$  tem núcleo não trivial, a esfera colapsa nas direções anuladas e a imagem é um elipsoide degenerado: um elipsoide *sólido* de dimensão  $r$ , achatado dentro de  $\mathbb{R}^m$  quando  $r < m$ , e preenchendo um volume  $m$ -dimensional quando  $r = m$  (o que exige  $n > m$ ).



Essa figura resume a interpretação geométrica da SVD. A matriz  $A$  transforma a esfera unitária em um elipsoide. O maior valor singular  $\sigma_1$  é o maior estiramento possível produzido por  $A$ . O segundo valor singular  $\sigma_2$  é o maior estiramento possível em uma direção ortogonal à primeira, e assim sucessivamente.

Em particular, o maior valor singular coincide com a norma espectral introduzida na Aula 3:

$$\|A\|_2 = \sigma_1.$$

Analogamente, a norma de Frobenius relaciona-se aos valores singulares por  $\|A\|_F = \sqrt{\sigma_1^2 + \cdots + \sigma_p^2}$ .

Se algum valor singular é zero, a matriz colapsa uma direção. Isso significa que existe uma direção de entrada que é enviada ao vetor nulo. Em termos de espaços fundamentais, essa direção pertence ao espaço nulo de  $A$ .

## 5. Exemplo simples: matriz diagonal

Considere

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}.$$

Essa matriz já está na forma de uma SVD:

$$A = I \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} I^T.$$

Logo,

$$U = I, \quad \Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}, \quad V = I.$$

Os valores singulares são

$$\sigma_1 = 3, \quad \sigma_2 = 1.$$

As direções singulares de entrada e saída são os próprios vetores da base canônica:

$$\mathbf{v}_1 = \mathbf{u}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \mathbf{u}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

Assim,

$$A\mathbf{v}_1 = 3\mathbf{u}_1, \quad A\mathbf{v}_2 = 1\mathbf{u}_2.$$

Geometricamente, o círculo unitário é transformado em uma elipse com semieixo maior igual a 3 na direção horizontal e semieixo menor igual a 1 na direção vertical.

Esse exemplo é simples porque a matriz já está alinhada com os eixos coordenados. A SVD se torna mais interessante quando a matriz mistura direções. Nesse caso,  $V^T$  primeiro encontra os eixos corretos de entrada,  $\Sigma$  estica esses eixos, e  $U$  reposiciona o resultado no espaço de saída.

## 6. Relação com $A^T A$ e $AA^T$

A SVD tem uma relação direta com autovalores e autovetores. Suponha

$$A = U\Sigma V^T.$$

Então

$$A^T = V\Sigma^T U^T.$$

Multiplicando,

$$A^T A = (V\Sigma^T U^T)(U\Sigma V^T).$$

Como  $U^T U = I$ , obtemos

$$A^T A = V\Sigma^T \Sigma V^T.$$

A matriz  $\Sigma^T \Sigma$  é diagonal e seus elementos diagonais são

$$\sigma_1^2, \sigma_2^2, \dots, \sigma_p^2,$$

com possíveis zeros adicionais. Portanto,

$$\boxed{A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i.}$$

Isso mostra que os vetores singulares à direita são autovetores de  $A^T A$ , e os autovalores correspondentes são os quadrados dos valores singulares.

De modo análogo,

$$AA^T = (U\Sigma V^T)(V\Sigma^T U^T) = U\Sigma\Sigma^T U^T.$$

Logo,

$$AA^T \mathbf{u}_i = \sigma_i^2 \mathbf{u}_i.$$

Os vetores singulares à esquerda são autovetores de  $AA^T$ .

Essa relação é importante por três motivos. Primeiro, mostra que os valores singulares são sempre reais e não negativos. Segundo, fornece um caminho conceitual para calcular a SVD. Terceiro, mostra que a SVD generaliza a decomposição espectral, mas sem exigir que  $A$  seja quadrada.

Um procedimento conceitual para obter a SVD é:

1. Calcular  $A^T A$ .
2. Encontrar autovalores  $\lambda_i$  e autovetores ortonormais  $\mathbf{v}_i$ .
3. Definir  $\sigma_i = \sqrt{\lambda_i}$ .
4. Para  $\sigma_i > 0$ , calcular  $\mathbf{u}_i = \frac{A\mathbf{v}_i}{\sigma_i}$ .
5. Completar  $U$  com vetores ortonormais, se necessário.

Na prática computacional, algoritmos numéricos mais estáveis são usados. Para a compreensão matemática desta aula, porém, esse procedimento revela a estrutura da SVD.

## 7. Exemplo completo em dimensão dois

Considere a matriz

$$A = \begin{bmatrix} 5 & 4 \\ 0 & 3 \end{bmatrix}.$$

Ela não é simétrica. Portanto, não devemos esperar uma decomposição espectral ortogonal simples. Ainda assim, a SVD existe.

Começamos calculando

$$A^T A = \begin{bmatrix} 5 & 0 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 5 & 4 \\ 0 & 3 \end{bmatrix} = \begin{bmatrix} 25 & 20 \\ 20 & 25 \end{bmatrix}.$$

Os autovalores de  $A^T A$  são obtidos por

$$\det(A^T A - \lambda I) = \det \begin{bmatrix} 25 - \lambda & 20 \\ 20 & 25 - \lambda \end{bmatrix}.$$

Assim,

$$(25 - \lambda)^2 - 400 = 0.$$

Logo,

$$25 - \lambda = \pm 20.$$

Portanto,

$$\lambda_1 = 45, \quad \lambda_2 = 5.$$

Os valores singulares são as raízes quadradas desses autovalores:

$$\sigma_1 = \sqrt{45} = 3\sqrt{5}, \quad \sigma_2 = \sqrt{5}.$$

Para  $\lambda_1 = 45$ , temos

$$(A^T A - 45I)\mathbf{v}_1 = \mathbf{0},$$

ou seja,

$$\begin{bmatrix} -20 & 20 \\ 20 & -20 \end{bmatrix} \begin{bmatrix} v_{11} \\ v_{12} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Da primeira linha,

$$-v_{11} + v_{12} = 0,$$

portanto  $v_{11} = v_{12}$ . Escolhendo o autovetor unitário,

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Para  $\lambda_2 = 5$ , obtemos

$$\begin{bmatrix} 20 & 20 \\ 20 & 20 \end{bmatrix} \begin{bmatrix} v_{21} \\ v_{22} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

logo

$$v_{21} + v_{22} = 0.$$

Escolhemos

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Assim,

$$V = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

Agora calculamos os vetores singulares à esquerda. Para o primeiro,

$$\mathbf{u}_1 = \frac{A\mathbf{v}_1}{\sigma_1}.$$



Como

$$A\mathbf{v}_1 = \begin{bmatrix} 5 & 4 \\ 0 & 3 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 9 \\ 3 \end{bmatrix},$$

temos

$$\mathbf{u}_1 = \frac{1}{3\sqrt{5}} \frac{1}{\sqrt{2}} \begin{bmatrix} 9 \\ 3 \end{bmatrix} = \frac{1}{\sqrt{10}} \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

Para o segundo,

$$A\mathbf{v}_2 = \begin{bmatrix} 5 & 4 \\ 0 & 3 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -3 \end{bmatrix}.$$

Logo,

$$\mathbf{u}_2 = \frac{A\mathbf{v}_2}{\sigma_2} = \frac{1}{\sqrt{5}} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -3 \end{bmatrix} = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ -3 \end{bmatrix}.$$

Portanto,

$$U = \frac{1}{\sqrt{10}} \begin{bmatrix} 3 & 1 \\ 1 & -3 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 3\sqrt{5} & 0 \\ 0 & \sqrt{5} \end{bmatrix}, \quad V^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

A decomposição é

$$\begin{bmatrix} 5 & 4 \\ 0 & 3 \end{bmatrix} = \frac{1}{\sqrt{10}} \begin{bmatrix} 3 & 1 \\ 1 & -3 \end{bmatrix} \begin{bmatrix} 3\sqrt{5} & 0 \\ 0 & \sqrt{5} \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}.$$

Esse exemplo mostra o papel de cada fator. Os vetores  $\mathbf{v}_1$  e  $\mathbf{v}_2$  são direções ortogonais no espaço de entrada. A matriz  $A$  transforma essas direções em  $\mathbf{u}_1$  e  $\mathbf{u}_2$ , também ortogonais, com fatores de escala  $3\sqrt{5}$  e  $\sqrt{5}$ . Portanto, a direção  $\mathbf{v}_1$  é a direção de maior amplificação, enquanto  $\mathbf{v}_2$  é amplificada por um fator menor.

## 8. SVD completa, SVD reduzida e SVD econômica

Na forma completa, a SVD de uma matriz  $A \in \mathbb{R}^{m \times n}$  é escrita como

$$A = U\Sigma V^T,$$

com

$$U \in \mathbb{R}^{m \times m}, \quad \Sigma \in \mathbb{R}^{m \times n}, \quad V \in \mathbb{R}^{n \times n}.$$

Essa forma é conceitualmente clara, mas pode carregar colunas que não contribuem para reconstruir  $A$ , especialmente quando a matriz é retangular ou tem posto baixo.

Suponha que

$$\text{rank}(A) = r.$$

Então exatamente  $r$  valores singulares são positivos:

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0, \quad \sigma_{r+1} = \cdots = 0.$$

As partes associadas aos valores singulares nulos não contribuem para  $A$ . Por isso, podemos escrever a SVD reduzida como

$$A = U_r \Sigma_r V_r^T,$$

onde

$$U_r \in \mathbb{R}^{m \times r}, \quad \Sigma_r \in \mathbb{R}^{r \times r}, \quad V_r \in \mathbb{R}^{n \times r}.$$

Aqui,

$$U_r = \begin{bmatrix} \mathbf{u}_1 & \cdots & \mathbf{u}_r \end{bmatrix}, \quad V_r = \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_r \end{bmatrix},$$

e

$$\Sigma_r = \text{diag}(\sigma_1, \dots, \sigma_r).$$

Convém precisar a terminologia, pois as duas formas compactas são próximas, mas não idênticas. A SVD *econômica* elimina apenas o bloco de zeros garantido de  $\Sigma$ : para  $A \in \mathbb{R}^{m \times n}$ , ela guarda as primeiras  $\min\{m, n\}$  colunas de  $U$  e de  $V$ . A SVD *reduzida* vai um passo além e mantém somente as  $r = \text{rank}(A)$  colunas associadas a valores singulares positivos. Quando  $A$  tem posto completo, as duas formas coincidem; quando  $A$  tem posto deficiente, a reduzida é estritamente menor, pois descarta também as direções de valor singular nulo. Em ambos os casos, a reconstrução de  $A$  permanece exata.

A economia é essencial em dados de alta dimensão. Por exemplo, se uma matriz de snapshots tem  $n = 10^6$  linhas e  $m = 100$  colunas, a matriz  $U$  completa teria  $10^6 \times 10^6$  entradas, o que é inviável; já a forma econômica guarda apenas  $\min\{m, n\} = 100$  colunas de  $U$ , evitando armazenar direções que não participam da representação dos dados.

É importante distinguir essas duas formas da SVD truncada. Tanto a econômica quanto a reduzida ainda representam exatamente a matriz, pois preservam todos os  $r$  valores singulares positivos. A SVD truncada, por sua vez, descarta propositalmente alguns valores singulares positivos para obter uma aproximação de posto menor. Esse segundo passo não será desenvolvido nesta aula.

## 9. SVD como soma de contribuições direcionais

A forma

$$A = U_r \Sigma_r V_r^T$$

pode ser reescrita como uma soma de matrizes de posto um:

$$A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T.$$

Cada termo

$$\sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

representa uma contribuição direcional. O vetor  $\mathbf{v}_i$  identifica uma direção de entrada; o vetor  $\mathbf{u}_i$  identifica a direção de saída correspondente; e  $\sigma_i$  mede a intensidade dessa contribuição.

Essa forma será muito importante nas próximas aplicações, mas já pode ser interpretada agora. A matriz  $A$  é decomposta em camadas ordenadas. A primeira camada é a mais forte, pois  $\sigma_1$  é o maior valor singular. A segunda é a próxima mais forte, e assim por diante. A ordenação

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$$

cria uma hierarquia de importância.

## 10. Exemplo de matriz de posto um

Considere

$$\mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

e a matriz

$$A = \mathbf{a} \mathbf{b}^T = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \begin{bmatrix} 1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{bmatrix}.$$

Todas as colunas de  $A$  são múltiplas de  $\mathbf{a}$ . Portanto,

$$\text{rank}(A) = 1.$$

A norma de  $\mathbf{a}$  é

$$\|\mathbf{a}\|_2 = \sqrt{1^2 + 2^2 + 3^2} = \sqrt{14},$$

e a norma de  $\mathbf{b}$  é

$$\|\mathbf{b}\|_2 = \sqrt{1^2 + 2^2} = \sqrt{5}.$$

Podemos escrever

$$\mathbf{a} = \sqrt{14} \mathbf{u}_1, \quad \mathbf{b} = \sqrt{5} \mathbf{v}_1,$$

onde

$$\mathbf{u}_1 = \frac{1}{\sqrt{14}} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \mathbf{v}_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Logo,

$$A = \mathbf{a} \mathbf{b}^T = (\sqrt{14} \mathbf{u}_1)(\sqrt{5} \mathbf{v}_1)^T = \sqrt{70} \mathbf{u}_1 \mathbf{v}_1^T.$$

Portanto, a SVD reduzida de  $A$  é

$$A = U_r \Sigma_r V_r^T,$$

com

$$U_r = \frac{1}{\sqrt{14}} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \Sigma_r = \begin{bmatrix} \sqrt{70} \end{bmatrix}, \quad V_r = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Esse exemplo mostra o caso mais simples da SVD: uma única direção de entrada é convertida em uma única direção de saída. Todas as demais direções de entrada pertencem ao espaço nulo de  $A$  ou são irrelevantes para a reconstrução da matriz.

## 11. Interpretação para matrizes de dados

Em aprendizado de máquina científico, a SVD raramente aparece apenas como uma técnica algébrica isolada. Ela aparece como uma forma de descobrir estruturas dominantes em uma matriz de dados. Considere novamente

$$X = \begin{bmatrix} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_m \\ | & | & & | \end{bmatrix} \in \mathbb{R}^{n \times m}.$$

Se cada coluna  $\mathbf{x}_k$  é um snapshot de um sistema físico, então  $n$  é o número de graus de liberdade de cada snapshot, e  $m$  é o número de snapshots coletados. Note que aqui adotamos  $X \in \mathbb{R}^{n \times m}$  (graus de liberdade nas linhas, snapshots nas colunas), enquanto o enunciado geral da SVD usou  $A \in \mathbb{R}^{m \times n}$ . Trata-se apenas de uma troca de nomes dos rótulos de dimensão:  $U$  continua sendo a matriz dos vetores singulares *à esquerda* — e são as suas colunas que guardam os modos espaciais — enquanto  $V$  guarda os vetores singulares *à direita*, associados aos snapshots. Os papéis de  $U$  e  $V$  só se invertem se a matriz de dados for de fato *transposta*, isto é, se os snapshots forem colocados nas linhas; é essa a convenção que adotaremos ao tratar de PCA.

A SVD reduzida — a de posto  $r$ , na terminologia fixada na Seção 8 — escreve

$$X = U_r \Sigma_r V_r^T.$$

As colunas de  $U_r$  formam padrões espaciais dominantes nos dados. No caso de um escoamento discretizado, essas colunas podem ser interpretadas como estruturas espaciais recorrentes do campo de velocidade, pressão ou temperatura. Os valores singulares em  $\Sigma_r$  medem a intensidade relativa desses padrões. A matriz  $V_r^T$ , combinada com  $\Sigma_r$ , descreve como esses padrões aparecem em cada snapshot.

A coluna  $\mathbf{x}_k$  pode ser escrita como

$$\mathbf{x}_k = \sum_{i=1}^r \sigma_i v_{ki} \mathbf{u}_i,$$

onde  $v_{ki} = (V)_{ki}$  é a entrada (linha  $k$ , coluna  $i$ ) da matriz  $V$ , correspondente ao snapshot  $k$  e ao modo  $i$ . Assim, cada snapshot é uma combinação dos modos  $\mathbf{u}_i$ , ponderados por coeficientes dependentes do snapshot.

Essa leitura é fundamental para aplicações futuras. Em PCA, os modos estarão associados às direções de maior variância dos dados. Em POD, os modos representarão estruturas coerentes de escoamentos. Em modelos de ordem reduzida, a dinâmica de alta dimensão será aproximada pela evolução de poucos coeficientes associados a esses modos.

A SVD é, portanto, uma ponte entre álgebra linear e modelagem de dados. Ela transforma uma matriz grande em três objetos interpretáveis: padrões de saída, intensidades e coordenadas de entrada.

## 12. Cuidado conceitual: a SVD depende da representação dos dados

A interpretação geométrica da SVD depende do produto interno usado no espaço dos dados. Como consequência, a SVD é sensível à forma como os dados são organizados, escalados e alinhados.

Considere uma sequência de imagens de um mesmo objeto. Se o objeto permanece centralizado e alinhado, poucas direções podem capturar boa parte da estrutura visual. Se o mesmo objeto se desloca, gira ou muda de escala, a SVD pode precisar de muitos modos para representar algo que, fisicamente, parece simples.

Em termos algébricos, isso ocorre porque a SVD busca separações lineares entre padrões de linha e de coluna. Quando o fenômeno envolve translações, rotações ou deformações não alinhadas ao sistema de coordenadas, a matriz de dados pode parecer artificialmente mais complexa. Em mecânica dos fluidos, ondas viajantes e estruturas convectadas são exemplos típicos em que a SVD pode espalhar uma estrutura simples por muitos modos.

Esse cuidado não diminui a importância da SVD. Pelo contrário, ele mostra que a SVD é uma ferramenta matemática poderosa, mas não mágica. Seu resultado deve ser interpretado à luz da forma como os dados foram coletados, escalados, centralizados e organizados.

## 13. Síntese da aula

A decomposição em valores singulares escreve qualquer matriz real como

$$A = U\Sigma V^T.$$

A matriz  $V^T$  muda as coordenadas no espaço de entrada,  $\Sigma$  estica ou comprime direções ortogonais, e  $U$  muda as coordenadas no espaço de saída. Por isso, a SVD pode ser entendida como uma composição rotação–estiramento–rotação, admitindo também reflexões.

Os valores singulares são não negativos e ordenados:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0.$$

Eles medem os fatores de amplificação da matriz em direções ortogonais especiais. O número de valores singulares positivos é o posto de  $A$ .

Os vetores singulares à direita são autovetores de  $A^T A$ , e os vetores singulares à esquerda são autovetores de  $AA^T$ :

$$A^T A \mathbf{v}_i = \sigma_i^2 \mathbf{v}_i, \quad AA^T \mathbf{u}_i = \sigma_i^2 \mathbf{u}_i.$$

A SVD reduzida remove todas as partes que não contribuem para a reconstrução exata da matriz; a econômica remove o bloco de zeros garantido pelas dimensões. Ambas são especialmente importantes quando  $A$  é retangular ou tem posto baixo.

Por fim, quando  $A$  é uma matriz de dados, a SVD separa padrões dominantes, intensidades e coordenadas. Essa interpretação será a base para PCA, POD e modelos reduzidos em mecânica dos fluidos.

## 14. Exercícios propostos

**Exercício 1.** Considere

$$A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}.$$

Identifique uma SVD de  $A$ . Descreva geometricamente a imagem do círculo unitário por essa matriz.

**Exercício 2.** Seja

$$A = \begin{bmatrix} 0 & 2 \\ 1 & 0 \end{bmatrix}.$$

Calcule  $A^T A$ , encontre seus autovalores e determine os valores singulares de  $A$ . Em seguida, encontre os vetores singulares à direita e à esquerda.

**Exercício 3.** Considere uma matriz  $A \in \mathbb{R}^{m \times n}$  com SVD

$$A = U \Sigma V^T.$$

Mostre que

$$\|A \mathbf{v}_1\|_2 = \sigma_1,$$

onde  $\mathbf{v}_1$  é o primeiro vetor singular à direita. Explique por que  $\sigma_1$  pode ser interpretado como o maior estiramento produzido por  $A$ .

**Exercício 4.** Seja

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{bmatrix}.$$

Mostre que  $A$  tem posto 1. Encontre uma SVD reduzida de  $A$  escrevendo  $A = \mathbf{a}\mathbf{b}^T$ , normalizando  $\mathbf{a}$  e  $\mathbf{b}$ .

**Exercício 5.** Suponha que uma matriz de dados seja escrita como

$$X = \begin{bmatrix} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_m \\ | & | & & | \end{bmatrix}.$$

Explique o significado das matrizes  $U$ ,  $\Sigma$  e  $V$  na SVD de  $X$ . Interprete a expressão

$$\mathbf{x}_k = \sum_{i=1}^r \sigma_i v_{ki} \mathbf{u}_i$$

como uma decomposição de um snapshot em modos espaciais.

## 15. Referências

- BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2. ed. Cambridge University Press, 2022.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.
- STRANG, G. *Introduction to Linear Algebra*. 6. ed. Wellesley-Cambridge Press, 2023.