

Aula 5 — SVD: truncamento e Eckart–Young

Aproximações de baixa ordem, energia acumulada, gap espectral, compressão e remoção de ruído

Prof. Dr. Rodrigo Figueiredo Abdo

1. Ideia central da aula

Na aula anterior, a decomposição em valores singulares foi apresentada como uma forma de escrever uma matriz geral como

$$A = U\Sigma V^T.$$

Essa expressão separa a ação de uma matriz em três partes: uma mudança ortonormal de coordenadas no espaço de entrada, um estiramento por fatores não negativos e uma mudança ortonormal de coordenadas no espaço de saída. A informação central da SVD está condensada nas relações

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i,$$

onde $\mathbf{v}_i$ é uma direção no espaço de entrada, $\mathbf{u}_i$ é uma direção no espaço de saída e σ_i é o valor singular correspondente.

Nesta aula, a pergunta muda. Em vez de perguntar apenas como decompor a matriz, perguntamos: é necessário usar todos os valores singulares para representar adequadamente a matriz? Em muitos problemas de dados, simulações e experimentos, a resposta é não. Parte importante da informação costuma estar concentrada nos primeiros valores singulares. Os demais podem representar detalhes finos, ruído, redundância ou estruturas pouco relevantes para a escala de interesse.

Essa é a ideia que torna a SVD tão útil em ciência de dados e em mecânica dos fluidos computacional. Uma simulação de escoamento pode ter milhões de graus de liberdade, mas a dinâmica observada pode ser dominada por poucas estruturas coerentes. Uma imagem pode ter centenas de milhares de pixels, mas sua aparência global pode ser reconstruída com muito menos informação. Uma matriz de medições pode ser grande, mas possuir estrutura aproximadamente de baixo posto.

O objetivo desta aula é entender matematicamente a SVD truncada. Veremos que a SVD permite escrever uma matriz como soma de matrizes de posto 1. A partir dessa soma, podemos construir aproximações de posto baixo. Em seguida, enunciaremos o teorema de Eckart–Young, que afirma que a SVD truncada fornece a melhor aproximação possível de posto fixado, tanto na norma de Frobenius quanto na norma espectral. Por fim, discutiremos critérios de truncamento e duas aplicações imediatas: compressão e remoção de ruído.

2. A SVD como soma de matrizes de posto 1

Considere uma matriz real

$$A \in \mathbb{R}^{m \times n}$$

e sua SVD

$$A = U \Sigma V^T.$$

Sejam

$$U = \begin{bmatrix} | & | & & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \\ | & | & & | \end{bmatrix}, \quad V = \begin{bmatrix} | & | & & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \\ | & | & & | \end{bmatrix}.$$

Os vetores $\mathbf{u}_i$ formam uma base ortonormal de $\mathbb{R}^m$, enquanto os vetores $\mathbf{v}_i$ formam uma base ortonormal de $\mathbb{R}^n$. A matriz Σ contém os valores singulares

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_p \geq 0, \quad p = \min\{m, n\}.$$

A multiplicação $U \Sigma V^T$ pode ser reescrita como uma soma de produtos externos:

$$A = \sum_{i=1}^p \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

Se apenas r valores singulares forem não nulos, então $r = \text{rank}(A)$ e a soma efetiva é

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

Cada termo

$$\sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

é uma matriz de posto 1, desde que $\sigma_i \neq 0$. Para ver isso, observe que $\mathbf{u}_i \mathbf{v}_i^T$ é um produto externo. Se

$$\mathbf{u}_i = \begin{bmatrix} u_{1i} \\ u_{2i} \\ \vdots \\ u_{mi} \end{bmatrix}, \quad \mathbf{v}_i = \begin{bmatrix} v_{1i} \\ v_{2i} \\ \vdots \\ v_{ni} \end{bmatrix},$$

então

$$\mathbf{u}_i \mathbf{v}_i^T = \begin{bmatrix} u_{1i}v_{1i} & u_{1i}v_{2i} & \cdots & u_{1i}v_{ni} \\ u_{2i}v_{1i} & u_{2i}v_{2i} & \cdots & u_{2i}v_{ni} \\ \vdots & \vdots & \ddots & \vdots \\ u_{mi}v_{1i} & u_{mi}v_{2i} & \cdots & u_{mi}v_{ni} \end{bmatrix}.$$

Todas as colunas dessa matriz são múltiplos de $\mathbf{u}_i$. Logo, seu espaço coluna é uma reta, e o posto é 1.

A leitura conceitual é direta: a SVD decompõe uma matriz em uma soma ordenada de padrões elementares. O primeiro padrão, associado a σ_1 , é o mais forte. O segundo é o mais forte entre os que restam, respeitando a ortogonalidade. E assim por diante. A matriz deixa de ser vista como uma coleção de entradas independentes e passa a ser vista como uma soma hierárquica de contribuições direcionais.

Exemplo 1: decomposição de uma matriz diagonal

Considere

$$A = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Neste caso, a própria matriz já está na forma diagonal da SVD. Podemos tomar

$$U = I, \quad V = I, \quad \Sigma = A.$$

Os valores singulares são

$$\sigma_1 = 5, \quad \sigma_2 = 2, \quad \sigma_3 = 1.$$

Logo,

$$A = 5\mathbf{e}_1\mathbf{e}_1^T + 2\mathbf{e}_2\mathbf{e}_2^T + 1\mathbf{e}_3\mathbf{e}_3^T.$$

Explicitamente,

$$5\mathbf{e}_1\mathbf{e}_1^T = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad 2\mathbf{e}_2\mathbf{e}_2^T = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad \mathbf{e}_3\mathbf{e}_3^T = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

A matriz original é a soma desses três blocos de posto 1. Como os valores singulares estão ordenados, o primeiro bloco é o mais importante em magnitude. Se quisermos uma aproximação de posto 1, a escolha natural é manter apenas o termo associado a $\sigma_1 = 5$.

3. SVD truncada

A SVD truncada é obtida mantendo apenas os k primeiros valores singulares e seus vetores singulares associados. Se

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T,$$

com $r = \text{rank}(A)$, definimos a aproximação de posto k por

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T, \quad k < r.$$

Em forma matricial, escrevemos

$$A_k = U_k \Sigma_k V_k^T,$$

onde

$$U_k = \begin{bmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_k \end{bmatrix},$$

$$\Sigma_k = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_k),$$

e

$$V_k = \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_k \end{bmatrix}.$$

A matriz A_k possui posto no máximo k . Se os k primeiros valores singulares forem todos positivos, então

$$\text{rank}(A_k) = k.$$

A diferença entre a matriz original e a aproximação truncada é o resíduo

$$A - A_k = \sum_{i=k+1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

Assim, truncar a SVD significa descartar as contribuições associadas aos menores valores singulares.

É importante notar que truncar não é o mesmo que apagar entradas pequenas da matriz original. A SVD não trabalha entrada por entrada. Ela trabalha por padrões globais. Ao descartar um valor singular, descartamos uma estrutura matricial inteira, dada por $\mathbf{u}_i \mathbf{v}_i^T$, e não apenas alguns elementos de A .

Exemplo 2: aproximações sucessivas de uma matriz diagonal

Voltemos à matriz

$$A = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Sua aproximação de posto 1 é

$$A_1 = 5\mathbf{e}_1 \mathbf{e}_1^T = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

A aproximação de posto 2 é

$$A_2 = 5\mathbf{e}_1 \mathbf{e}_1^T + 2\mathbf{e}_2 \mathbf{e}_2^T = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

A aproximação de posto 3 recupera exatamente a matriz original:

$$A_3 = A.$$

Neste exemplo, a interpretação é quase visual: A_1 preserva apenas a direção mais intensa; A_2 preserva as duas direções mais intensas; A_3 preserva tudo. Em uma matriz não diagonal, a ideia é a mesma, mas as direções preservadas não são os eixos coordenados originais. São as direções singulares, determinadas pela própria matriz.

4. Normas necessárias para medir o erro

Para dizer que A_k é uma boa aproximação de A , precisamos medir o erro. Duas normas aparecem naturalmente no teorema de Eckart–Young: a norma de Frobenius e a norma espectral.

A norma de Frobenius de uma matriz $A \in \mathbb{R}^{m \times n}$ é definida por

$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2 \right)^{1/2}.$$

Ela mede o tamanho da matriz como se todas as entradas fossem empilhadas em um único vetor. Se uma matriz representa um campo discretizado, a norma de Frobenius pode ser interpretada como uma medida global da intensidade do campo.

A norma espectral é definida por

$$\|A\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|_2}{\|\mathbf{x}\|_2}.$$

Ela mede o maior fator de amplificação produzido pela matriz. Esse máximo da razão $\|A\mathbf{x}\|_2 / \|\mathbf{x}\|_2$ é atingido na direção $\mathbf{v}_1$ e vale exatamente o maior valor singular (Aulas 3 e 4):

$$\|A\|_2 = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|A\mathbf{x}\|_2}{\|\mathbf{x}\|_2} = \sigma_1.$$

Mais geralmente, como

$$A - A_k = \sum_{i=k+1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T,$$

o maior valor singular do erro é σ_{k+1} . Portanto,

$$\|A - A_k\|_2 = \sigma_{k+1}.$$

Para a norma de Frobenius, usando $\|A\|_F^2 = \text{tr}(A^T A)$ (Aula 3) e $A^T A = V \Sigma^T \Sigma V^T$, a

ciclicidade do traço fornece $\text{tr}(A^T A) = \text{tr}(\Sigma^T \Sigma V^T V) = \text{tr}(\Sigma^T \Sigma) = \sum_i \sigma_i^2$. Portanto,

$$\|A\|_F^2 = \sum_{i=1}^r \sigma_i^2.$$

Consequentemente,

$$\|A - A_k\|_F^2 = \sum_{i=k+1}^r \sigma_i^2.$$

Essa fórmula é uma das mais importantes da aula. Ela mostra que o erro quadrático da aproximação truncada é exatamente a soma dos quadrados dos valores singulares descartados.

Exemplo 3: erro de truncamento

Considere novamente

$$A = \text{diag}(5, 2, 1).$$

A norma de Frobenius da matriz original é

$$\|A\|_F^2 = 5^2 + 2^2 + 1^2 = 25 + 4 + 1 = 30.$$

Logo,

$$\|A\|_F = \sqrt{30}.$$

Para a aproximação de posto 1,

$$A_1 = \text{diag}(5, 0, 0),$$

o erro é

$$A - A_1 = \text{diag}(0, 2, 1).$$

Assim,

$$\|A - A_1\|_F^2 = 2^2 + 1^2 = 5,$$

e

$$\|A - A_1\|_F = \sqrt{5}.$$

Pela norma espectral,

$$\|A - A_1\|_2 = \sigma_2 = 2.$$

Para a aproximação de posto 2,

$$A_2 = \text{diag}(5, 2, 0),$$

temos

$$\|A - A_2\|_F^2 = 1^2 = 1, \quad \|A - A_2\|_2 = \sigma_3 = 1.$$

Esse exemplo mostra que o ganho obtido ao passar de A_1 para A_2 depende do tamanho do valor singular que foi acrescentado. Se σ_2 é grande, essa melhora é expressiva. Se os valores singulares seguintes são pequenos, acrescentar novos termos melhora pouco a reconstrução.

5. Teorema de Eckart–Young

A SVD truncada não é apenas uma aproximação conveniente. Ela é a melhor aproximação possível de posto fixado, no sentido das normas de Frobenius e espectral.

Seja $A \in \mathbb{R}^{m \times n}$ uma matriz de posto r , com SVD

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T, \quad \sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0.$$

Para $k < r$, defina

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

O teorema de Eckart–Young afirma que

$$A_k = \arg \min_{\text{rank}(B) \leq k} \|A - B\|_F.$$

Além disso,

$$\|A - A_k\|_F^2 = \sum_{i=k+1}^r \sigma_i^2.$$

O mesmo truncamento também é ótimo na norma espectral:

$$A_k = \arg \min_{\text{rank}(B) \leq k} \|A - B\|_2,$$

com erro

$$\|A - A_k\|_2 = \sigma_{k+1}.$$

Esse teorema deve ser lido com cuidado. Ele não diz apenas que A_k é uma aproximação boa. Ele diz que nenhuma outra matriz de posto menor ou igual a k consegue aproximar A melhor, nessas normas. Portanto, se o objetivo é substituir uma matriz por outra de posto baixo, a SVD truncada é a escolha natural.

A intuição por trás do teorema é simples. A SVD coloca a matriz em um sistema de coordenadas no qual seus efeitos aparecem ordenados por intensidade. Como U e V são ortogonais, elas não alteram comprimentos nem ângulos. O problema de aproximar A por posto k se reduz a escolher quais entradas diagonais de Σ preservar. A melhor escolha é preservar as maiores.

A demonstração formal completa exige resultados de aproximação matricial, mas a ideia

essencial é esta: se os valores singulares medem as intensidades fundamentais da matriz, descartar uma intensidade grande antes de descartar uma pequena só pode piorar a aproximação.

6. Energia acumulada e variância explicada

Em aplicações, a pergunta prática é: quantos valores singulares devemos manter? Não existe uma resposta universal. A escolha de k depende do objetivo: compressão, visualização, remoção de ruído, redução de ordem ou preservação de fenômenos físicos específicos.

Um critério muito usado é a energia acumulada. Como

$$\|A\|_F^2 = \sum_{i=1}^r \sigma_i^2,$$

definimos a fração de energia preservada pelos k primeiros modos como

$$E_k = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}.$$

Também podemos escrever a fração de energia descartada como

$$1 - E_k = \frac{\sum_{i=k+1}^r \sigma_i^2}{\sum_{i=1}^r \sigma_i^2} = \frac{\|A - A_k\|_F^2}{\|A\|_F^2}.$$

Esse critério é especialmente natural em mecânica dos fluidos quando as colunas da matriz representam campos de velocidade. Se cada snapshot contém valores de velocidade em uma malha, a soma dos quadrados está associada à intensidade quadrática do campo. Nesse contexto, fala-se frequentemente em energia modal: os primeiros modos da SVD capturam as estruturas mais energéticas da base de dados.

Entretanto, é preciso cuidado. Energia acumulada não é sinônimo automático de importância física. Um modo pouco energético pode ser importante para uma instabilidade, para uma região localizada do escoamento ou para uma condição de contorno. O critério energético é poderoso, mas não substitui interpretação física.

Exemplo 4: escolha de posto por energia acumulada

Suponha que uma matriz tenha valores singulares

$$\sigma_1 = 10, \quad \sigma_2 = 4, \quad \sigma_3 = 1, \quad \sigma_4 = 0,5.$$

A energia total é

$$\sum_{i=1}^4 \sigma_i^2 = 10^2 + 4^2 + 1^2 + 0,5^2 = 100 + 16 + 1 + 0,25 = 117,25.$$

A energia preservada com $k = 1$ é

$$E_1 = \frac{100}{117,25} \approx 0,853.$$

Logo, o primeiro modo preserva aproximadamente 85,3% da energia.

Com $k = 2$, temos

$$E_2 = \frac{100 + 16}{117,25} = \frac{116}{117,25} \approx 0,989.$$

Portanto, os dois primeiros modos preservam aproximadamente 98,9% da energia. Se o critério escolhido for preservar pelo menos 95% da energia, então $k = 2$ é suficiente.

O erro relativo quadrático da aproximação de posto 2 é

$$\frac{\|A - A_2\|_F^2}{\|A\|_F^2} = 1 - E_2 \approx 0,011.$$

Isso significa que, na norma de Frobenius ao quadrado, apenas cerca de 1,1% da energia foi descartada.

7. Gap espectral e cotovelo da curva

Outro critério de truncamento consiste em observar a queda dos valores singulares. Se os valores singulares apresentam uma separação clara entre valores grandes e pequenos, essa separação sugere uma dimensão efetiva para os dados.

Uma forma simples de medir essa separação é analisar as razões

$$\frac{\sigma_i}{\sigma_{i+1}}.$$

Quando essa razão é muito grande, há um gap espectral entre σ_i e σ_{i+1} . Nesse caso, pode ser razoável manter os i primeiros modos e descartar os demais.

Por exemplo, considere


$$\sigma_1 = 20, \quad \sigma_2 = 12, \quad \sigma_3 = 8, \quad \sigma_4 = 0,4, \quad \sigma_5 = 0,3.$$

A razão

$$\frac{\sigma_3}{\sigma_4} = \frac{8}{0,4} = 20$$

é muito maior do que as razões anteriores. Isso sugere que os três primeiros valores singulares representam a estrutura dominante, enquanto os demais podem estar associados a ruído ou detalhes fracos.

Graficamente, esse critério aparece como um cotovelo na curva dos valores singulares. Em escala semilogarítmica, uma queda brusca seguida de uma cauda relativamente plana sugere um ponto de truncamento.



Os três primeiros valores singulares concentram a estrutura dominante; a queda brusca para σ_4 marca o gap espectral.

O gap espectral é um critério útil, mas não infalível. Em muitos problemas reais, os valores singulares decaem gradualmente, sem separação nítida. Em outros, o ruído pode se misturar com o sinal. Portanto, a escolha de k deve combinar análise matemática, finalidade computacional e interpretação física.

8. Compressão de dados

Uma aplicação direta da SVD truncada é a compressão. Suponha que uma matriz $A \in \mathbb{R}^{m \times n}$ seja armazenada diretamente. São necessários mn números.

Se aproximarmos A por

$$A_k = U_k \Sigma_k V_k^T,$$

então precisamos armazenar:


$$U_k \in \mathbb{R}^{m \times k}, \quad \Sigma_k \in \mathbb{R}^{k \times k}, \quad V_k \in \mathbb{R}^{n \times k}.$$

Como Σ_k é diagonal, basta armazenar seus k valores diagonais. Assim, o número aproximado de números armazenados é

$$mk + k + nk = k(m + n + 1).$$

A compressão faz sentido quando

$$k(m + n + 1) < mn.$$



Em vez das mn entradas de A , guardam-se apenas os blocos finos U_k , Σ_k e V_k^T .

Exemplo 5: estimativa de armazenamento

Considere uma imagem em escala de cinza representada por uma matriz

$$A \in \mathbb{R}^{1000 \times 1000}.$$

Armazenar a imagem completa exige

$$1000 \times 1000 = 1.000.000$$

números.

Uma aproximação de posto $k = 50$ exige armazenar aproximadamente

$$50(1000 + 1000 + 1) = 50 \times 2001 = 100.050$$

números. Isso representa cerca de 10% do armazenamento original.

Essa conta não garante que a imagem reconstruída será boa. A qualidade depende do decaimento dos valores singulares. Se a imagem tiver estrutura de baixo posto aproximado, poucos modos poderão preservar a maior parte da informação visual. Se a imagem tiver muitos detalhes finos, ruído ou padrões pouco compressíveis, será necessário usar mais modos.

A compressão por SVD é mais do que uma técnica para imagens. Em simulações físicas, uma matriz de snapshots pode ser enorme. Se os dados forem aproximadamente de baixo posto, a SVD truncada permite representar a evolução observada por poucos modos espaciais e poucos coeficientes temporais. Essa ideia é uma das portas de entrada para modelos de ordem reduzida.

9. Remoção de ruído por truncamento

Outra aplicação importante da SVD truncada é a remoção de ruído. A ideia é supor que uma matriz observada pode ser escrita como

$$A = A_{\text{sinal}} + A_{\text{ruído}}.$$

Se o sinal possui estrutura coerente de baixo posto e o ruído está espalhado por muitas direções, os primeiros valores singulares tendem a capturar a estrutura dominante, enquanto valores singulares menores tendem a carregar parte do ruído.

Nesse caso, uma aproximação truncada

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

pode funcionar como uma versão filtrada dos dados.

Essa interpretação é muito útil, mas precisa ser usada com cautela. O truncamento por

SVD não sabe, por si só, o que é física e o que é ruído. Ele apenas ordena padrões por intensidade global. Se um ruído for forte ou estruturado, ele pode aparecer nos primeiros modos. Se uma estrutura física for fraca ou localizada, ela pode aparecer em modos de baixa energia. Portanto, denoising por SVD é uma ferramenta, não um critério automático de verdade física. Quando o nível de ruído é aproximadamente conhecido, existem critérios objetivos para o limiar de truncamento; o critério de Gavish e Donoho, por exemplo, fornece um limiar ótimo para os valores singulares na presença de ruído de variância conhecida.

Exemplo 6: sinal de posto baixo contaminado por ruído

Suponha que a matriz verdadeira seja

$$A_{\text{sinal}} = 10\mathbf{u}_1\mathbf{v}_1^T + 3\mathbf{u}_2\mathbf{v}_2^T,$$

ou seja, uma matriz de posto 2. Se uma medição acrescenta ruído, observamos

$$A = A_{\text{sinal}} + A_{\text{ruído}}.$$

A SVD de A pode produzir muitos valores singulares não nulos, pois o ruído geralmente aumenta o posto numérico da matriz. Porém, se o sinal for dominante, os dois primeiros valores singulares estarão destacados. Uma aproximação A_2 tende a recuperar a estrutura principal de A_{sinal} , descartando parte da variação associada ao ruído.

Em termos práticos, esse procedimento equivale a procurar uma matriz simples, de posto baixo, que explique a maior parte da estrutura observada. Essa ideia será recorrente no curso: antes de treinar modelos complexos, muitas vezes é útil perguntar se os dados possuem uma estrutura dominante de baixa dimensão.

10. SVD truncada em matrizes de snapshots

Em mecânica dos fluidos computacional, é comum organizar dados em uma matriz de snapshots:

$$X = \begin{bmatrix} | & | & & | \\ \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_m \\ | & | & & | \end{bmatrix} \in \mathbb{R}^{n \times m}.$$

Cada coluna $\mathbf{x}_j$ pode representar um campo de velocidade, pressão, temperatura ou vorticidade em um instante de tempo. O número n pode ser muito grande, pois corresponde aos graus de liberdade espaciais. O número m é o número de snapshots. Note que aqui adotamos $X \in \mathbb{R}^{n \times m}$ (graus de liberdade nas linhas, snapshots nas colunas); em relação ao enunciado geral com $A \in \mathbb{R}^{m \times n}$, os papéis de U e V se trocam conforme a convenção, mas o conteúdo matemático é o mesmo.

A SVD truncada escreve

$$X_k = U_k \Sigma_k V_k^T.$$

As colunas de U_k podem ser interpretadas como modos espaciais dominantes. Já as linhas de

$$\Sigma_k V_k^T$$

contêm os coeficientes temporais associados a esses modos. Equivalentemente, a coluna j de $\Sigma_k V_k^T$ reúne os coeficientes $a_1(t_j), \dots, a_k(t_j)$ do snapshot j . Assim, cada snapshot pode ser aproximado como combinação dos modos espaciais:

$$\mathbf{x}_j \approx a_1(t_j)\mathbf{u}_1 + a_2(t_j)\mathbf{u}_2 + \dots + a_k(t_j)\mathbf{u}_k.$$

Essa expressão é fundamental para a ideia de redução de ordem. Em vez de descrever o sistema por n variáveis espaciais, tentamos descrever sua evolução por k coeficientes temporais, com $k \ll n$.

No contexto de fluidos, isso é particularmente atraente porque muitos escoamentos apresentam estruturas coerentes: esteiras periódicas, recirculações, camadas de cisalhamento, grandes vórtices ou padrões dominantes. A SVD não descobre diretamente as equações que regem esses coeficientes, mas fornece uma base compacta onde uma dinâmica reduzida pode ser construída posteriormente.

11. Limitações do truncamento por SVD

A SVD truncada é ótima para aproximar uma matriz fixa por outra de posto baixo nas normas de Frobenius e espectral. Essa frase é forte, mas também delimita o alcance do resultado. A otimalidade é matricial, não necessariamente física.

Há pelo menos quatro limitações importantes.

Primeiro, a SVD depende da forma como os dados foram organizados. Se snapshots estão desalinhados, deslocados ou rotacionados, o posto aparente pode aumentar. Um fenômeno simples, quando representado em coordenadas inadequadas, pode exigir muitos modos.

Segundo, os modos da SVD são ortogonais por construção. Essa ortogonalidade é matematicamente conveniente, mas estruturas físicas reais nem sempre são naturalmente ortogonais.

Terceiro, os primeiros modos são os mais energéticos, não necessariamente os mais relevantes para uma pergunta específica. Um fenômeno pequeno pode ser decisivo para estabilidade, transição ou controle.

Quarto, a escolha do posto k envolve compromisso. Um k pequeno comprime e filtra, mas pode descartar informação importante. Um k grande reconstrói melhor os dados, mas reduz menos a dimensão e pode preservar ruído.

Essas limitações não diminuem a importância da SVD. Ao contrário, ajudam a usá-

la corretamente. A SVD truncada deve ser entendida como uma ferramenta de organização, compressão e análise de dados, não como substituto automático da interpretação física.

12. Síntese da aula

A SVD permite escrever uma matriz como soma ordenada de matrizes de posto 1:

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

A SVD truncada mantém apenas os k primeiros termos dessa soma:

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

O teorema de Eckart–Young garante que A_k é a melhor aproximação de A por uma matriz de posto menor ou igual a k , tanto na norma de Frobenius quanto na norma espectral:

$$A_k = \arg \min_{\text{rank}(B) \leq k} \|A - B\|_F, \quad A_k = \arg \min_{\text{rank}(B) \leq k} \|A - B\|_2.$$

Os erros são dados por

$$\|A - A_k\|_F^2 = \sum_{i=k+1}^r \sigma_i^2, \quad \|A - A_k\|_2 = \sigma_{k+1}.$$

A energia acumulada

$$E_k = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}$$

fornece um critério prático para escolher o posto truncado. O gap espectral fornece outro critério, baseado na separação entre valores singulares dominantes e valores pequenos. Em aplicações, essas ferramentas permitem compressão, remoção de ruído e construção de bases reduzidas para dados de alta dimensão. Na próxima aula, essas ideias reaparecem na PCA e na POD: aplicar a SVD a dados centralizados liga os valores singulares à variância explicada e os modos às direções principais e às estruturas coerentes de escoamentos.

13. Exercícios propostos

Exercício 1. Considere a matriz

$$A = \text{diag}(6, 3, 1).$$

Escreva A como soma de três matrizes de posto 1. Em seguida, escreva A_1 e A_2 , as aproximações truncadas de posto 1 e posto 2. Calcule $\|A - A_1\|_F$, $\|A - A_2\|_F$, $\|A - A_1\|_2$ e $\|A - A_2\|_2$.

Exercício 2. Uma matriz possui valores singulares

$$\sigma_1 = 12, \quad \sigma_2 = 5, \quad \sigma_3 = 2, \quad \sigma_4 = 1.$$

Calcule a energia acumulada E_1 , E_2 , E_3 e E_4 . Qual é o menor valor de k que preserva pelo menos 95% da energia?

Exercício 3. Considere uma matriz $A \in \mathbb{R}^{800 \times 600}$. Quantos números são necessários para armazenar A diretamente? Quantos números são necessários para armazenar uma aproximação SVD truncada de posto $k = 40$, considerando o armazenamento de U_k , dos valores singulares em Σ_k e de V_k ? Qual é a razão aproximada entre o armazenamento truncado e o armazenamento original?

Exercício 4. Explique, com suas palavras, por que truncar a SVD não equivale a simplesmente apagar entradas pequenas da matriz original. Na sua resposta, use a ideia de produto externo $\mathbf{u}_i \mathbf{v}_i^T$.

Exercício 5. Considere que uma matriz de snapshots de um escoamento possui valores singulares que decaem lentamente, sem gap espectral evidente. O que isso sugere sobre a possibilidade de representar o escoamento com poucos modos? Essa conclusão deve ser tomada como uma verdade física definitiva? Justifique.

Exercício 6. Em uma matriz de snapshots X , cada coluna representa um campo de velocidade discretizado. Explique por que a quantidade

$$E_k = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}$$

pode ser interpretada como fração de energia modal capturada. Em seguida, discuta uma situação em que um modo de baixa energia ainda poderia ser fisicamente relevante.

14. Referências

- BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2. ed. Cambridge University Press, 2022.
- STRANG, G. *Introduction to Linear Algebra*. 6. ed. Wellesley-Cambridge Press, 2023.