

Aula 6 — PCA: Análise de Componentes Principais

Centragem dos dados, SVD dos dados centrados, variância explicada e matriz de covariância

Prof. Dr. Rodrigo Figueiredo Abdo

1. Ideia central da aula

Nas aulas anteriores, a decomposição em valores singulares foi apresentada como uma ferramenta para decompor matrizes, interpretar transformações lineares, construir aproximações de posto baixo e medir erro de truncamento. A partir de agora, essa ferramenta passa a ser lida também como um método de análise de dados.

A ideia central da análise de componentes principais, ou PCA, é a seguinte: quando um conjunto de dados possui muitas variáveis, é comum que essas variáveis não sejam independentes. Elas podem variar de forma coordenada. Em vez de descrever os dados nas coordenadas originais, procuramos novas direções ortogonais ao longo das quais a variação dos dados seja mais organizada.

Essas novas direções são as componentes principais. A primeira componente principal é a direção de maior variância dos dados. A segunda é a direção de maior variância restante, mas ortogonal à primeira. A terceira é a direção de maior variância restante, ortogonal às duas primeiras, e assim por diante.

Do ponto de vista algébrico, PCA é essencialmente a SVD aplicada aos dados centrados. A palavra centrados é decisiva. Antes de aplicar PCA, subtraímos a média dos dados. Essa subtração desloca a nuvem de pontos para que seu centro esteja na origem. Assim, a PCA passa a medir variação em torno da média, e não a posição absoluta da nuvem no espaço.

Em aprendizado de máquina científico, essa distinção é importante. Um campo de velocidade, uma distribuição de temperatura, uma sequência de imagens ou uma matriz de sensores pode possuir uma parte média dominante e flutuações menores, mas fisicamente relevantes. Se a média não for tratada adequadamente, a primeira componente pode apenas representar o nível médio dos dados, e não a principal forma de variação.

O objetivo desta aula é desenvolver a PCA de forma matemática e operacional. Veremos como organizar os dados, como centralizá-los, como construir a matriz de covariância, como obter as componentes principais pela SVD e como interpretar a variância explicada. Ao final, faremos um exemplo bidimensional completo, com todas as contas explícitas.

2. Organização dos dados

Considere um conjunto de dados com N observações e d variáveis. Usaremos, nesta aula, a convenção comum em aprendizado de máquina: cada linha representa uma observação e cada coluna representa uma variável. Assim, a matriz de dados é

$$X \in \mathbb{R}^{N \times d}.$$

Explicitamente,

$$X = \begin{bmatrix} - & \mathbf{x}_1^T & - \\ - & \mathbf{x}_2^T & - \\ & \vdots & \\ - & \mathbf{x}_N^T & - \end{bmatrix},$$

onde cada observação é um vetor linha

$$\mathbf{x}_i^T = \begin{bmatrix} x_{i1} & x_{i2} & \cdots & x_{id} \end{bmatrix}.$$

A entrada x_{ij} representa o valor da variável j na observação i .

Por exemplo, se medimos temperatura, pressão e velocidade em vários experimentos, então $d = 3$, e cada linha contém uma realização experimental. Se cada observação é uma imagem vetorizada, então d pode ser o número de pixels. Se cada observação é uma simulação em um instante de tempo, então d pode ser o número de graus de liberdade do estado discretizado.

Em mecânica dos fluidos, também é frequente usar a convenção oposta: cada coluna é um snapshot. Nesse caso, a matriz de dados é usualmente escrita como

$$X = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_m \end{bmatrix}.$$

Essa organização aparecerá com força na aula sobre POD. Nesta aula, para manter a conexão com a matriz de covariância usual de PCA, adotaremos a convenção linhas igual a observações e colunas igual a variáveis. A matemática é a mesma; o que muda é a posição das transpostas.

3. Centragem dos dados

A média amostral dos dados é o vetor

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \in \mathbb{R}^d.$$

Em componentes, isso significa

$$\bar{x}_j = \frac{1}{N} \sum_{i=1}^N x_{ij}, \quad j = 1, 2, \dots, d.$$

Para centralizar os dados, subtraímos esse vetor médio de todas as observações. Definimos a matriz centrada

$$B = X - \mathbf{1}\bar{\mathbf{x}}^T,$$

onde

$$\mathbf{1} = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix}^T \in \mathbb{R}^N.$$

Assim, a linha i de B é

$$\mathbf{b}_i^T = \mathbf{x}_i^T - \bar{\mathbf{x}}^T.$$

A matriz B possui média zero em cada coluna:

$$\frac{1}{N} \sum_{i=1}^N b_{ij} = 0, \quad j = 1, 2, \dots, d.$$

A centragem não é um detalhe estético. Ela muda o problema matemático. Sem centragem, a SVD enxerga simultaneamente a posição média da nuvem e sua variação. Com centragem, a PCA passa a estudar apenas a geometria das flutuações em torno da média.

Suponha, por exemplo, que os dados estejam quase sobre uma reta inclinada, mas que essa reta esteja longe da origem. Se aplicarmos SVD diretamente em X , a primeira direção pode ser influenciada fortemente pelo vetor que liga a origem ao centro da nuvem. Depois de centralizar, a origem é deslocada para o centro dos dados, e a primeira componente passa a apontar para a direção real de espalhamento da nuvem.

Em problemas físicos, essa interpretação é natural. Se $\mathbf{x}_i$ representa um campo medido em um instante de tempo, então podemos escrever

$$\mathbf{x}_i = \bar{\mathbf{x}} + \mathbf{b}_i.$$

A média $\bar{\mathbf{x}}$ representa o estado médio, enquanto $\mathbf{b}_i$ representa a flutuação. PCA nos dados centrados analisa as estruturas dominantes das flutuações.

4. Matriz de covariância

A matriz de covariância dos dados centrados é definida por

$$C = \frac{1}{N-1} B^T B \in \mathbb{R}^{d \times d}, \quad N \geq 2.$$

A entrada C_{jk} é

$$C_{jk} = \frac{1}{N-1} \sum_{i=1}^N b_{ij} b_{ik}.$$

Portanto, C_{jk} mede como as variáveis j e k variam conjuntamente. Quando $j = k$, obtemos a variância da variável j :

$$C_{jj} = \frac{1}{N-1} \sum_{i=1}^N b_{ij}^2.$$

Quando $j \neq k$, obtemos a covariância entre duas variáveis distintas.

A matriz C é simétrica:

$$C^T = \left(\frac{1}{N-1} B^T B \right)^T = \frac{1}{N-1} B^T B = C.$$

Além disso, C é semidefinida positiva. Para qualquer vetor $\mathbf{w} \in \mathbb{R}^d$, temos

$$\mathbf{w}^T C \mathbf{w} = \mathbf{w}^T \left(\frac{1}{N-1} B^T B \right) \mathbf{w} = \frac{1}{N-1} (B\mathbf{w})^T (B\mathbf{w}) = \frac{1}{N-1} \|B\mathbf{w}\|_2^2 \geq 0.$$

Essa expressão é central para a PCA. Registre-se, desde já, a consequência que usaremos adiante: se $\mathbf{v}$ é autovetor unitário de C , com $C\mathbf{v} = \lambda\mathbf{v}$, então $\lambda = \mathbf{v}^T C \mathbf{v} \geq 0$. Ou seja, é da *semidefinição positiva* — e não da simetria — que vem a não negatividade dos autovalores. A simetria garante outra coisa, igualmente necessária: que eles sejam reais e que exista uma base ortonormal de autovetores.

O vetor $B\mathbf{w} \in \mathbb{R}^N$ contém as projeções das observações centradas na direção $\mathbf{w}$. Se $\|\mathbf{w}\|_2 = 1$, então

$$\mathbf{w}^T C \mathbf{w} = \frac{1}{N-1} \|B\mathbf{w}\|_2^2$$

é a variância dos dados quando observados ao longo da direção $\mathbf{w}$. Assim, estudar a matriz de covariância equivale a estudar como a variância dos dados depende da direção de observação.

5. PCA como problema de maximização de variância

A primeira componente principal é a direção unitária $\mathbf{v}_1$ que maximiza a variância projetada dos dados:

$$\mathbf{v}_1 = \arg \max_{\|\mathbf{w}\|_2=1} \mathbf{w}^T C \mathbf{w}.$$

Como C é simétrica, ela possui uma base ortonormal de autovetores. Sejam

$$C\mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad i = 1, 2, \dots, d,$$

com autovalores reais, garantidos pela simetria, e não negativos, garantidos pela semidefinição positiva estabelecida na seção anterior:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d \geq 0.$$

Então $\mathbf{v}_1$, autovetor associado ao maior autovalor, resolve o problema de maximização acima.

A razão pode ser vista diretamente. Como os autovetores de C formam uma base ortonormal, qualquer vetor unitário $\mathbf{w}$ pode ser escrito como

$$\mathbf{w} = a_1 \mathbf{v}_1 + a_2 \mathbf{v}_2 + \cdots + a_d \mathbf{v}_d,$$

com

$$a_1^2 + a_2^2 + \cdots + a_d^2 = 1.$$

Logo,

$$\mathbf{w}^T C \mathbf{w} = \sum_{i=1}^d \lambda_i a_i^2.$$

Como λ_1 é o maior autovalor,

$$\sum_{i=1}^d \lambda_i a_i^2 \leq \lambda_1 \sum_{i=1}^d a_i^2 = \lambda_1.$$

A igualdade ocorre quando toda a massa está concentrada nas direções de autovalor máximo, isto é, quando $a_i = 0$ para todo i com $\lambda_i < \lambda_1$. Se $\lambda_1 > \lambda_2$, isso força $a_1^2 = 1$ — ou seja, $a_1 = \pm 1$ — e os demais nulos, e o maximizador é $\mathbf{w} = \mathbf{v}_1$, único a menos de sinal. Se λ_1 for um autovalor repetido, qualquer vetor unitário do autoespaço correspondente maximiza a forma quadrática, e as componentes principais desse bloco não ficam unicamente definidas.

A segunda componente principal é obtida impondo ortogonalidade à primeira:

$$\mathbf{v}_2 = \arg \max_{\|\mathbf{w}\|_2=1, \mathbf{w}^T \mathbf{v}_1=0} \mathbf{w}^T C \mathbf{w}.$$

A solução é o autovetor associado a λ_2 . Continuando esse raciocínio, as componentes principais são os autovetores de C , ordenados pelos autovalores decrescentes.

Portanto, PCA pode ser entendida como uma rotação do sistema de coordenadas original para um novo sistema em que a matriz de covariância fica diagonal. Se

$$V = \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_d \end{bmatrix},$$

então

$$C = V \Lambda V^T, \quad \Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d).$$

Nas coordenadas principais, a covariância é

$$V^T C V = \Lambda.$$

Isso significa que as novas variáveis são descorrelacionadas linearmente, e suas variâncias são os autovalores λ_i .

6. PCA como SVD dos dados centrados

Embora a PCA possa ser apresentada pela decomposição espectral da matriz de covariância, a forma computacional mais robusta é obtê-la pela SVD da matriz centrada B . Escrevemos

$$B = U\Sigma V^T.$$

Então,

$$B^T B = (U\Sigma V^T)^T (U\Sigma V^T).$$

Como $U^T U = I$, temos

$$B^T B = V\Sigma^T \Sigma V^T.$$

Logo,

$$C = \frac{1}{N-1} B^T B = V \left(\frac{1}{N-1} \Sigma^T \Sigma \right) V^T.$$

Comparando com

$$C = V\Lambda V^T,$$

obtemos

$$\lambda_i = \frac{\sigma_i^2}{N-1}.$$

Portanto, os vetores singulares à direita de B são as componentes principais, e os valores singulares determinam as variâncias explicadas por essas componentes através de $\lambda_i = \sigma_i^2/(N-1)$.

Essa relação é uma das ideias mais importantes da aula:

$$\text{PCA} = \text{SVD dos dados centrados}.$$

Mais precisamente, PCA é a interpretação estatística da SVD da matriz de dados centrados. A SVD fornece a base ortonormal V , os valores singulares σ_i e as coordenadas dos dados nessa base.

As coordenadas dos dados nas componentes principais são chamadas de scores. Definimos

$$Z = BV.$$

Como

$$B = U\Sigma V^T,$$

segue que

$$Z = BV = U\Sigma V^T V = U\Sigma.$$

A coluna i de Z contém as coordenadas de todas as observações ao longo da componente principal $\mathbf{v}_i$. Assim, V contém as direções principais, enquanto Z contém os dados reescritos nessas novas direções.

7. Variância explicada

A variância total dos dados centrados é a soma das variâncias nas direções principais:

$$\lambda_1 + \lambda_2 + \cdots + \lambda_d.$$

Equivalentemente, essa soma é o traço da matriz de covariância, $\sum_{i=1}^d \lambda_i = \text{tr}(C)$, pois o traço é invariante por mudança ortonormal de base. Como

$$\lambda_i = \frac{\sigma_i^2}{N-1},$$

a variância total também pode ser escrita como

$$\frac{1}{N-1} \sum_{i=1}^d \sigma_i^2.$$

A fração de variância explicada pela componente i é

$$\eta_i = \frac{\lambda_i}{\sum_{j=1}^d \lambda_j} = \frac{\sigma_i^2}{\sum_{j=1}^d \sigma_j^2}.$$

A fração de variância explicada pelas primeiras k componentes é

$$E_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j} = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{j=1}^d \sigma_j^2}.$$

Esse número é um critério prático para redução de dimensão. Se $E_2 = 0,97$, por exemplo, então as duas primeiras componentes preservam 97% da variância total dos dados centrados. Isso não significa que toda informação física relevante está preservada, mas significa que a maior parte da variação quadrática dos dados está contida nesse subespaço bidimensional.

É importante distinguir dois enunciados. Dizer que uma componente explica muita variância é uma afirmação geométrica e estatística sobre a nuvem de dados. Não é automaticamente uma afirmação causal nem física. Em problemas de fluidos, uma estrutura de baixa energia pode ainda ser essencial para transição, instabilidade ou controle. Portanto, a variância explicada é uma medida útil, mas não substitui a interpretação do problema.

8. Redução de dimensão e reconstrução

Se mantivermos apenas as k primeiras componentes principais, definimos

$$V_k = \begin{bmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_k \end{bmatrix}.$$

As coordenadas reduzidas dos dados são

$$Z_k = BV_k \in \mathbb{R}^{N \times k}.$$

Cada linha de Z_k contém a representação de uma observação em k coordenadas principais. Essa é a etapa de redução de dimensão:

$$\mathbb{R}^d \longrightarrow \mathbb{R}^k, \quad k < d.$$

A reconstrução aproximada dos dados centrados é

$$B_k = Z_k V_k^T.$$

Como $Z_k = BV_k$, temos

$$B_k = BV_k V_k^T.$$

Além disso, pela SVD truncada,

$$B_k = U_k \Sigma_k V_k^T.$$

A reconstrução aproximada dos dados originais é obtida recolocando a média:

$$X_k = \mathbf{1} \bar{x}^T + B_k.$$

A matriz $V_k V_k^T$ é a projeção ortogonal no subespaço gerado pelas k primeiras componentes principais. Portanto, PCA reduz dimensão projetando os dados no subespaço que melhor preserva variância, entre todos os subespaços lineares de dimensão k .

A qualidade dessa reconstrução pode ser medida pela norma de Frobenius:

$$\|B - B_k\|_F^2 = \sum_{i=k+1}^r \sigma_i^2,$$

onde $r = \text{rank}(B)$. Pela ortogonalidade de U e V (como na Aula 5), $\|B\|_F^2 = \sum_{i=1}^r \sigma_i^2$; dividindo o erro por essa energia total,

$$\frac{\|B - B_k\|_F^2}{\|B\|_F^2} = 1 - E_k.$$

Assim, se as primeiras k componentes explicam 95% da variância, a fração de erro quadrático relativo na reconstrução centrada é 5%.

9. Exemplo trabalhado em duas dimensões

Considere a matriz centrada

$$B = \begin{bmatrix} \sqrt{2} & \sqrt{2} \\ -\sqrt{2} & -\sqrt{2} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 0 \end{bmatrix}.$$

Cada linha é uma observação em $\mathbb{R}^2$. A média das colunas é zero, pois as linhas aparecem em pares opostos e há uma linha nula. Portanto, essa matriz já está centrada.

Como há $N = 5$ observações, a matriz de covariância é

$$C = \frac{1}{4} B^T B.$$

Vamos calcular $B^T B$. Como cada linha de B é uma observação centrada $\mathbf{b}_i^T$, vale $B^T B = \sum_{i=1}^N \mathbf{b}_i \mathbf{b}_i^T$, de modo que basta somar as contribuições de posto 1 de cada linha. A primeira linha de B contribui com

$$\begin{bmatrix} \sqrt{2} \\ \sqrt{2} \end{bmatrix} \begin{bmatrix} \sqrt{2} & \sqrt{2} \end{bmatrix} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}.$$

A segunda linha contribui com a mesma matriz. A terceira linha contribui com

$$\begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{bmatrix}.$$

A quarta linha contribui com a mesma matriz, e a quinta não contribui. Logo,

$$B^T B = 2 \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} + 2 \begin{bmatrix} \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{bmatrix} = \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix}.$$

Portanto,

$$C = \frac{1}{4} \begin{bmatrix} 5 & 3 \\ 3 & 5 \end{bmatrix} = \begin{bmatrix} \frac{5}{4} & \frac{3}{4} \\ \frac{3}{4} & \frac{5}{4} \end{bmatrix}.$$

Agora calculamos os autovalores de C . Como

$$C = \begin{bmatrix} a & b \\ b & a \end{bmatrix}, \quad a = \frac{5}{4}, \quad b = \frac{3}{4},$$

os autovetores são

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

De fato,

$$C \mathbf{v}_1 = \begin{bmatrix} \frac{5}{4} & \frac{3}{4} \\ \frac{3}{4} & \frac{5}{4} \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 2 \mathbf{v}_1,$$

e

$$C\mathbf{v}_2 = \begin{bmatrix} \frac{5}{4} & \frac{3}{4} \\ \frac{3}{4} & \frac{5}{4} \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \frac{1}{2}\mathbf{v}_2.$$

Logo,

$$\lambda_1 = 2, \quad \lambda_2 = \frac{1}{2}.$$

A primeira componente principal é a direção diagonal

$$\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

e a segunda é a direção ortogonal

$$\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

A variância total é

$$\lambda_1 + \lambda_2 = 2 + \frac{1}{2} = \frac{5}{2}.$$

A fração explicada pela primeira componente é

$$\eta_1 = \frac{2}{5/2} = \frac{4}{5} = 0,8.$$

A fração explicada pela segunda componente é

$$\eta_2 = \frac{1/2}{5/2} = \frac{1}{5} = 0,2.$$

Portanto, apenas a primeira componente preserva 80% da variância dos dados.

Vamos agora calcular os scores. Defina

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}.$$

Então

$$Z = BV.$$

Para a primeira observação,

$$\begin{bmatrix} \sqrt{2} & \sqrt{2} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} 2 & 0 \end{bmatrix}.$$

Fazendo o mesmo para as demais linhas, obtemos

$$Z = BV = \begin{bmatrix} 2 & 0 \\ -2 & 0 \\ 0 & 1 \\ 0 & -1 \\ 0 & 0 \end{bmatrix}.$$

Esse resultado mostra exatamente o que a PCA fez. Ela encontrou uma rotação que escreve os dados em coordenadas alinhadas com as direções de maior e menor variação. Nas coordenadas originais, a nuvem estava inclinada. Nas coordenadas principais, a maior variação aparece no primeiro eixo.

Pela relação entre autovalores e valores singulares,

$$\sigma_i^2 = (N - 1)\lambda_i.$$

Assim,

$$\sigma_1^2 = 4 \cdot 2 = 8, \quad \sigma_2^2 = 4 \cdot \frac{1}{2} = 2,$$

e, portanto,

$$\sigma_1 = 2\sqrt{2}, \quad \sigma_2 = \sqrt{2}.$$

A SVD dos dados centrados tem dois valores singulares, e o quadrado desses valores singulares reproduz as variâncias principais multiplicadas por $N - 1$.

Se fizermos uma reconstrução usando apenas a primeira componente, mantemos somente a primeira coluna de Z :

$$Z_1 = \begin{bmatrix} 2 \\ -2 \\ 0 \\ 0 \\ 0 \end{bmatrix}.$$

A reconstrução centrada de posto 1 é

$$B_1 = Z_1 \mathbf{v}_1^T.$$

Logo,


$$B_1 = \begin{bmatrix} 2 \\ -2 \\ 0 \\ 0 \\ 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \end{bmatrix} = \begin{bmatrix} \sqrt{2} & \sqrt{2} \\ -\sqrt{2} & -\sqrt{2} \\ 0 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

As duas primeiras observações são reconstruídas exatamente, pois estão sobre a primeira componente. As terceira e quarta observações são projetadas na origem, pois vivem inteiramente na

segunda componente. Essa perda corresponde aos 20% de variância descartada.

10. Interpretação geométrica

Em duas dimensões, PCA pode ser visualizada como uma rotação dos eixos coordenados. Os eixos originais são substituídos por dois novos eixos ortogonais: o primeiro alinhado com a direção de maior espalhamento da nuvem, e o segundo alinhado com a direção ortogonal de maior espalhamento restante.



A nuvem espalha-se sobretudo ao longo de v_1 (maior variância); v_2 é a direção ortogonal de menor variância.

Em dimensões maiores, a ideia é a mesma. A PCA encontra um subespaço linear de dimensão k que captura a maior variância possível dos dados centrados. Esse subespaço é gerado por

$$v_1, v_2, \dots, v_k.$$

Cada observação x_i é aproximada por

$$x_i \approx \bar{x} + \text{combinação linear de } v_1, \dots, v_k.$$

Isso deixa claro que PCA é um método linear. Ela procura um plano, hiperplano ou subespaço linear que represente bem os dados. Se os dados estiverem sobre uma variedade curva, a PCA pode ainda ser útil localmente ou como primeira aproximação, mas não capturará toda a geometria não linear.

Em muitos problemas físicos, essa aproximação linear é surpreendentemente eficiente. Escoamentos com estruturas coerentes, respostas térmicas dominadas por poucos modos e sinais experimentais correlacionados podem ter uma fração grande de sua variância concentrada em poucas componentes. Essa é a razão pela qual PCA, SVD e POD aparecem de forma recorrente em aprendizado de máquina científico. Um exemplo clássico em reconhecimento de padrões é o das *eigenfaces*, em que as componentes principais de um conjunto de imagens de rostos formam

uma base compacta para representá-los.¹

11. PCA, unidades físicas e escalonamento

A PCA depende da escala das variáveis — mas é necessário ser preciso sobre *qual* escala. Como a análise é feita sobre os dados centrados B , o nível médio de uma variável é irrelevante: ele foi subtraído na Seção 3 e não entra em C . O que domina são as *flutuações* em torno da média. Assim, se as flutuações de uma variável forem numericamente muito maiores que as das outras — o que costuma ocorrer quando as unidades diferem por ordens de grandeza —, a variância dela tende a dominar as primeiras componentes. Por exemplo, se as pressões flutuam na ordem de 10^3 Pa em torno da média e as velocidades na ordem de 1 m/s, aplicar PCA diretamente pode fazer com que a primeira componente seja essencialmente a pressão. Note que uma pressão de ordem 10^5 Pa com flutuações minúsculas *não* dominaria nada.

Em estatística e aprendizado de máquina, uma prática comum é padronizar as variáveis, isto é, subtrair a média e dividir pelo desvio padrão. Isso transforma cada variável em uma quantidade adimensional com variância unitária. Em termos matriciais, se s_j é o desvio padrão amostral da variável j — calculado com o mesmo fator $1/(N-1)$ usado em C , e necessariamente positivo, o que exclui variáveis constantes —, usamos

$$\tilde{b}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}, \quad s_j > 0.$$

A PCA aplicada a $\tilde{B}$ equivale a trabalhar com a matriz de correlação, e não diretamente com a matriz de covariância.

Em problemas físicos, entretanto, a padronização deve ser usada com cuidado. Dividir cada variável por seu desvio padrão pode apagar relações dimensionais importantes. Se as variáveis representam grandezas físicas diferentes, pode ser mais adequado trabalhar com uma normalização baseada em escalas características do problema, como velocidade de referência, comprimento característico, temperatura de referência ou energia cinética. Portanto, a decisão de centralizar, padronizar ou adimensionalizar não é apenas numérica; é também uma decisão de modelagem.

12. Limitações da PCA

A PCA é poderosa, mas sua interpretação exige cuidado. A primeira limitação é a linearidade. A PCA procura subespaços lineares. Se os dados estão organizados em uma estrutura curva, como uma variedade não linear, muitas componentes lineares podem ser necessárias para representar uma geometria que, intrinsecamente, tem poucos graus de liberdade.

A segunda limitação é a sensibilidade à escala. Variáveis com maior variância numérica

¹BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering*. 2. ed. Cambridge University Press, 2022, §1.6.

tendem a dominar as primeiras componentes. Por isso, a preparação dos dados é parte essencial da análise.

A terceira limitação é que variância não é sinônimo de importância. Uma direção de grande variância pode representar uma oscilação dominante, mas uma direção de pequena variância pode conter a informação que separa dois regimes, indica uma instabilidade ou antecipa uma transição.

A quarta limitação é a sensibilidade a outliers. Como a PCA é baseada em variância quadrática, pontos extremos podem modificar de forma considerável as componentes principais.

A quinta limitação, especialmente importante em mecânica dos fluidos, é o alinhamento dos dados. Translações, rotações ou deslocamentos de estruturas coerentes podem aumentar artificialmente o número de componentes necessárias. Um único vórtice se deslocando no domínio pode parecer um fenômeno de posto alto se os snapshots forem organizados em uma base fixa e desalinhada.

Essas limitações não tornam a PCA fraca. Elas definem o seu uso correto. A PCA é uma ferramenta de organização linear da variância. Quando combinada com conhecimento físico, ela se torna uma porta de entrada para redução de ordem, visualização, compressão, filtragem e descoberta de padrões.

13. Síntese da aula

A PCA começa com uma matriz de dados

$$X \in \mathbb{R}^{N \times d}.$$

Subtraímos a média de cada variável para obter a matriz centrada

$$B = X - \mathbf{1}\bar{\mathbf{x}}^T.$$

A matriz de covariância é

$$C = \frac{1}{N-1} B^T B.$$

As componentes principais são os autovetores de C , ordenados por autovalores decrescentes:

$$C\mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad \lambda_1 \geq \lambda_2 \geq \dots \geq 0.$$

A mesma informação é obtida pela SVD dos dados centrados:

$$B = U \Sigma V^T.$$

Nesse caso, as componentes principais são as colunas de V , e as variâncias explicadas são

$$\lambda_i = \frac{\sigma_i^2}{N-1}.$$

As coordenadas principais são

$$Z = BV = U\Sigma.$$

A fração de variância explicada pelas primeiras k componentes é

$$E_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j} = \frac{\sum_{i=1}^k \sigma_i^2}{\sum_{j=1}^d \sigma_j^2}.$$

A reconstrução usando k componentes é

$$X_k = \mathbf{1}\bar{\mathbf{x}}^T + BV_kV_k^T = \mathbf{1}\bar{\mathbf{x}}^T + U_k\Sigma_kV_k^T.$$

Portanto, PCA é a SVD dos dados centrados interpretada como uma decomposição da variância dos dados em direções ortogonais.

14. Exercícios propostos

Exercício 1. Considere os pontos

$$(1, 2), \quad (2, 4), \quad (3, 6).$$

Construa a matriz de dados X , calcule a média $\bar{\mathbf{x}}$, obtenha a matriz centrada B e calcule a matriz de covariância C . Qual é o posto de B ? O que isso indica sobre a geometria dos pontos?

Exercício 2. Considere a matriz de covariância

$$C = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}.$$

Determine as componentes principais, os autovalores e a fração de variância explicada por cada componente. Faça uma interpretação geométrica.

Exercício 3. Considere a matriz de covariância

$$C = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Calcule os autovalores e autovetores. Qual é a direção de maior variância? Qual fração da variância total é explicada pela primeira componente?

Exercício 4. Uma matriz de dados centrados $B \in \mathbb{R}^{100 \times 5}$ possui valores singulares

$$\sigma_1 = 20, \quad \sigma_2 = 10, \quad \sigma_3 = 5, \quad \sigma_4 = 2, \quad \sigma_5 = 1.$$

Calcule as variâncias principais λ_i e a fração de variância explicada pelas duas primeiras componentes.

Exercício 5. Explique por que aplicar PCA sem centralizar os dados pode gerar uma primeira componente associada à posição média da nuvem, e não à direção dominante de variação.

Exercício 6. Em uma aplicação física, duas variáveis possuem unidades e escalas muito diferentes. Discuta as diferenças entre aplicar PCA diretamente aos dados centrados, aplicar PCA aos dados padronizados e aplicar PCA a dados adimensionalizados com escalas físicas características.

Exercício 7. Considere dados de um escoamento em que a primeira componente principal explica 92% da variância. Isso significa que todos os fenômenos fisicamente relevantes estão contidos nessa componente? Justifique com base na diferença entre variância estatística e importância física.

Exercício 8. Mostre que, se $B = U\Sigma V^T$, então as coordenadas principais são $Z = BV = U\Sigma$. Explique o significado das linhas de Z e das colunas de V .

15. Referências

- BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. 2. ed. Cambridge University Press, 2022.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.
- STRANG, G. *Introduction to Linear Algebra*. 6. ed. Wellesley-Cambridge Press, 2023.