

Resumo do Módulo 1

Álgebra Linear, SVD, PCA, POD e Modelos de Ordem Reduzida

NeuroFluidos, Fundamentos de Aprendizado de Máquina Científico para Mecânica dos Fluidos

Prof. Dr. Rodrigo Figueiredo Abdo

Resumo

Este documento consolida o Módulo 1 do curso. O fio condutor é único: da leitura da multiplicação Ax como combinação de colunas até a projeção da física de um escoamento inteiro em um subespaço de baixa dimensão. Percorremos os fundamentos de álgebra linear, a decomposição em valores singulares (SVD) e sua aproximação de posto baixo, e as três leituras que dela derivam, PCA (estatística), POD (física de campos) e ROM (dinâmica reduzida). O texto enfatiza as dimensões das matrizes, as hipóteses de cada resultado e as distinções que mais geram confusão.

Sumário

1	Panorama: o arco do módulo	2
2	Fundamentos de álgebra linear	3
2.1	Multiplicação matriz–vetor como combinação de colunas	3
2.2	Os quatro subespaços fundamentais	3
2.3	Produto interno, norma, ortogonalidade e projeção	3
2.4	Matrizes ortogonais	4
2.5	Autovalores e autovetores	4
2.6	Matrizes simétricas e decomposição espectral	4
2.7	Normas de matrizes	4
3	SVD, Decomposição em Valores Singulares	5
3.1	Enunciado e dimensões	5
3.2	Interpretação geométrica	5
3.3	Forma de soma (díadica)	6
3.4	SVD reduzida versus completa	6
3.5	Relação com $A^T A$ e AA^T	6
3.6	Os quatro subespaços via SVD	6
4	Aproximação de posto baixo (Eckart–Young)	6
4.1	SVD truncada	6
4.2	O teorema de otimalidade	6
4.3	Energia, erro e a relação ao quadrado	7
5	PCA, Análise de Componentes Principais	7
5.1	Convenção dos dados e centragem	7
5.2	Matriz de covariância e componentes	8
5.3	Scores (projeções)	8

6	POD, Decomposição Ortogonal Própria	8
6.1	Do campo ao vetor: snapshots	8
6.2	Campo médio e flutuações	9
6.3	SVD, modos e coeficientes	9
6.4	As duas formas de obter os coeficientes	9
6.5	Método dos snapshots	10
6.6	Produto interno físico (malha não uniforme)	10
6.7	Posto dos dados versus truncamento	10
6.8	PCA e POD: por que os papéis de U e V se trocam	10
6.9	Limitações	10
7	ROM, Modelo de Ordem Reduzida	10
7.1	Representação e coordenadas	10
7.2	Projeção ortogonal e erro	11
7.3	Da aproximação do estado à da dinâmica	11
7.4	Projeção de Galerkin	11
7.5	Caso linear: redução fechada	11
7.6	Forma contínua	11
7.7	Caso especial: a equação do calor	11
7.8	Caso não linear: o gargalo	12
7.9	Validação	12
8	A distinção decisiva: POD $\neq$ ROM	12
9	Exemplos resolvidos	13
9.1	Exemplo A, coordenadas e erro de projeção	13
9.2	Exemplo B, POD algébrica (SVD “de graça”)	13
9.3	Exemplo C, ROM linear	13
10	Síntese	13

1 Panorama: o arco do módulo

Todo o módulo pode ser resumido em uma cadeia de transformações de significado:

dados $\xrightarrow[\text{a mesma matemática}]{\text{SVD = PCA = POD}}$ modos dominantes $\xrightarrow[\text{muda a natureza}]{\text{projeção de Galerkin}}$ dinâmica reduzida (ROM).

Há dois tipos de passagem, de naturezas diferentes:

- **De SVD para PCA e POD, mudança de interpretação.** A matemática é idêntica (a mesma decomposição $A = U\Sigma V^T$, aplicada a dados *centrados*); só muda a leitura: o estatístico vê variância, o engenheiro de fluidos vê estruturas coerentes.
- **De POD para ROM, mudança de natureza.** Sai-se de uma *decomposição de dados* (retrospectiva) e entra-se em uma *aproximação de dinâmica* (preditiva): ganha-se uma equação que pode ser integrada para gerar estados novos, inclusive em condições não amostradas, desde que dentro da validade da base.

Notação. A tabela abaixo fixa os símbolos usados no texto.

Símbolo	Significado	Símbolo	Significado
$\mathbf{x}, \mathbf{u}$	vetores (coluna)	A, X	matrizes
$A^\top$	transposta	$\text{posto}(A)$	posto
$\text{Col}(A)$	espaço coluna	$\text{Nul}(A)$	espaço nulo
σ_i	valores singulares	λ_i	autovalores
U, V	fatores ortogonais da SVD	Σ	diagonal de σ_i
ϕ_j	modos espaciais (POD)	$a_j(t)$	amplitudes temporais
Φ	base reduzida ($n \times r$)	$\mathbf{a}$	coordenadas reduzidas
n	graus de liberdade espaciais	m	número de snapshots
r_0	posto dos dados	r	posto de truncamento (escolha)
N, p	observações, variáveis (PCA)	t_k	instante k

Aviso sobre m e n . No enunciado *geral* da SVD (Seção 3), m e n são apenas o número de linhas e de colunas de uma matriz qualquer. Nas aplicações a dados, a matriz é *orientada*, e as letras ganham papel físico: na PCA, $B \in \mathbb{R}^{N \times p}$ tem N observações (linhas) e p variáveis (colunas); na POD, $X' \in \mathbb{R}^{n \times m}$ tem n pontos espaciais (linhas) e m snapshots (colunas). A correspondência entre as duas é $N \leftrightarrow m$ e $p \leftrightarrow n$, pois uma tabela é a transposta da outra (Seção 6.10).

2 Fundamentos de álgebra linear

2.1 Multiplicação matriz–vetor como combinação de colunas

Seja $A \in \mathbb{R}^{m \times n}$ com colunas $\mathbf{a}_1, \dots, \mathbf{a}_n \in \mathbb{R}^m$. Então

$$A\mathbf{x} = \sum_{j=1}^n x_j \mathbf{a}_j.$$

Ou seja: $A\mathbf{x}$ é uma *combinação linear das colunas de A* , com as entradas de $\mathbf{x}$ como pesos. Essa é a leitura mais produtiva do módulo inteiro, reconstruções, projeções e a própria SVD são casos particulares dela.

2.2 Os quatro subespaços fundamentais

Para $A \in \mathbb{R}^{m \times n}$ de posto $r = \text{posto}(A)$:

- **Espaço coluna** $\text{Col}(A) = \text{ger}\{\mathbf{a}_1, \dots, \mathbf{a}_n\} \subseteq \mathbb{R}^m$, de dimensão r : tudo que A consegue gerar como saída.
- **Espaço linha** $\text{Lin}(A) = \text{Col}(A^\top) \subseteq \mathbb{R}^n$, de dimensão r .
- **Espaço nulo** $\text{Nul}(A) = \{\mathbf{x} : A\mathbf{x} = \mathbf{0}\} \subseteq \mathbb{R}^n$, de dimensão $n - r$: as direções de entrada que A anula.
- **Espaço nulo à esquerda** $\text{Nul}(A^\top) \subseteq \mathbb{R}^m$, de dimensão $m - r$.

Vale o *teorema do posto–nulidade*: $\text{posto}(A) + \dim \text{Nul}(A) = n$. A SVD (Seção 3) fornecerá bases ortonormais explícitas para os quatro.

2.3 Produto interno, norma, ortogonalidade e projeção

Em $\mathbb{R}^n$, o produto interno e a norma euclidiana são

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y} = \sum_i x_i y_i, \quad \|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^\top \mathbf{x}}.$$

Dois vetores são *ortogonais* se $\mathbf{x}^\top \mathbf{y} = 0$; um conjunto é *ortonormal* se, além disso, cada vetor tem norma 1. A *projeção ortogonal* de $\mathbf{u}$ sobre um subespaço com base ortonormal em colunas de Q é $QQ^\top \mathbf{u}$, e o erro $\mathbf{u} - QQ^\top \mathbf{u}$ é ortogonal ao subespaço. *Imagem*: a projeção de $\mathbf{u}$ é a sua **sombra** sobre o subespaço, e a linha que liga $\mathbf{u}$ à sombra, o erro, cai perpendicular ao subespaço. Este fato reaparece, literalmente, na projeção de Galerkin (Seção 7).

2.4 Matrizes ortogonais

$Q \in \mathbb{R}^{n \times n}$ é *ortogonal* se $Q^\top Q = QQ^\top = I_n$, isto é, suas colunas formam uma base ortonormal. Matrizes ortogonais *preservam* comprimentos e ângulos: $\|Q\mathbf{x}\|_2 = \|\mathbf{x}\|_2$. Geometricamente, são rotações e reflexões. Os fatores U e V da SVD são ortogonais.

Cuidado com a ordem quando a matriz é retangular. Se $\Phi \in \mathbb{R}^{n \times r}$ tem *colunas* ortonormais mas $r < n$, então $\Phi^\top \Phi = I_r$ (identidade $r \times r$), **mas** $\Phi \Phi^\top \neq I_n$: esta última é o *projektor ortogonal* sobre o subespaço gerado pelas colunas (posto r), que descarta a parte fora dele. Só valeria $\Phi \Phi^\top = I_n$ se Φ fosse quadrada ($r = n$).

2.5 Autovalores e autovetores

Para $A \in \mathbb{R}^{n \times n}$, um par $(\lambda, \mathbf{v})$ com $\mathbf{v} \neq \mathbf{0}$ é *autovalor/autovetor* se

$$A\mathbf{v} = \lambda\mathbf{v}.$$

Interpretação: $\mathbf{v}$ é uma direção *preservada* por A , a transformação apenas a reescala pelo fator λ . Matrizes quadradas gerais podem ter autovalores complexos; as simétricas, não.

2.6 Matrizes simétricas e decomposição espectral

Se $A = A^\top$, então A admite a *decomposição espectral*

$$A = Q\Lambda Q^\top, \quad Q \text{ ortogonal}, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n),$$

com todos os λ_i *reais* e as colunas de Q formando uma *base ortonormal* de autovetores. Este é o protótipo que a SVD generaliza para matrizes retangulares.

Simetria $\nRightarrow$ autovalores ≥ 0 . A simetria garante autovalores *reais* e base ortonormal; *não* garante o sinal. A não negatividade é uma propriedade separada, a *semidefinição positiva*. Uma matriz simétrica A é semidefinida positiva se $\mathbf{v}^\top A\mathbf{v} \geq 0$ para todo $\mathbf{v}$, o que equivale a $\lambda_i \geq 0$. Em particular, *toda* matriz da forma $A^\top A$ é semidefinida positiva, pois

$$\mathbf{v}^\top A^\top A \mathbf{v} = (A\mathbf{v})^\top (A\mathbf{v}) = \|A\mathbf{v}\|_2^2 \geq 0.$$

É daqui, e não da simetria, que vem $\sigma_i^2 \geq 0$ na SVD.

2.7 Normas de matrizes

Duas normas atravessam o módulo:

$$\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2} = \sqrt{\text{tr}(A^\top A)} = \sqrt{\sum_i \sigma_i^2} \quad (\text{Frobenius}), \quad \|A\|_2 = \sigma_1 \quad (\text{espectral}).$$

A de Frobenius soma a “energia” de todas as entradas (como se empilhasse a matriz num vetor gigante e medisse seu comprimento); a espectral mede o maior estiramento (veremos em §3.2 que σ_1 é, de fato, o maior fator de estiramento da matriz). Ambas são *unitariamente invariantes* ($\|UAV\| = \|A\|$ para U, V ortogonais), o que as torna as normas naturais para medir erro de aproximação via SVD.

3 SVD, Decomposição em Valores Singulares

Por que uma decomposição nova? A decomposição espectral $A = Q\Lambda Q^T$ só existe para matrizes **quadradas**. Dados reais são tabelas **retangulares** ($m \neq n$): aí a própria equação $A\mathbf{v} = \lambda\mathbf{v}$ perde sentido, porque $\mathbf{v}$ vive em $\mathbb{R}^n$ e $A\mathbf{v}$ vive em $\mathbb{R}^m$, nem moram no mesmo espaço, não há como compará-los. A SVD contorna isso pedindo menos: que cada direção de *entrada* $\mathbf{v}_i$ seja levada a uma direção de *saída* $\mathbf{u}_i$, esticada por um fator σ_i . É essa a generalização.

3.1 Enunciado e dimensões

Teorema 1 (SVD). Toda matriz $A \in \mathbb{R}^{m \times n}$ pode ser escrita como

$$A = U\Sigma V^T, \quad U \in \mathbb{R}^{m \times m}, \quad V \in \mathbb{R}^{n \times n} \text{ ortogonais}, \quad \Sigma \in \mathbb{R}^{m \times n} \text{ “diagonal”},$$

com $\Sigma_{ii} = \sigma_i \geq 0$ e $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$, $p = \min(m, n)$. Os σ_i são os *valores singulares*; as colunas $\mathbf{u}_i$ de U e $\mathbf{v}_i$ de V são os *vetores singulares* à esquerda e à direita.

3.2 Interpretação geométrica

Vista como transformação $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$, a SVD decompõe A em três operações aplicadas *da direita para a esquerda*:

$$A\mathbf{x} = \underbrace{U}_{\text{rotação na saída } \mathbb{R}^m} \underbrace{\Sigma}_{\text{estiramento}} \underbrace{V^T \mathbf{x}}_{\text{rotação na entrada } \mathbb{R}^n}.$$

Portanto:

- as colunas $\mathbf{v}_i$ de V são as **direções de entrada** (base ortonormal de $\mathbb{R}^n$);
- as colunas $\mathbf{u}_i$ de U são as **direções de saída** (base ortonormal de $\mathbb{R}^m$);
- cada σ_i mede *quanto* a direção $\mathbf{v}_i$ é esticada, indo para $\mathbf{u}_i$: vale a relação fundamental

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i.$$

Uma esfera unitária no espaço de entrada é levada em um elipsoide no espaço de saída, cujos semieixos são os σ_i nas direções $\mathbf{u}_i$.

Exemplo mínimo. Para $A = \text{diag}(3, 1)$, temos $U = V = I$, $\sigma_1 = 3$, $\sigma_2 = 1$: o círculo unitário vira uma elipse de semieixos 3 (horizontal) e 1 (vertical). A SVD só “dá trabalho” quando a matriz *mistura* direções, aí V^T precisa girar para achar os eixos escondidos que a matriz privilegia.




Figura 1. A SVD leva a esfera unitária de entrada num elipsoide de saída: cada direção $\mathbf{v}_i$ vira $\mathbf{u}_i$, esticada por σ_i . Em geral o elipsoide aparece *girado*, esse giro é o papel de U .

3.3 Forma de soma (díadica)

Somando apenas os termos com $\sigma_i > 0$,

$$A = \sum_{i=1}^{r_0} \sigma_i \mathbf{u}_i \mathbf{v}_i^T, \quad r_0 = \text{posto}(A).$$

Cada parcela $\sigma_i \mathbf{u}_i \mathbf{v}_i^T$ é uma matriz de *posto um*. A matriz é, então, uma soma de r_0 camadas de posto um, ordenadas por importância.

3.4 SVD reduzida versus completa

Se $m > n$ (caso típico de dados: muitas amostras/linhas), guarda-se apenas a *SVD reduzida* (ou compacta): $U \in \mathbb{R}^{m \times r_0}$, $\Sigma \in \mathbb{R}^{r_0 \times r_0}$, $V \in \mathbb{R}^{n \times r_0}$, com $r_0 = \text{posto}(A)$. As colunas descartadas de U correspondem a valores singulares nulos e não contribuem para A . (A forma dita *econômica* retém $\min(m, n)$ colunas; a *reduzida* vai além e mantém só as r_0 associadas a $\sigma_i > 0$.)

3.5 Relação com $A^T A$ e AA^T

Da SVD seguem

$$A^T A = V \Sigma^T \Sigma V^T, \quad AA^T = U \Sigma \Sigma^T U^T.$$

Logo os $\mathbf{v}_i$ são autovetores de $A^T A$ e os $\mathbf{u}_i$ são autovetores de AA^T , ambos com autovalores σ_i^2 . Como $A^T A$ e AA^T são simétricas e semidefinidas positivas, seus autovalores são reais e ≥ 0 , o que garante $\sigma_i = \sqrt{\lambda_i}$ real. Esta é a ponte entre a decomposição espectral (matrizes simétricas) e a SVD (matrizes quaisquer).

3.6 Os quatro subespaços via SVD

Com $r = r_0$:

$$\begin{aligned} \text{Col}(A) &= \text{ger}\{\mathbf{u}_1, \dots, \mathbf{u}_r\}, & \text{Nul}(A^T) &= \text{ger}\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_m\}, \\ \text{Lin}(A) &= \text{ger}\{\mathbf{v}_1, \dots, \mathbf{v}_r\}, & \text{Nul}(A) &= \text{ger}\{\mathbf{v}_{r+1}, \dots, \mathbf{v}_n\}. \end{aligned}$$

A SVD entrega, de graça, bases *ortonormais* para os quatro subespaços fundamentais.

O que representa: a fatoração matricial mais geral: organiza *qualquer* transformação linear como rotação de entrada, estiramento e rotação de saída, e revela seu posto, seus subespaços e sua melhor aproximação de baixo posto.

4 Aproximação de posto baixo (Eckart–Young)

4.1 SVD truncada

Retendo os r maiores valores singulares:

$$A_r = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T = U_r \Sigma_r V_r^T, \quad U_r \in \mathbb{R}^{m \times r}, \Sigma_r \in \mathbb{R}^{r \times r}, V_r \in \mathbb{R}^{n \times r}.$$

4.2 O teorema de otimalidade

Teorema 2 (Eckart–Young(–Mirsky)). Entre todas as matrizes B de posto $\leq r$, a truncada A_r minimiza *simultaneamente* o erro nas normas de Frobenius e espectral:

$$\min_{\text{posto}(B) \leq r} \|A - B\|_F = \|A - A_r\|_F = \sqrt{\sum_{i>r} \sigma_i^2}, \quad \min_{\text{posto}(B) \leq r} \|A - B\|_2 = \|A - A_r\|_2 = \sigma_{r+1}.$$

É por isso que “ficar com os r maiores σ_i ” é a compressão ótima naquele posto.

4.3 Energia, erro e a relação ao quadrado

Define-se a *fração de energia retida* pelos r primeiros modos e a *energia acumulada*:

$$E_j = \frac{\sigma_j^2}{\sum_{\ell} \sigma_{\ell}^2}, \quad \eta_r = \sum_{j=1}^r E_j = \frac{\sum_{j \leq r} \sigma_j^2}{\sum_{\ell} \sigma_{\ell}^2}.$$

Energia descartada = erro ao quadrado. Vale a identidade

$$\frac{\|A - A_r\|_F^2}{\|A\|_F^2} = 1 - \eta_r.$$

Logo, a fração de energia *descartada* é o erro relativo de Frobenius *elevado ao quadrado*, não o erro em si. Reter 99% da energia ($\eta_r = 0,99$) corresponde a erro relativo $\sqrt{0,01} = 10\%$, não 1%.

Escolha de r . Na prática, escolhe-se r pelo menor valor tal que η_r atinja um limiar (por exemplo 95% ou 99%), lido no *gráfico de energia acumulada*, ou plotando os σ_i em *escala logarítmica*, onde uma queda brusca seguida de cauda achatada revela um **cotovelo**: trunca-se ali, mantendo a parte íngreme e descartando a cauda.

Exemplo numérico. Com $\sigma = (10, 4, 1, 0,5)$, a energia total é $\sum \sigma_i^2 = 117,25$. Então $E_1 = 100/117,25 \approx 85\%$ e $\eta_2 = 116/117,25 \approx 99\%$: para 95% já basta $r = 2$. Note o alerta acima em ação, descartar $\approx 1\%$ de *energia* corresponde a $\approx 10\%$ de *erro* relativo de Frobenius.




Figura 2. Espectro de valores singulares: queda brusca seguida de cauda achatada. Trunca-se no *cotovelo*, mantendo a parte íngreme e descartando a cauda de baixa energia. (Em escala logarítmica no eixo vertical, o cotovelo fica ainda mais nítido.)

O que representa: o princípio de compressão ótima: descartar as camadas de posto um de menor valor singular preserva o máximo de conteúdo possível para o posto escolhido.

5 PCA, Análise de Componentes Principais

5.1 Convenção dos dados e centragem

Organize os dados em $B \in \mathbb{R}^{N \times p}$ com N **observações nas linhas** e p variáveis nas colunas. *Centralize* cada coluna subtraindo sua média (condição essencial para que a PCA meça variância em torno da média, e não em torno da origem).

Por que centrar? Pense numa nuvem de pontos quase sobre uma reta inclinada, mas *longe* da origem. Sem centrar, a primeira direção aponta para **onde** a nuvem está (o vetor da origem até o centro dela), não para **como** ela varia. Centrar desloca a nuvem para a origem; só então a primeira componente se alinha à direção real de espalhamento.




Figura 3. (a) Sem centrar, a primeira componente aponta da origem para o *centro* da nuvem, para onde ela está. (b) Depois de centrar, ela se alinha à *direção de espalhamento*, como a nuvem varia. É essa segunda que a PCA busca.

5.2 Matriz de covariância e componentes

A matriz de covariância amostral é

$$C = \frac{1}{N-1} B^T B \in \mathbb{R}^{p \times p},$$

simétrica e semidefinida positiva. Cada entrada de C mede como duas variáveis variam juntas: *positiva* se sobem juntas, *negativa* se uma sobe quando a outra desce, *próxima de zero* se não há relação linear. Sua decomposição espectral $C = V \Lambda V^T$ fornece as componentes principais. Via SVD de $B = U \Sigma V^T$,

$$C = \frac{1}{N-1} V \Sigma^T \Sigma V^T \implies \lambda_i = \frac{\sigma_i^2}{N-1},$$

onde N é o número de observações.

Componentes principais = colunas de V (vetores singulares à *direita* de B) = autovetores de C : as direções de *máxima variância* dos dados, ortogonais entre si e ordenadas por $\lambda_1 \geq \lambda_2 \geq \dots$ As *variâncias explicadas* por cada direção são os λ_i .

5.3 Scores (projeções)

Os *scores* são as coordenadas das observações nas novas direções:

$$Z = BV = U \Sigma \in \mathbb{R}^{N \times p}.$$

Cada linha de Z é uma observação reescrita na base das componentes principais; as colunas de Z são descorrelacionadas.

O que representa: a leitura *estatística* da SVD: encontrar as poucas direções ao longo das quais os dados mais variam, para reduzir dimensão preservando variância e para descorrelacionar variáveis.

6 POD, Decomposição Ortogonal Própria

6.1 Do campo ao vetor: snapshots

Um campo $u(\mathbf{x}, t)$ discretizado em n pontos de malha, num instante t_k , vira um vetor $\mathbf{u}_k \in \mathbb{R}^n$ (empilham-se os valores nodais; para campos vetoriais, concatenam-se as componentes). Colecionando m instantes lado a lado, forma-se a *matriz de snapshots* $X \in \mathbb{R}^{n \times m}$, com cada *coluna* sendo um retrato do escoamento.

6.2 Campo médio e flutuações

Separa-se a média temporal das flutuações:

$$\bar{\mathbf{u}} = \frac{1}{m} \sum_{k=1}^m \mathbf{u}_k, \quad \mathbf{X}' = \mathbf{X} - \bar{\mathbf{u}} \mathbf{1}^\top \in \mathbb{R}^{n \times m} \quad (\text{flutuações centradas}).$$

Sem subtrair a média, o primeiro modo tende a capturar o próprio escoamento médio, mascarando a dinâmica; por isso a POD para *dinâmica coerente* trabalha com $\mathbf{X}'$.

6.3 SVD, modos e coeficientes

Aplicando a SVD, $\mathbf{X}' = \mathbf{U} \Sigma \mathbf{V}^\top$ com $\mathbf{U} \in \mathbb{R}^{n \times n}$, $\mathbf{V} \in \mathbb{R}^{m \times m}$. Então

$$\begin{aligned} \phi_j = \mathbf{u}_j = \frac{1}{\sigma_j} \mathbf{X}' \mathbf{v}_j \quad (\text{modos espaciais}), \quad a_j(t_k) = \sigma_j V_{kj} \quad (\text{amplitudes temporais}), \\ E_j = \frac{\sigma_j^2}{\sum_{\ell} \sigma_{\ell}^2} \quad (\text{energia modal}), \quad \mathbf{X}' \approx \sum_{j=1}^r \sigma_j \phi_j \mathbf{v}_j^\top \quad (\text{reconstrução de posto } r). \end{aligned}$$

Modos POD = colunas de $\mathbf{U}$ (vetores singulares à *esquerda*): padrões espaciais dominantes, ortonormais, ordenados por *energia* σ_j^2 . Cada ϕ_j é um campo espacial que pode ser reorganizado na geometria original (por exemplo, uma imagem de vorticidade).

Por que “energia”? Para um campo de velocidade em malha uniforme, a soma dos quadrados das flutuações é proporcional à **energia cinética** das flutuações. Dizer “os dois primeiros modos retêm 90% da energia” significa que eles capturam 90% dessa energia cinética. (E lembre da §4.3: isto é energia; o *erro* em si é a raiz do que se descarta.)

Exemplo físico, a esteira do cilindro. Atrás de um cilindro, a POD tipicamente devolve um **par de modos quase idênticos, porém deslocados**, a assinatura do desprendimento alternado de vórtices (esteira de von Kármán). Suas amplitudes $a_1(t)$ e $a_2(t)$ oscilam em *quadratura* (uma como cosseno, a outra como seno): a cada instante o ponto (a_1, a_2) percorre uma **órbita fechada, quase um círculo** (porque $\sigma_1 \approx \sigma_2$). Milhões de graus de liberdade se reduzem a *duas amplitudes girando num círculo*: a POD não só comprimiu o dado, revelou a geometria escondida da dinâmica.

6.4 As duas formas de obter os coeficientes

Os coeficientes se obtêm por dois caminhos que *coincidem*:

$$a_j(t_k) = \sigma_j V_{kj} \quad (\text{lidos dos fatores da SVD}) \quad \Longleftrightarrow \quad a_j = \phi_j^\top \mathbf{u}'_k \quad (\text{por projeção}).$$

A prova é direta: como a coluna k de $\mathbf{X}'$ é $\mathbf{u}'_k = \sum_i \sigma_i V_{ki} \mathbf{u}_i$,

$$\phi_j^\top \mathbf{u}'_k = \mathbf{u}_j^\top \sum_i \sigma_i V_{ki} \mathbf{u}_i = \sum_i \sigma_i V_{ki} \underbrace{\mathbf{u}_j^\top \mathbf{u}_i}_{\delta_{ij}} = \sigma_j V_{kj}.$$

A leitura $\sigma_j V_{kj}$ serve para os snapshots que entraram na decomposição; a projeção $\phi_j^\top \mathbf{u}'$ funciona também para um estado *novo*.

6.5 Método dos snapshots

Quando $n \gg m$ (típico em fluidos: milhões de pontos, centenas de instantes), diagonalizar $X'X'^T \in \mathbb{R}^{n \times n}$ é inviável. Resolve-se, em vez disso, o problema *pequeno*

$$C_t = X'^T X' \in \mathbb{R}^{m \times m}, \quad C_t \mathbf{v}_j = \sigma_j^2 \mathbf{v}_j, \quad \phi_j = \frac{1}{\sigma_j} X' \mathbf{v}_j.$$

Isto entrega *exatamente* os mesmos modos: $X' \mathbf{v}_j$ é autovetor de $X'X'^T$ com autovalor σ_j^2 , pois $X'X'^T(X' \mathbf{v}_j) = X'(X'^T X') \mathbf{v}_j = \sigma_j^2(X' \mathbf{v}_j)$.

6.6 Produto interno físico (malha não uniforme)

Em malha *não uniforme*, o produto interno euclidiano distorce a energia (pontos mais densos pesam artificialmente mais). Introduce-se a *matriz de massa* M (simétrica, definida positiva) que codifica o volume/área associado a cada ponto:

$$\langle \mathbf{a}, \mathbf{b} \rangle_M = \mathbf{a}^T M \mathbf{b}, \quad \Phi^T M \Phi = I, \quad a_j = \phi_j^T M \mathbf{u}'.$$

Em malha uniforme, M é um múltiplo da identidade e recai-se no caso euclidiano.

6.7 Posto dos dados versus truncamento

Distinção de contagem: $r_0 = \text{posto}(X')$ é *quantos modos os dados têm* (propriedade dos dados; com r_0 modos a reconstrução é exata). Já $r \leq r_0$ é *quantos modos se escolhe reter* (decisão do usuário, guiada pela energia acumulada). Na prática $r \ll r_0$.

6.8 PCA e POD: por que os papéis de U e V se trocam

É a *mesma* SVD; muda só a orientação dos dados. Na PCA, as observações vão nas *linhas* ($B \in \mathbb{R}^{N \times p}$) e as componentes ficam nas colunas de V . Na POD, os snapshots vão nas *colunas* ($X' \in \mathbb{R}^{n \times m}$) e os modos ficam nas colunas de U . Como uma organização é a *transposta* da outra ($X' = B^T$, a menos de rótulos), os papéis de U e V se trocam **pela transposição**, e não porque a matemática mude. Convenção do curso: **modos POD nas colunas de U ; componentes PCA nas colunas de V .**

6.9 Limitações

A POD ordena por *energia global*, não por importância *dinâmica*: um modo de baixa energia pode governar instabilidades, transições ou transferência de energia. Além disso, a POD é linear (subespaços lineares) e depende dos dados usados para construí-la (pode falhar fora do regime amostrado). Em particular, uma estrutura que apenas **se desloca** pelo domínio, uma onda viajante, um vórtice convectado, pode exigir muitos modos, porque a SVD enxerga cada posição como um padrão novo: é um problema de *coordenadas*, não de física.

O que representa: a leitura *física* da SVD: extrair de um escoamento poucos padrões espaciais coerentes que concentram a maior parte da energia das flutuações, com a evolução temporal separada nos coeficientes.

7 ROM, Modelo de Ordem Reduzida

7.1 Representação e coordenadas

Com uma base ortonormal $\Phi = [\phi_1 \cdots \phi_r] \in \mathbb{R}^{n \times r}$ (tipicamente os r primeiros modos POD), $\Phi^T \Phi = I_r$, o estado é aproximado por

$$\mathbf{u}(t) \approx \Phi \mathbf{a}(t), \quad \mathbf{a}(t) \in \mathbb{R}^r, \quad \mathbf{a} = \Phi^T \mathbf{u} \text{ (coordenadas reduzidas).}$$

A alta dimensão fica nos modos (calculados uma vez, *offline*); a evolução fica nos poucos coeficientes $\mathbf{a}(t)$ (integrados barato, *online*).

7.2 Projeção ortogonal e erro

Quando $\mathbf{u}$ não pertence ao subespaço, sua melhor representação ali é

$$\mathbf{u}_r = \Phi \Phi^\top \mathbf{u}, \quad \mathbf{e} = \mathbf{u} - \mathbf{u}_r, \quad \Phi^\top \mathbf{e} = \mathbf{0} \text{ (erro ortogonal ao subespaço)}.$$

Lembrando a distinção crucial: $\Phi^\top \Phi = I_r$, mas $\Phi \Phi^\top$ é o *projetor* (posto r), não a identidade.

7.3 Da aproximação do estado à da dinâmica

Representar o estado ($\mathbf{u} \approx \Phi \mathbf{a}$) é o *fim da POD*. O ROM *começa* ao exigir uma equação para $\mathbf{a}(t)$. Partindo de $\dot{\mathbf{u}} = \mathbf{F}(\mathbf{u})$ e substituindo, como Φ é fixo:

$$\Phi \dot{\mathbf{a}} \approx \mathbf{F}(\Phi \mathbf{a}).$$

O lado esquerdo mora no subespaço; o direito, em geral, não, a igualdade exata pode não existir ali dentro. Define-se o *resíduo* $\mathbf{R} = \Phi \dot{\mathbf{a}} - \mathbf{F}(\Phi \mathbf{a})$.

7.4 Projeção de Galerkin

Não se anula o resíduo inteiro, mas exige-se que ele seja ortogonal ao subespaço:

$$\Phi^\top \mathbf{R} = \mathbf{0} \implies \Phi^\top (\Phi \dot{\mathbf{a}} - \mathbf{F}(\Phi \mathbf{a})) = \mathbf{0} \xrightarrow{\Phi^\top \Phi = I_r} \boxed{\dot{\mathbf{a}} = \Phi^\top \mathbf{F}(\Phi \mathbf{a})}.$$

Interpretação: dentro das direções retidas, a equação fecha perfeitamente; o erro só sobra nas direções já descartadas. É a melhor escolha *instantânea* de $\dot{\mathbf{a}}$ (minimiza $\|\Phi \dot{\mathbf{a}} - \mathbf{F}\|_2$), o que não garante que a *trajetória* resultante seja a melhor possível.

7.5 Caso linear: redução fechada

Para $\dot{\mathbf{u}} = A\mathbf{u}$, a projeção dá

$$A_r = \Phi^\top A \Phi \in \mathbb{R}^{r \times r}, \quad \dot{\mathbf{a}} = A_r \mathbf{a}.$$

Calculado A_r uma vez, toda a evolução ocorre no espaço reduzido, sem voltar a $\mathbb{R}^n$. A_r é a **sombra de A** no subespaço: a melhor descrição da ação de A que cabe ali dentro. Havendo forçante $\mathbf{f}(t)$, projeta-se também: $\mathbf{f}_r = \Phi^\top \mathbf{f}$.

7.6 Forma contínua

Com funções em vez de vetores, a expansão é $u(x, t) \approx \sum_j a_j(t) \phi_j(x)$, a ortonormalidade é $\langle \phi_j, \phi_i \rangle = \delta_{ij}$ (com integral no lugar de soma), e a condição de Galerkin é $\langle \mathbf{R}, \phi_i \rangle = 0$. É a mesma projeção, só mudando o produto interno de soma para integral (a menos do peso de quadratura da malha).

7.7 Caso especial: a equação do calor

Para $\partial_t u = \alpha \partial_{xx} u$ ($\alpha > 0$) com $u(0, t) = u(L, t) = 0$, a base natural são os senos $\phi_j = \sqrt{2/L} \sin(j\pi x/L)$, que são *autofunções* do operador: $\partial_{xx} \phi_j = -(j\pi/L)^2 \phi_j$. A projeção *desacopla* completamente os modos:

$$\dot{a}_i = -\alpha \left(\frac{j\pi}{L} \right)^2 a_i \implies a_i(t) = a_i(0) e^{-\alpha (j\pi/L)^2 t}.$$

Cada modo evolui sozinho, decaindo exponencialmente, e os de índice alto (estruturas espaciais mais finas) decaem muito mais rápido, porque o índice entra ao quadrado: é por isso que o calor *suaviza as irregularidades* rapidamente. Isto é a *exceção*, não a regra: só ocorre porque a base está alinhada ao operador. Com não linearidade, os modos raramente permanecem desacoplados.

7.8 Caso não linear: o gargalo

Para $\dot{\mathbf{u}} = \mathbf{A}\mathbf{u} + \mathbf{N}(\mathbf{u})$,

$$\dot{\mathbf{a}} = \underbrace{\Phi^T \mathbf{A} \Phi}_{A_r} \mathbf{a} + \underbrace{\Phi^T \mathbf{N}(\Phi \mathbf{a})}_{\text{pode custar } O(n)} .$$

A parte linear reduz de fato; mas avaliar $\mathbf{N}(\Phi \mathbf{a})$ pelo caminho direto exige reconstruir $\Phi \mathbf{a} \in \mathbb{R}^n$, avaliar $\mathbf{N}$ em n pontos e projetar de volta. *Reduzir o estado não é o mesmo que reduzir todo o custo*. Para não linearidades gerais, usam-se métodos de hiper-redução (EIM, DEIM); para polinomiais, tensores pré-computados.

7.9 Validação

Compara-se a solução reduzida $\mathbf{u}_r(t) = \Phi \mathbf{a}(t)$ (solução do ROM, não a mera projeção do estado verdadeiro) com uma referência:

$$\varepsilon(t) = \frac{\|\mathbf{u}(t) - \mathbf{u}_r(t)\|_2}{\|\mathbf{u}(t)\|_2} \quad (\text{instantâneo}), \quad \varepsilon_F = \frac{\|X - X_r\|_F}{\|X\|_F} \quad (\text{global}).$$

Norma pequena não basta: é preciso comparar *grandezas físicas* (energia cinética, frequência de desprendimento, arrasto, sustentação). E a validação respeita a *finalidade*: compressão, previsão ou controle exigem testes diferentes.

O que representa: a passagem de *decompor dados* para *prever*: uma equação integrável no tempo, que gera estados novos, inclusive em condições não amostradas, dentro da validade da base, a partir dos modos fornecidos pela POD.

8 A distinção decisiva: POD $\neq$ ROM

A **POD** responde: *quais modos reconstroem melhor os snapshots observados?* (erro de reconstrução; olha para trás). O **ROM** responde: *como os coeficientes desses modos evoluem no tempo?* (dinâmica; olha para frente). A POD fornece a *base*; o ROM projeta a *equação governante* nessa base, ingrediente que a POD nunca usa.

Consequências práticas:

- energia pequena $\neq$ importância dinâmica pequena;
- uma base ótima para *reconstruir* não é automaticamente um bom modelo *preditivo*;
- a truncagem pode remover modos de baixa energia dinamicamente decisivos;
- em sistemas não lineares, modos retidos e descartados interagem.

E quando não se tem, ou não se quer projetar, a equação governante? Entram os métodos *data-driven* (DMD, SINDy, redes neurais), que aprendem a dinâmica dos coeficientes diretamente dos dados. É por aí que segue o Módulo 2.

9 Exemplos resolvidos

9.1 Exemplo A, coordenadas e erro de projeção

Sejam $\phi_1 = \frac{1}{\sqrt{2}}(1, 1, 0)^\top$, $\phi_2 = (0, 0, 1)^\top$ (ortonormais) e $\mathbf{u} = (2, 4, 3)^\top$. Então

$$\mathbf{a} = \Phi^\top \mathbf{u} = \left(\frac{2+4}{\sqrt{2}}, 3 \right) = (3\sqrt{2}, 3), \quad \mathbf{u}_r = \Phi \mathbf{a} = (3, 3, 3)^\top, \quad \mathbf{e} = \mathbf{u} - \mathbf{u}_r = (-1, 1, 0)^\top,$$

com $\Phi^\top \mathbf{e} = \mathbf{0}$. *Leitura:* a projeção substituiu o par (2, 4) pela média (3, 3); o subespaço guarda a média das duas primeiras coordenadas e a terceira, e manda a diferença para o erro. Repare que $\mathbf{u}_r = (3, 3, 3) \neq \mathbf{u} = (2, 4, 3)$: isto é $\Phi\Phi^\top \neq I$ em ação, o projetor devolve a melhor sombra de $\mathbf{u}$ no subespaço, não $\mathbf{u}$ de volta. É justamente por $\Phi\Phi^\top$ não ser a identidade que sobra um erro para medir.

9.2 Exemplo B, POD algébrica (SVD “de graça”)

Com $\phi_1 = \frac{1}{\sqrt{2}}(1, 1, 0, 0)^\top$, $\phi_2 = \frac{1}{\sqrt{2}}(0, 0, 1, -1)^\top$ e amplitudes $\mathbf{a}_1^\top = (2, 0, -2, 0)$, $\mathbf{a}_2^\top = (0, 1, 0, -1)$, construa $X' = \phi_1 \mathbf{a}_1^\top + \phi_2 \mathbf{a}_2^\top$. Como os modos são ortonormais e as amplitudes ortogonais, a SVD sai normalizando as amplitudes:

$$\sigma_1 = \|\mathbf{a}_1\| = 2\sqrt{2}, \quad \sigma_2 = \|\mathbf{a}_2\| = \sqrt{2}, \quad \mathbf{v}_j = \frac{\mathbf{a}_j}{\|\mathbf{a}_j\|}.$$

A energia total é $\sigma_1^2 + \sigma_2^2 = 8 + 2 = 10$; o primeiro modo explica $E_1 = 0,8$. *Por que $\sigma_j = \|\mathbf{a}_j\|$?* Porque a fatoração já é uma SVD (modos ortonormais à esquerda, amplitudes normalizadas ortonormais à direita), e os valores singulares são únicos: o valor singular mede a energia total do modo ao longo de todos os instantes, que é exatamente a norma da sua série de amplitudes.

9.3 Exemplo C, ROM linear

Para $A = \text{diag}(-1, -2, -10)$ e Φ com colunas $\frac{1}{\sqrt{2}}(1, 1, 0)^\top$ e $(0, 0, 1)^\top$:

$$A_r = \Phi^\top A \Phi = \text{diag}\left(-\frac{3}{2}, -10\right) \implies \dot{a}_1 = -\frac{3}{2}a_1, \quad \dot{a}_2 = -10a_2.$$

A taxa $-\frac{3}{2}$ é a média de -1 e -2 : o primeiro modo mistura as duas primeiras coordenadas. *Nota:* o subespaço não é invariante por A (pois $A\phi_1$ sai dele), então o ROM é aproximação, não cópia exata, o Galerkin escolhe a melhor representação instantânea dentro do subespaço.

10 Síntese

Método	Objeto	O que representa / entrega
SVD	matriz qualquer A	fatoração $U\Sigma V^\top$: direções de entrada (V), estiramentos (Σ) e de saída (U); bases dos quatro subespaços.
SVD truncada	aproximação A_r	melhor aproximação de posto r (Eckart–Young), em Frobenius e espectral.
PCA	dados centrados $B \in \mathbb{R}^{N \times p}$	direções de máxima variância (colunas de V); $\lambda_i = \sigma_i^2 / (N - 1)$; scores BV .
POD	snapshots $X' \in \mathbb{R}^{n \times m}$	modos espaciais (colunas de U) e amplitudes temporais; energia σ_j^2 ; método dos snapshots.
ROM	dinâmica reduzida	equações para os coeficientes: $\dot{\mathbf{a}} = \Phi^\top \mathbf{F}(\Phi \mathbf{a})$; linear $A_r = \Phi^\top A \Phi$.

As duas identidades para levar do módulo:

$$\mathbf{u} \approx \Phi \mathbf{a} \quad (\text{reduz o } \textit{estado}, \text{ geometria}), \quad \dot{\mathbf{a}} = \Phi^\top \mathbf{F}(\Phi \mathbf{a}) \quad (\text{reduz a } \textit{dinâmica}, \text{ evolução}).$$

Reduzir o estado é uma coisa; reduzir a dinâmica é outra. A POD faz a primeira; a projeção de Galerkin faz a segunda.