

PLANEJAMENTO DO CURSO

Fundamentos de Aprendizagem de Máquina Científico para Mecânica dos Fluidos

Prof. Dr. Rodrigo Figueiredo Abdo — IFB, Campus Estrutural

18 semanas | 2 aulas/semana Total: 36 aulas (72 horas-aula)

Sem.	Aula	Tema	Conteúdo	Ref.	Leitura Prep.
MÓDULO 1 — FUNDAMENTOS MATEMÁTICOS E DECOMPOSIÇÕES (Semanas 1–4 / Aulas 1–8)					
1	1	Panorama: IA e mecânica dos fluidos	Motivação histórica. O que é aprendizado de máquina científico? Exemplos: PINNs, SINDy, surrogates. Apresentação do projeto PIBIC, mapa do curso, ferramentas (Python, Colab, GitHub).	[1] cap. 1, §1.1.	[1] cap. 1, §1.1.
1	2	Revisão de álgebra linear I	Matrizes e vetores: notação, multiplicação (3 visões), transposta, inversa. Posto, espaço coluna e espaço nulo. Teorema do núcleo e da imagem.	[1] cap. 1, §1.1. [3] cap. I.	[3] cap. I, §I.1–I.2.
2	3	Revisão de álgebra linear II	Autovalores e autovetores: definição, cálculo, significado geométrico. Decomposição espectral. Matrizes ortogonais. Normas de vetor e de matriz (Frobenius, espectral).	[1] cap. 1, §1.2. [3] cap. I–II.	[3] cap. I, §I.5–I.6.
2	4	SVD: definição e interpretação geométrica	Enunciado da SVD. Interpretação: rotação–estiramento–rotação. Valores singulares e sua ordenação. SVD econômica. Relação com autovalores de $\mathbf{A}^T \mathbf{A}$. Exemplos em Python.	[1] cap. 1, §1.3–1.4.	[1] cap. 1, §1.3–1.4.
3	5	SVD: truncamento e Eckart–Young	SVD como soma de matrizes de posto 1. SVD truncada $\mathbf{A}_k$. Teorema de Eckart–Young (normas Frobenius e espectral). Critérios de truncamento: energia acumulada e gap espectral. Aplicações: compressão e denoising.	[1] cap. 1, §1.5–1.6.	[1] cap. 1, §1.5–1.6.
3	6	PCA: Análise de Componentes Principais	Centragem dos dados. PCA = SVD dos dados centrados. Componentes principais e variância explicada. Relação com a matriz de covariância. Exemplo 2D trabalhado.	[1] cap. 1, §1.5–1.6.	[1] cap. 1, §1.5.
4	7	POD em mecânica dos fluidos	Proper Orthogonal Decomposition: PCA em snapshots de escoamento. Modos POD, coeficientes temporais, energia modal. Demonstração: POD do escoamento em cilindro.	[1] cap. 1, §1.6.	[1] cap. 1, §1.6.

Sem.	Aula	Tema	Conteúdo	Ref.	Leitura Prep.
4	8	Modelos de ordem reduzida e consolidação	Ideia de ROM: projetar a dinâmica em subespaço de baixa dimensão. Menção a Galerkin-POD (conceitual). Exercícios de consolidação do Módulo 1.	[1] cap. 12, §12.2.	Revisar Módulo 1.
MÓDULO 2 — REGRESSÃO, EDPs E DMD (Semanas 5–7 / Aulas 9–14)					
5	9	Regressão linear e mínimos quadrados	Formulação do problema. Mínimos quadrados: interpretação geométrica (projeção). Solução via equações normais e via pseudoinversa (SVD). Exemplo: ajuste polinomial.	[1] cap. 4, §4.1–4.2.	[1] cap. 4, §4.1.
5	10	Regularização: Ridge e Lasso	Overfitting. Regularização Ridge (L2): redução de variância. Regularização Lasso (L1): esparsidade. Validação cruzada. Demonstração: Ridge vs Lasso.	[1] cap. 4, §4.3–4.4.	[1] cap. 4, §4.3–4.4.
6	11	Regressão esparsa e compressive sensing	Soluções esparsas: interpretabilidade e generalização. Conexão com SINDy. Panorama de compressive sensing.	[1] cap. 3, §3.1–3.2.	[1] cap. 3, §3.1.
6	12	EDPs: revisão e classificação	EDOs vs EDPs. Classificação: elípticas, parabólicas, hiperbólicas. Exemplos: Laplace, calor, onda, Burgers, Navier-Stokes. Condições de contorno e iniciais.	[6] §2.	[6] §1–2.
7	13	Problemas diretos e inversos	Problema direto vs inverso: definição formal. Exemplos em transferência de calor e fluidos. Malcolocação de problemas inversos: sensibilidade a ruído, não-unicidade.	[6] §3–4.	[6] §3–4.
7	14	DMD: Dynamic Mode Decomposition	Operador linear que avança snapshots no tempo. Algoritmo DMD via SVD. Modos DMD e autovalores: frequência e crescimento/decaimento. Comparação com POD. Demonstração.	[1] cap. 7, §7.1–7.2.	[1] cap. 7, §7.1.
MÓDULO 3 — REDES NEURAIS ARTIFICIAIS (Semanas 8–10 / Aulas 15–20)					
8	15	Neurônio artificial e perceptron	Inspiração biológica. Neurônio artificial: modelo matemático. Perceptron: classificador linear. Limitação: problema XOR.	[2] cap. 6, §6.1–6.2.	[2] cap. 6, §6.1–6.2.
8	16	Redes multicamadas e aproximação universal	Arquitetura de MLP: camadas de entrada, ocultas, saída. Representação matricial. Funções de ativação: sigmoid, tanh, ReLU, Swish. Teorema da aproximação universal (enunciado intuitivo).	[2] cap. 6, §6.3–6.4. cap. 6, §6.1.	[1] [2] cap. 6, §6.3–6.4.

Sem.	Aula	Tema	Conteúdo	Ref.	Leitura Prep.
9	17	Função de perda e descida de gradiente	O que é “treinar” uma rede: minimizar função de perda. Perda quadrática e entropia cruzada. Descida de gradiente e taxa de aprendizado. Visualização do landscape de otimização.	[2] cap. 4, §4.3; cap. 8, §8.1.	[2] cap. 4, §4.3.
9	18	Backpropagation	Regra da cadeia em redes. Grafo computacional: forward e backward pass. Derivação completa para rede de 2 camadas. Eficiência computacional.	[2] cap. 6, §6.5.1–6.5.4.	[2] cap. 6, §6.5.
10	19	Otimizadores modernos	SGD: batch, mini-batch, estocástico. Momentum e Nesterov. Adam: intuição. Learning rate schedules. Comparação prática.	[2] cap. 8, §8.3–8.5.	[2] cap. 8, §8.3–8.5.
10	20	Regularização em redes neurais	Overfitting em redes profundas. Dropout, early stopping, weight decay, batch normalization. Curvas de aprendizado. Panorama de spectral bias e NTK (conceitual).	[2] cap. 7. (panorama).	[9] [2] cap. 7, §7.1–7.5.
MÓDULO 4 — PINNs: FUNDAMENTOS (Semanas 11–13 / Aulas 21–26)					
11	21	Diferenciação automática	Derivação numérica, simbólica e automática (AD). Modo forward vs reverse. <code>torch.autograd</code> . Exemplo: $\partial^2 u / \partial x^2$ de uma rede neural. Por que AD é essencial para PINNs.	[4] §1. [1] cap. 12, §12.3.	[4] §1.
11	22	Introdução conceitual a PINNs	Rede neural como aproximação da solução de uma EDP. Incorporar a EDP na função de perda. Arquitetura completa de um PINN: perda de dados + física + contorno.	[4] §1–2. [6] §3.	[4] §1–2.
12	23	PINN para EDO	Primeiro exemplo: oscilador harmônico amortecido. Formulação passo a passo da perda. Condições iniciais. Treinamento. Análise de convergência.	[4] §3. [7] §4.	[4] §3.
12	24	PINN para advecção-difusão 1D	EDP parabólica: $\partial u / \partial t + c \partial u / \partial x = \nu \partial^2 u / \partial x^2$. Formulação. Amostragem de pontos de colocação: aleatória, Latin Hypercube. Condições de contorno.	[4] §3. [5] §2.	[5] §2.
13	25	PINN para equação de Burgers 1D	Benchmark canônico. Solução de referência (Cole–Hopf). Implementação em DeepXDE. Comparação PINN vs diferenças finitas. Sensibilidade a arquitetura e pontos de colocação.	[4] §3.1. [5] §3.	[4] §3.1. Tutorial DeepXDE.

Sem.	Aula	Tema	Conteúdo	Ref.	Leitura Prep.
13	26	Treinamento de PINNs na prática	Competição entre termos de perda. Gradientes conflitantes. Pesos manuais e adaptativos. Adaptive residual sampling. Diagnóstico e boas práticas.	[9]. [7] §2–5.	[7] §2–3.
MÓDULO 5 — PINNs: APLICAÇÕES (Semanas 14–16 / Aulas 27–32)					
14	27	PINN para equação do calor 2D	Formulação 2D: $\partial T / \partial t = \alpha \nabla^2 T$. Condições mistas (Dirichlet + Neumann). Malha de colocação 2D. Visualização de campos. Comparação com solução analítica.	[5] §3.	[5] §3.
14	28	PINN para Navier-Stokes canônicos	Formulação velocidade-pressão. Incompressibilidade ($\nabla \cdot \mathbf{u} = 0$) como perda adicional. Poiseuille e Couette: validação com solução analítica. Demonstração em DeepXDE.	[5] §4. [11].	[5] §4.
15	29	Problemas inversos com PINNs	Parâmetros desconhecidos como variáveis treináveis. Identificação de α , ν , K . Efeito de ruído e esparsidade dos dados.	[4] §4. [6] §4.	[4] §4.
15	30	Assimilação de dados com PINNs	Reconstrução de campos completos a partir de medições parciais. Quantificação de incerteza: introdução conceitual a B-PINNs. Aplicações em engenharia e medicina.	[11].	[11] §1–2.
16	31	PINNs para fluidos não-newtonianos	Fluidos de lei de potência ($\tau = K\dot{\gamma}^n$): PINN com modelo constitutivo não-linear. Introdução a PINNs para fluidos viscoelásticos (Oldroyd-B). Conexão com subprojetos dos bolsistas.	[10].	[10] completo.
16	32	Limitações e direções futuras de PINNs	Failure modes. Spectral bias em EDPs multi-escala. Custo em alta dimensão. Domain decomposition: XPINNs, cPINNs. Comparação com CFD tradicional. Estado da arte.	[9].	[9] §1–3.
MÓDULO 6 — SINDy E TÓPICOS AVANÇADOS (Semana 17 / Aulas 33–35)					
17	33	SINDy: descoberta de equações	Biblioteca de funções candidatas $\Theta(\mathbf{X})$. Regressão esparsa sequencial (STLSQ). Formulação matricial. Exemplo: descoberta do sistema de Lorenz a partir de dados. Demonstração com PySINDy.	[8]. [1] cap. 7, §7.3.	[8] completo.
17	34	SINDy aplicado a escoamentos	POD + SINDy: descoberta de dinâmica reduzida. Aplicação ao escoamento em cilindro. Demonstração computacional com PySINDy.	[1] cap. 7, §7.4.	[1] cap. 7, §7.4.

Sem.	Aula	Tema	Conteúdo	Ref.	Leitura Prep.
18	35	Surrogates, Neural Operators e RL	Modelos substitutos com redes neurais. Neural Operators: DeepONet e FNO (mapear funções para funções). RL para controle de escoamentos. Comparação: PINNs vs SINDy vs surrogates vs NOs.	[1] cap. 11, §11.1; cap. 12, §12.2.	[1] cap. 12, §12.2.
MÓDULO 7 — CONSOLIDAÇÃO (Semana 18 / Aula 36)					
18	36	Workshop: apresentações dos bolsistas	Cada bolsista apresenta (20 min + 10 min discussão): subprojeto, formulação, resultados preliminares e plano para a Fase II. Discussão coletiva.	—	Preparar apresentação e notebook.

Referências

- [1] Brunton, S. L. & Kutz, J. N. (2022). *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*, 2.^a ed. Cambridge University Press. PDF gratuito: <https://databookuw.com/databookV2.pdf>. Códigos: https://github.com/dynamicslab/databook_python.
- [2] Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press. PDF gratuito: <https://www.deeplearningbook.org>.
- [3] Strang, G. (2019). *Linear Algebra and Learning from Data*. Wellesley-Cambridge Press.
- [4] Raissi, M., Perdikaris, P. & Karniadakis, G. E. (2019). “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations”. *J. Comput. Phys.*, 378, 686–707.
- [5] Cai, S. et al. (2021). “Physics-informed neural networks (PINNs) for fluid mechanics: A review”. *Acta Mech. Sinica*, 37, 1727–1738.
- [6] Karniadakis, G. E. et al. (2021). “Physics-informed machine learning”. *Nat. Rev. Phys.*, 3, 422–440.
- [7] Lu, L. et al. (2021). “DeepXDE: A deep learning library for solving differential equations”. *SIAM Rev.*, 63(1), 208–228. Documentação: <https://deepxde.readthedocs.io>.
- [8] Brunton, S. L., Proctor, J. L. & Kutz, J. N. (2016). “Discovering governing equations from data by sparse identification of nonlinear dynamical systems”. *PNAS*, 113(15), 3932–3937.
- [9] Wang, S., Yu, X. & Perdikaris, P. (2022). “When and why PINNs fail to train: A neural tangent kernel perspective”. *J. Comput. Phys.*, 449, 110768.
- [10] Zhai, R., Yin, D. & Pang, G. (2023). “A deep learning framework for solving forward and inverse problems of power-law fluids”. *Phys. Fluids*, 35(9), 093115.
- [11] Raissi, M., Yazdani, A. & Karniadakis, G. E. (2020). “Hidden fluid mechanics: Learning velocity and pressure fields from flow visualizations”. *Science*, 367, 1026–1030.

Bibliografia complementar

Leituras adicionais para bolsistas que desejarem aprofundamento, especialmente na fase dos subprojetos individuais:

- Brunton, S. L., Noack, B. R. & Koumoutsakos, P. (2020). “Machine Learning for Fluid Mechanics”. *Annu. Rev. Fluid Mech.*, 52, 477–508. — *Panorama geral da área; leitura indicada para a Aula 1.*
- Zhao, C. et al. (2024). “A comprehensive review of advances in physics-informed neural networks and their applications in complex fluid dynamics”. *Phys. Fluids*, 36(10), 101301. — *Review mais recente; útil como ponto de partida para os subprojetos.*
- Mahmoudabadbozchelou, M., Karniadakis, G. E. & Jamali, S. (2022). “nn-PINNs: Non-Newtonian physics-informed neural networks for complex fluid modeling”. *Soft Matter*, 18, 172–185. — *PINNs para fluidos viscoelásticos; referência direta para os subprojetos 3 e 5.*

Recursos computacionais

- Códigos Python de [1]: https://github.com/dynamicslab/databook_python
- DeepXDE [7]: <https://deepxde.readthedocs.io>
- PySINDy [8]: <https://pysindy.readthedocs.io>
- Tutoriais PyTorch: <https://pytorch.org/tutorials>